

Estimación Bayesiana para el modelo de Brennan-Schwartz.

Hernandez Soc Tomas David

Índice general

1. Preliminares y definición del Modelo	4
1.1. Introducción a las Ecuaciones Diferenciales Estocásticas (EDE)	4
1.1.1. Antecedentes: Del Movimiento Browniano al cálculo de Itô	4
1.1.2. Definición y estructura matemática	4
1.1.3. Justificación en el ámbito financiero	5
1.2. El modelo de Brennan–Schwartz: Definición y Propiedades	6
1.2.1. Presentación general del Modelo	6
1.2.2. Ecuación del Modelo	6
1.2.3. Características del Modelo	7
1.2.4. Datos que Puede Modelar	8
1.2.5. Aplicaciones prácticas	9
1.3. Solución Analítica y Transformación de Lamperti	9
1.3.1. Solución Analítica mediante Factor Integrante	9
1.3.2. Transformación de Lamperti	12
1.4. Análisis de Momentos y Distribución Estacionaria	13
1.4.1. Función de tendencia	14
1.4.2. Momentos transitorios	15
1.4.3. Distribución estacionaria	17
1.4.4. Momentos estacionarios	20
2. La Problemática de la Estimación con Datos Discretos	23
2.1. Simulación Numérica y Validación del Modelo	23
2.1.1. Solución Exacta del Modelo	23
2.1.2. Métodos de Simulación	24
2.1.3. Simulación de Trayectorias	26
2.1.4. Comparación Numérica: Media, Varianza y Error	28
2.1.5. Distribución Estacionaria	30
2.1.6. Análisis de Sensibilidad de Parámetros	32
2.2. Estimación Clásica: Máxima Verosimilitud y Método de Momentos.	36
2.2.1. Estimación de máxima verosimilitud de los parámetros de deriva	36
2.2.2. Estimación del parámetro de difusión σ mediante variación cuadrática	39
2.2.3. Normalidad asintótica de los estimadores	41
2.2.4. Intervalos de confianza marginales asintóticos	45
2.2.5. Estimación de parámetros a partir de simulaciones	48
3. Metodología Bayesiana y Aumento de Datos	53
3.1. El Sesgo de Discretización y el Problema de Datos Faltantes.	53
3.1.1. La brecha entre la teoría continua y la observación discreta	53

3.1.2.	Sesgo de discretización	54
3.1.3.	Inferencia Bayesiana y Aumento de Datos	55
3.2.	Simulación de Escasez de Datos y Evaluación del Error.	55
3.2.1.	El Esquema de Milstein como Verdad del Proceso	56
3.2.2.	Reducción de Datos y El Fenómeno del Submuestreo	57
3.3.	Introducción a la Inferencia Bayesiana en EDEs	58
3.3.1.	Transformación de Lamperti	59
3.3.2.	Aplicación del Lema de Itô	59
3.3.3.	Funciones auxiliares $s_{\alpha,\beta}(x)$ y $H_{\alpha,\beta}(x)$	61
3.4.	Reconstrucción de Trayectorias mediante Puentes de Difusión	62
3.4.1.	Construcción del Puente Browniano	63
3.4.2.	Validación Monte Carlo de la Reconstrucción	64
3.5.	Función de Verosimilitud Aumentada y Forma Exponencial	66
3.5.1.	Verosimilitud de Girsanov en Tiempo Continuo	66
3.5.2.	Definición de Estadísticos Suficientes y Forma Cuadrática	67
3.5.3.	Compleitud del Cuadrado y Distribución Condicional de la Deriva	70
3.6.	Algoritmo MCMC: Gibbs Sampler y Metropolis-within-Gibbs	71
3.6.1.	Distribución posteriori exacta y completitud del cuadrado	71
3.6.2.	Derivación de la distribución condicional posterior de σ^2	72
3.6.3.	Estrategia de muestreo: Metropolis-within-Gibbs	74
4.	Validación con Datos Sintéticos	76
4.1.	Resumen del Algoritmo MCMC para la Implementación Computacional	76
4.1.1.	Pasos del algoritmo MCMC	76
4.1.2.	Diseño del Experimento y Validación en Trayectoria Única	77
4.2.	Implementación Computacional y Resultados Iniciales	78
4.2.1.	Resultados Iniciales y Eficiencia del Muestreador	78
4.2.2.	El Problema de la Autocorrelación Estructural	78
4.2.3.	Tamaño Efectivo de Muestra (ESS) y Factor de Raleo	81
4.3.	Distribuciones Marginales y Conjuntas (Resultados Definitivos)	83
4.3.1.	Distribución Predictiva Posterior de las Trayectorias Latentes	85
4.4.	Validación Asintótica: Experimento de Monte Carlo	87
4.4.1.	Análisis de Resultados Agregados	87
4.4.2.	Distribución Empírica de los Estimadores	88
5.	Aplicación Empírica del Modelo Brennan–Schwartz en Mercados de Bo-	90
nos.		
5.1.	Naturaleza de los Datos y Análisis de Discontinuidad.	90
5.1.1.	El Bono del Tesoro a 10 años ($\sim$ TNX).	91
5.1.2.	Los Certificados de la Tesorería (CETES 28).	92
5.1.3.	Diagnóstico de Irregularidad Temporal.	93
5.2.	Estimación Bayesiana con Aumento de Datos.	94
5.2.1.	Implementación del Algoritmo MCMC.	95
5.2.2.	Resultados de las Estimaciones.	95
5.2.3.	Diagnóstico de Convergencia de las Cadenas.	97
5.3.	Diagnóstico Estadístico del Modelo.	100
5.3.1.	Pruebas de Verosimilitud (Log-Likelihood).	100
5.3.2.	Análisis de Residuales.	102
5.4.	Validación Predictiva Out-of-Sample.	105

5.4.1. Diseño del Experimento de Predicción.	106
5.4.2. Trayectorias Predictivas y Bandas de Confianza.	106
5.4.3. Métricas de Desempeño Predictivo.	108
6. Conclusiones y Trabajo Futuro	110
A. Cálculos técnicos	116
A.1. Cálculo del segundo momento transitorio	116
B. Repositorio Computacional y Código Fuente	119

Capítulo 1

Preliminares y definición del Modelo

1.1. Introducción a las Ecuaciones Diferenciales Estocásticas (EDE)

El uso de las Ecuaciones Diferenciales Estocásticas (EDE) ha sido fundamental para el análisis matemático y financiero en las últimas décadas. Estas ecuaciones permiten pasar de modelos deterministas, que a veces son muy limitados para representar la realidad, a modelos que incorporan la incertidumbre y el azar [44]. En esta sección daremos un repaso general sobre su origen, su definición matemática y su relevancia en el modelado de activos.

1.1.1. Antecedentes: Del Movimiento Browniano al cálculo de Itô

Todo empezó con la observación del movimiento browniano. En 1827, el botánico Robert Brown notó que las partículas de polen suspendidas en agua se movían de forma errática [15]. Aunque inicialmente no se conocía la causa, en 1905 Albert Einstein [21] y Marian Smoluchowski [52] explicaron físicamente que este comportamiento se debía al choque constante de las moléculas del fluido contra las partículas de polen.

Años después, en la década de 1920, Norbert Wiener formalizó matemáticamente este fenómeno definiendo el proceso de Wiener $\{W_t\}_{t \geq 0}$ [62]. Este proceso es la base del análisis estocástico moderno. Sin embargo, trabajar con él trajo un reto técnico: las trayectorias de Wiener son continuas, pero no se pueden derivar en ningún punto. Esto significaba que las reglas del cálculo tradicional, como la regla de la cadena, no se podían aplicar directamente a funciones que dependen de estos procesos [33, 10].

Fue el matemático Kiyosi Itô quien, en los años 40, resolvió este problema al proponer una nueva definición de integral: la integral de Itô [30]. Con esta herramienta se pudo dar un sentido matemático sólido a las ecuaciones que incluyen un componente aleatorio, dando origen formal a las EDE [33, 46].

1.1.2. Definición y estructura matemática

Básicamente, una EDE se puede entender como una extensión de una ecuación diferencial ordinaria (EDO) a la que se le añade un término de “ruido”. Si tenemos una

dinámica que normalmente se escribiría como

$$\frac{dX_t}{dt} = \mu(t, X_t),$$

donde X_t representa la variable de estado del sistema en el instante t (en este trabajo, el nivel de la tasa de interés), al agregar el componente aleatorio la expresión queda de la siguiente forma:

$$dX_t = \mu(t, X_t)dt + \sigma(t, X_t)dW_t, \quad X_{t_0} = x_0.$$

Para asegurar que esta ecuación tenga una solución única y bien definida, se asumen condiciones estándar de regularidad sobre las funciones μ y σ , como las condiciones de Lipschitz y de crecimiento lineal [44, 33]. Estas garantizan que el proceso no explote en tiempo finito.

En esta estructura hay tres componentes principales que determinan el comportamiento del sistema:

1. **El término de deriva (drift):** Representado por $\mu(t, X_t)$, indica la tendencia promedio o dirección del proceso. En finanzas, esto modela la evolución esperada de las tasas de interés a largo plazo [12].
2. **El término de difusión:** Representado por $\sigma(t, X_t)$, mide la intensidad de la volatilidad o el ruido. Como este término acompaña al diferencial dW_t , es necesario emplear el Lema de Itô para realizar cualquier cambio de variable, funcionando éste como el análogo estocástico de la regla de la cadena [44].
3. **Proceso de Wiener:** El diferencial dW_t introduce el ruido blanco esencial para modelar las fluctuaciones imprevistas de los mercados [44, 33].

La solución de esta ecuación es un proceso estocástico $\{X_t\}_{t \geq t_0}$ que cumple con la siguiente ecuación integral [33, 44]:

$$X_t = X_{t_0} + \int_{t_0}^t \mu(s, X_s)ds + \int_{t_0}^t \sigma(s, X_s)dW_s.$$

Es importante notar que la segunda integral es una integral de Itô, lo que permite que el proceso sea una martingala bajo ciertas condiciones [46]. Esta estructura es la que permite construir los métodos de estimación y verosimilitud que se verán más adelante.

Un aspecto fundamental a destacar es que, en la práctica, las trayectorias completas del proceso $\{X_t\}_{t \geq t_0}$ no son observables. En aplicaciones reales, especialmente en finanzas, solo se dispone de observaciones discretas en el tiempo [53]. Esta diferencia entre el modelo continuo y los datos discretos genera dificultades teóricas y computacionales importantes en la inferencia estadística, que motivan el desarrollo de métodos de estimación específicos, como los que se estudiarán en los capítulos posteriores [4, 5].

1.1.3. Justificación en el ámbito financiero

Las EDE se volvieron herramientas estándar en las finanzas después de los trabajos de Black, Scholes y Merton en 1973 [11, 39]. Permiten modelar comportamientos que las ecuaciones normales no capturan, como la reversión a la media en las tasas de interés o el hecho de que la volatilidad cambie dependiendo del valor del activo [12, 43].

El modelo de Brennan–Schwartz que estudiaremos en esta tesis se basa en toda esta teoría, es una forma específica de EDE diseñada para capturar la reversión a la media en las tasas de interés [12]. Su característica principal es que propone una dinámica donde la volatilidad depende directamente del nivel de la tasa de interés. Esto requiere un análisis matemático más detallado, incluyendo herramientas como la transformación de Lamperti, para poder realizar una inferencia estadística correcta, particularmente cuando se dispone de información incompleta o discretizada, como ocurre en los enfoques bayesianos basados en aumento de datos que se desarrollan más adelante [4].

1.2. El modelo de Brennan–Schwartz: Definición y Propiedades

Una vez establecidas las bases generales de las ecuaciones diferenciales estocásticas, es fundamental profundizar en el estudio del modelo que constituye el núcleo de este trabajo. El modelo de Brennan–Schwartz representa un avance significativo en la modelación de tasas de interés al proponer una estructura que combina la reversión a la media con una volatilidad dependiente del nivel de la tasa.

1.2.1. Presentación general del Modelo

El modelo Brennan–Schwartz es un esquema matemático ampliamente utilizado en las finanzas cuantitativas para modelar la dinámica de las tasas de interés y valorar diversos instrumentos de deuda. Desarrollado originalmente por Michael Brennan y Eduardo Schwartz en la década de 1970 [12], este modelo describe la evolución de las tasas de interés tanto a corto como a largo plazo mediante el uso de ecuaciones diferenciales estocásticas. Su aparición permitió abordar problemas de valoración que modelos anteriores no lograban capturar con la misma precisión técnica.

La gestión del riesgo de tasas de interés es un aspecto crítico en la administración moderna de carteras de bonos y otros instrumentos de renta fija. Los cambios en las tasas de interés tienen un impacto directo y significativo en el valor de estos instrumentos, lo que hace estrictamente necesario contar con modelos precisos y robustos para predecir su comportamiento futuro. El modelo Brennan–Schwartz se distingue por su capacidad para capturar de forma realista la dinámica de las tasas, convirtiéndose en una herramienta poderosa tanto para la valoración de bonos como para la gestión integral de riesgos en los mercados financieros [43, 57].

En el desarrollo de este trabajo, se presenta una descripción detallada del modelo, explorando a fondo sus fundamentos matemáticos y sus diversas aplicaciones prácticas en la valoración de activos. Además, se discuten los tipos de datos que pueden ser modelados bajo este esquema y las ventajas comparativas del enfoque de Brennan–Schwartz frente a otros modelos clásicos de estructura temporal [60, 20].

1.2.2. Ecuación del Modelo

El modelo describe la dinámica de la tasa de interés mediante la siguiente formulación matemática. Sea $(\Omega, \mathcal{F}, \{\mathcal{F}_t\}_{t \geq 0}, P)$ un espacio de probabilidad filtrado que cumpla con las condiciones habituales. Sea $\{X_t\}_{t \in [t_0, T]}$ un proceso de difusión homogéneo unidimensional adaptado a la filtración $\{\mathcal{F}_t\}$, el cual se define como la única solución fuerte de la siguiente

ecuación diferencial estocástica [12, 44]:

$$dX_t = (\alpha X_t + \beta)dt + \sigma X_t dW_t, \quad X_{t_0} = x_0. \quad (1.1)$$

donde los componentes se definen de la siguiente manera:

- X_t : Representa el valor de la **tasa de interés** en el instante de tiempo t , con espacio de estados en $\mathbb{R}^+$.
- σ : Es la constante que define la **volatilidad del proceso**. Al estar multiplicada por X_t , establece que la variabilidad es proporcional al nivel del proceso, capturando el fenómeno de que a mayores tasas, mayor incertidumbre absoluta.
- W_t : Es un **proceso estándar de Wiener** (o movimiento Browniano) unidimensional bajo la medida P , encargado de introducir el componente estocástico.
- $x_0 > 0$: Es un valor real fijo que representa la condición inicial del proceso.
- α y β : Son los parámetros que gobiernan el *drift* o deriva del proceso. Específicamente, determinan la **reversión a la media** y la **dirección del crecimiento** de la tasa.

Es importante notar que cuando el parámetro $\beta = 0$, el proceso se reduce a una difusión lognormal homogénea (o movimiento browniano geométrico), que se considera un caso específico dentro de esta familia. Sin embargo, para capturar la dinámica de reversión a la media que caracteriza a las tasas de interés, es usual considerar el caso general con $\beta \neq 0$ y $\alpha < 0$.

A pesar de su formulación teórica en tiempo continuo, en aplicaciones empíricas reales la tasa de interés X_t no es observada de manera continua, sino únicamente en instantes discretos $t_0, t_1, \dots, t_n$. Esta discrepancia entre la naturaleza continua del modelo y la estructura discreta de los datos observados introduce dificultades significativas en la estimación de los parámetros, particularmente un sesgo de discretización que motiva el uso de métodos de inferencia más sofisticados [53, 4].

1.2.3. Características del Modelo

El diseño de la ecuación (1.1) otorga al modelo propiedades analíticas fundamentales para el estudio de series financieras [43, 29]:

1. **Reversión a la media:** La tasa de interés tiende a volver a un nivel de equilibrio de largo plazo. En particular, cuando $\alpha < 0$, el proceso presenta reversión hacia un nivel de equilibrio determinado por $\theta = -\beta/\alpha$. Bajo esta parametrización, la deriva puede reescribirse como $\kappa(\theta - X_t)dt$, donde $\kappa = -\alpha$ representa la velocidad de reversión [12]. Un valor absoluto de α más grande implica que el proceso regresará a su promedio de manera más rápida tras sufrir un choque aleatorio.
2. **Volatilidad proporcional:** Una característica clave es que la difusión depende del nivel de X_t . Si la tasa de interés es baja, la volatilidad también lo será, y análogamente aumentará si X_t sube. Esta estructura previene, bajo ciertas condiciones matemáticas (como que $\beta > \sigma^2/2$), que la tasa toque el cero de forma persistente [34, 43]. Además, esta dependencia multiplicativa de la volatilidad complica el

análisis directo del proceso y la construcción de su función de verosimilitud exacta, lo que motiva el uso de transformaciones que estabilizan la varianza, como la transformación de Lamperti.

3. **Homogeneidad:** El modelo es homogéneo en el tiempo, lo que significa que los coeficientes de deriva $\mu(x) = \alpha x + \beta$ y de difusión $\sigma(x) = \sigma x$ no dependen explícitamente del tiempo t , facilitando el estudio de su distribución estacionaria [12].
4. **No Negatividad (bajo ciertas condiciones):** Si se cumple que $\beta \geq 0$ y la condición inicial $x_0 \geq 0$, el proceso X_t tiene la propiedad de permanecer en el cuadrante no negativo [12, 43]. Esta es una propiedad esencial para el modelado de tasas de interés nominales, las cuales por definición económica suelen estar acotadas inferiormente.

1.2.4. Datos que Puede Modelar

El modelo de Brennan–Schwartz representa un caso particular dentro de la clase de difusiones con reversión a la media y volatilidad dependiente del estado. Esta familia de modelos, que incluye estructuras fundamentales como la de Cox–Ingersoll–Ross [20] y la generalización de Chan–Karolyi–Longstaff–Sanders (CKLS) [17], comparte propiedades matemáticas que permiten capturar la dinámica de diversos fenómenos complejos. Gracias a estas propiedades estructurales, modelos de difusión con características similares han sido empleados en áreas como:

- **Tasas de Interés:** Es el área natural del modelo. Se utiliza para describir la dinámica de la tasa corta y la estructura temporal de los bonos, compartiendo fundamentos con modelos de equilibrio y no arbitraje [12, 14].
- **Commodities y Energía:** Debido a que los precios de activos como el petróleo o el gas natural tienden a regresar a un costo de producción marginal, se emplean modelos de reversión a la media inspirados en la estructura estocástica de Schwartz [49].
- **Curvas de Rendimiento:** La capacidad de modelar la volatilidad proporcional al nivel de la tasa permite una valoración más precisa de bonos con diferentes vencimientos [13].
- **Variables Macroeconómicas y Ambientales:** El uso de ecuaciones diferenciales estocásticas para modelar indicadores con tendencia de largo plazo, como la inflación o temperaturas, se apoya en la teoría de difusiones ergódicas, de la cual el modelo Brennan–Schwartz es un ejemplo analíticamente tratable [29, 9].

En esta tesis, el enfoque se centrará específicamente en la modelación de tasas de interés gubernamentales. Esta elección responde tanto a la relevancia económica de las tasas de interés de instrumentos de deudas gubernamentales como a la idoneidad del modelo para capturar la estructura de volatilidad de la economía nacional e internacional.

1.2.5. Aplicaciones prácticas

Modelar tasas de interés: La reversión a la media y la volatilidad proporcional son dos características fundamentales en el comportamiento observado de las tasas de interés en los mercados reales. En este contexto, la EDE puede ser utilizada para describir el movimiento estocástico de las tasas, proporcionando una representación más precisa de su evolución a lo largo del tiempo. Esto permite modelar fenómenos como las fluctuaciones en las tasas de corto y largo plazo, lo cual es crucial para lograr una mejor comprensión y predicción de la dinámica de los mercados financieros actuales [12, 43].

Valorar instrumentos financieros: La solución de la EDE es particularmente útil para la valoración de instrumentos financieros que dependen directamente de las tasas de interés, como los bonos, las opciones sobre tasas y otros derivados financieros complejos. En este sentido, el modelo permite calcular los precios de estos instrumentos de forma más precisa, considerando la incertidumbre de las tasas de interés futuras. Mediante técnicas de simulación numérica y métodos de Monte Carlo [36, 25], es posible obtener evaluaciones más exactas de las posiciones en derivados, especialmente en escenarios de alta complejidad donde los modelos tradicionales deterministas podrían no ser adecuados [12].

Simular escenarios: La dinámica estocástica de X_t descrita por la ecuación del modelo permite simular distintos escenarios futuros de las tasas de interés, lo cual es una tarea fundamental para la gestión de riesgos financieros. Estas simulaciones se utilizan para evaluar el impacto de diferentes trayectorias de tasas sobre carteras de bonos. Al generar múltiples caminos posibles para X_t , los gestores pueden entender mejor los riesgos asociados a sus inversiones y ajustar sus estrategias [25, 29]. Además, esta simulación ayuda significativamente a la toma de decisiones informadas en la planificación financiera institucional.

Sin embargo, la correcta implementación de estas aplicaciones depende críticamente de la estimación confiable de los parámetros. Cuando los datos son observados de forma discreta o presentan una frecuencia de muestreo baja (como datos mensuales), los métodos clásicos como la Máxima Verosimilitud exacta pueden ser difíciles de implementar o presentar sesgos significativos [54, 53]. Esto justifica el desarrollo de los enfoques bayesianos y las técnicas de aumento de datos que constituyen el eje central de esta investigación [5, 4].

1.3. Solución Analítica y Transformación de Lamperti

En esta sección se estudian las propiedades analíticas del modelo de Brennan–Schwartz. En particular, se obtiene una solución explícita de la ecuación diferencial estocástica mediante el método del factor integrante y se introduce la transformación de Lamperti. Esto ayudará a entender mejor la dinámica del proceso y al desarrollo de los métodos de inferencia estadística presentados en los capítulos posteriores.

1.3.1. Solución Analítica mediante Factor Integrante

Dado que la ecuación (1.1) es lineal en el estado X_t , es posible obtener una solución explícita utilizando técnicas estándar del cálculo estocástico. Reescribimos la ecuación

(1.1) en la forma general de una EDE lineal:

$$dX_t = (A(t)X_t + a(t))dt + (C(t)X_t + c(t))dW_t. \quad (1.2)$$

En el caso específico del modelo de Brennan–Schwartz, los coeficientes son constantes en el tiempo, identificándose como:

- $A(t) = \alpha, \quad a(t) = \beta,$
- $C(t) = \sigma, \quad c(t) = 0.$

Es decir, en nuestro caso, $A(t), a(t), C(t)$ y $c(t)$ son constantes.

Dado que la ecuación (1.1) es una EDE lineal, su solución puede expresarse mediante el método del factor integrante estocástico [33, 44], lo que conduce a la representación general (1.3):

$$X_t = \Phi_t \left(x_{t_0} + \int_{t_0}^t \Phi_s^{-1} (a(s) - C(s)c(s)) ds + \int_{t_0}^t \Phi_s^{-1} c(s) dW_s \right), \quad (1.3)$$

donde Φ_t es un proceso estocástico auxiliar que satisface la ecuación homogénea asociada:

$$d\Phi_t = \alpha\Phi_t dt + \sigma\Phi_t dW_t, \quad \Phi_{t_0} = 1. \quad (1.4)$$

Por lo tanto, queremos encontrar un proceso Φ_t que actúe como un factor integrante estocástico, y sabemos que Φ_t debe capturar tanto la dinámica determinista como la estocástica de la EDE. Entonces, buscamos un Φ_t que cumpla:

$$d\Phi_t = \alpha\Phi_t dt + \sigma\Phi_t dW_t.$$

Dividiendo ambos lados entre Φ_t , obtenemos:

$$\frac{d\Phi_t}{\Phi_t} = \alpha dt + \sigma dW_t.$$

Definimos el proceso Y_t como:

$$Y_t = \ln(\Phi_t).$$

Ahora recordemos la fórmula de Itô para procesos univariados [44]:

$$df(t, X_t) = f_t(t, X_t)dt + f_x(t, X_t)dX_t + \frac{1}{2}f_{xx}(t, X_t)(dX_t)^2,$$

donde $(dX_t)^2$ se calcula con las reglas de multiplicación estocástica:

$$dt^2 = dt dW_t = dW_t dt = 0, \quad dW_t^2 = dt.$$

Aplicando la fórmula de Itô a Y_t :

$$dY_t = \frac{1}{\Phi_t} d\Phi_t - \frac{1}{2} \frac{1}{\Phi_t^2} (d\Phi_t)^2.$$

De donde el término cuadrático es:

$$\begin{aligned} (d\Phi_t)^2 &= (\alpha\Phi_t dt + \sigma\Phi_t dW_t)^2 \\ &= \sigma^2 \Phi_t^2 dt. \end{aligned}$$

Sustituimos en dY_t :

$$\begin{aligned} dY_t &= \frac{1}{\Phi_t}(\alpha\Phi_t dt + \sigma\Phi_t dW_t) - \frac{1}{2} \frac{1}{\Phi_t^2}(\sigma^2\Phi_t^2 dt) \\ &= \alpha dt + \sigma dW_t - \frac{1}{2}\sigma^2 dt \\ &= (\alpha - \frac{1}{2}\sigma^2)dt + \sigma dW_t. \end{aligned}$$

Integramos ambos lados desde t_0 hasta t :

$$Y_t - Y_{t_0} = \int_{t_0}^t (\alpha - \frac{1}{2}\sigma^2)ds + \int_{t_0}^t \sigma dW_s.$$

Como $Y_t = \ln(\Phi_t)$ y $\Phi_{t_0} = 1$ (de donde $Y_{t_0} = \ln(1) = 0$), entonces:

$$\ln(\Phi_t) = (\alpha - \frac{1}{2}\sigma^2)(t - t_0) + \sigma(W_t - W_{t_0}).$$

Entonces:

$$\Phi_t = \exp\left((\alpha - \frac{1}{2}\sigma^2)(t - t_0) + \sigma(W_t - W_{t_0})\right).$$

Y por lo tanto:

$$\Phi_t^{-1} = \exp\left(-(\alpha - \frac{1}{2}\sigma^2)(t - t_0) - \sigma(W_t - W_{t_0})\right).$$

Sustituyendo en (1.3):

$$\begin{aligned} X_t &= e^{(\alpha - \frac{1}{2}\sigma^2)(t - t_0) + \sigma(W_t - W_{t_0})} \left(x_{t_0} + (\beta - \sigma \cdot 0) \int_{t_0}^t e^{-(\alpha - \frac{1}{2}\sigma^2)(s - t_0) - \sigma(W_s - W_{t_0})} ds \right. \\ &\quad \left. + 0 \cdot \int_{t_0}^t \Phi_s^{-1} dW_s \right) \\ &= e^{(\alpha - \frac{1}{2}\sigma^2)(t - t_0) + \sigma(W_t - W_{t_0})} \left(x_{t_0} + \beta \int_{t_0}^t e^{-(\alpha - \frac{1}{2}\sigma^2)(s - t_0) - \sigma(W_s - W_{t_0})} ds \right). \end{aligned}$$

Por lo tanto, en nuestro caso, aplicando el resultado anterior, la ecuación diferencial estocástica (1.1) tiene una única solución X_t , esta solución tiene la siguiente expresión explícita:

$$X_t = e^{(\alpha - \frac{1}{2}\sigma^2)(t - t_0) + \sigma(W_t - W_{t_0})} \left(x_{t_0} + \beta \int_{t_0}^t e^{-(\alpha - \frac{1}{2}\sigma^2)(s - t_0) - \sigma(W_s - W_{t_0})} ds \right). \quad (1.5)$$

La expresión anterior muestra que el proceso X_t puede interpretarse como una transformación exponencial de un movimiento browniano con deriva, modulada por un término integral que captura el efecto de la reversión a la media. Esta forma cerrada permite estudiar propiedades como la no negatividad, los momentos y la distribución estacionaria, así como construir esquemas de simulación eficientes.

A pesar de contar con una solución explícita, la dependencia multiplicativa del término de difusión en (1.1) complica la construcción directa de la función de verosimilitud a partir de datos discretos. Para abordar este problema, se introduce a continuación la transformación de Lamperti.

1.3.2. Transformación de Lamperti

Recordemos que para el modelo de Brennan-Schwartz definido en (1.1) el término de difusión es $\sigma(x) = \sigma x$. Para estabilizar la varianza y obtener un proceso con difusión unitaria, aplicamos la transformación de Lamperti [53]. Definimos la función de cambio de variable $h(x)$ como:

$$h(x) = \int \frac{1}{\sigma u} du = \frac{1}{\sigma} \ln(x).$$

Definimos el proceso transformado como $Y_t = h(X_t) = \frac{\ln(X_t)}{\sigma}$. De esta relación, podemos expresar la inversa como:

$$X_t = \exp(\sigma Y_t).$$

Para encontrar la dinámica de Y_t , aplicamos la fórmula de Itô [44]. Primero calculamos las derivadas de la función de transformación $h(x)$:

$$h'(x) = \frac{d}{dx} \left(\frac{\ln x}{\sigma} \right) = \frac{1}{\sigma x}, \quad h''(x) = \frac{d}{dx} \left(\frac{1}{\sigma x} \right) = -\frac{1}{\sigma x^2}.$$

La fórmula de Itô para una función $h(X_t)$ establece que:

$$dY_t = h'(X_t) dX_t + \frac{1}{2} h''(X_t) (dX_t)^2.$$

Sustituimos dX_t por la EDE original y utilizamos la regla $(dX_t)^2 = \sigma^2(X_t)^2 dt$ (los términos dt^2 y $dt \cdot dW_t$ se desprecian):

$$dY_t = \underbrace{\frac{1}{\sigma X_t} [(\alpha X_t + \beta)dt + \sigma X_t dW_t]}_{\text{Término de primer orden}} + \underbrace{\frac{1}{2} \left(-\frac{1}{\sigma X_t^2} \right) (\sigma^2 X_t^2 dt)}_{\text{Corrección de Itô}}.$$

Desarrollamos los términos algebraicamente:

1. Parte del Drift (Primer orden):

$$\frac{1}{\sigma X_t} (\alpha X_t + \beta) = \frac{\alpha X_t}{\sigma X_t} + \frac{\beta}{\sigma X_t} = \frac{\alpha}{\sigma} + \frac{\beta}{\sigma X_t}.$$

2. Parte de Difusión:

$$\frac{1}{\sigma X_t} (\sigma X_t dW_t) = dW_t.$$

3. Parte de la corrección de Itô (Segundo orden):

$$-\frac{1}{2\sigma X_t^2} (\sigma^2 X_t^2) = -\frac{\sigma^2}{2\sigma} = -\frac{\sigma}{2}.$$

Reagrupando todos los términos con dt (el drift) y dW_t (la difusión):

$$dY_t = \left(\frac{\alpha}{\sigma} + \frac{\beta}{\sigma X_t} - \frac{\sigma}{2} \right) dt + dW_t.$$

Finalmente, expresamos todo en términos de la nueva variable Y_t . Recordando que $X_t = e^{\sigma Y_t}$, entonces $\frac{1}{X_t} = e^{-\sigma Y_t}$. Sustituyendo esto en la ecuación anterior, obtenemos la EDE para el proceso transformado:

$$dY_t = \underbrace{\left[\left(\frac{\alpha}{\sigma} - \frac{\sigma}{2} \right) + \frac{\beta}{\sigma} e^{-\sigma Y_t} \right]}_{\mu_{\alpha,\beta}(Y_t)} dt + dW_t.$$

Así, el drift en la escala de Lamperti queda definido como:

$$\mu_{\alpha,\beta}(y) = \frac{\alpha}{\sigma} - \frac{\sigma}{2} + \frac{\beta}{\sigma} e^{-\sigma y}.$$

Asimismo, para facilitar la inferencia bayesiana, construimos una función potencial asociada al drift. Definimos el potencial $H_{\alpha,\beta}(y)$ siguiendo la estructura usual en difusiones (integral del drift menos corrección logarítmica de la difusión original, necesaria por el cambio de medida):

$$H_{\alpha,\beta}(y) = \int \mu_{\alpha,\beta}(y) dy - \ln(\sigma(x(y))).$$

Calculamos primero la integral del drift $\mu_{\alpha,\beta}(y)$ respecto a y :

$$\int \left[\left(\frac{\alpha}{\sigma} - \frac{\sigma}{2} \right) + \frac{\beta}{\sigma} e^{-\sigma y} \right] dy = \left(\frac{\alpha}{\sigma} - \frac{\sigma}{2} \right) y - \frac{\beta}{\sigma^2} e^{-\sigma y}.$$

Para expresar este potencial en términos de la variable original x , deshacemos el cambio de variable usando $y = \frac{\ln x}{\sigma}$ y $e^{-\sigma y} = \frac{1}{x}$:

$$\text{Integral} = \left(\frac{\alpha}{\sigma} - \frac{\sigma}{2} \right) \frac{\ln x}{\sigma} - \frac{\beta}{\sigma^2 x} = \frac{\alpha}{\sigma^2} \ln x - \frac{1}{2} \ln x - \frac{\beta}{\sigma^2 x}.$$

Incorporando el término logarítmico del jacobiano/difusión (donde $\ln(\sigma x) = \ln \sigma + \ln x$) y agrupando las constantes y logaritmos adecuadamente según la convención elegida para la verosimilitud [48, 4], llegamos a la forma final del potencial:

$$H_{\alpha,\beta}(x) = \frac{\alpha}{\sigma^2} \ln(x) - \frac{\beta}{\sigma^2 x} - \ln(\sigma x).$$

Esta H encapsula la información del drift y la geometría del espacio transformado, lo que resulta especialmente conveniente en el contexto bayesiano, ya que permite expresar la verosimilitud aumentada del proceso en una forma exponencial manejable, facilitando la implementación de algoritmos MCMC, como los que se desarrollan en el Capítulo 3.

1.4. Análisis de Momentos y Distribución Estacionaria

En esta sección se analiza el comportamiento del proceso de Brennan–Schwartz tanto en horizonte finito como en el largo plazo. Primero se estudia la evolución de la esperanza condicional y su convergencia, lo que permite identificar el nivel de reversión a la media del modelo. Posteriormente, se analizan los momentos del proceso, distinguiendo entre momentos transitorios y estacionarios. Finalmente, se caracteriza la distribución estacionaria del proceso y se establecen las condiciones bajo las cuales el modelo es ergódico [43].

1.4.1. Función de tendencia

La EDE en la ecuación (1.1) se puede escribir en forma integral como:

$$X_t = X_s + \int_s^t (\alpha X_u + \beta) du + \sigma \int_s^t X_u dW_u.$$

de donde obtenemos la esperanza condicional utilizando las propiedades de la integral de Itô [44]:

$$\mathbb{E}[X_t | X_s = x_s] = x_s + \beta(t - s) + \alpha \int_s^t \mathbb{E}[X_u | X_s = x_s] du.$$

Denotando esto por $g(t) = \mathbb{E}[X_t | X_s = x_s]$, tenemos:

$$g(t) = x_s + \beta(t - s) + \alpha \int_s^t g(u) du,$$

y derivando con respecto a t :

$$g'(t) = \alpha g(t) + \beta, \quad g(s) = x_s.$$

Vamos a resolver la Ecuación Diferencial Ordinaria (ODE) anterior. La parte homogénea de la ODE es:

$$g'(t) = \alpha g(t).$$

Y la solución general de esta ecuación es:

$$g_{hom}(t) = C e^{\alpha t}.$$

Buscamos una solución particular para la parte no homogénea $g'(t) = \alpha g(t) + \beta$. Suponemos una solución constante $g_{part}(t) = A$. Sustituyendo en la ODE:

$$0 = \alpha A + \beta \Rightarrow A = -\frac{\beta}{\alpha}.$$

Así pues, la solución general de la ODE es la suma de la solución homogénea y la particular:

$$g(t) = C e^{\alpha t} - \frac{\beta}{\alpha}.$$

Usando que $g(s) = x_s$, encontraremos C :

$$x_s = C e^{\alpha s} - \frac{\beta}{\alpha} \Rightarrow C = \left(x_s + \frac{\beta}{\alpha} \right) e^{-\alpha s}.$$

Sustituimos C en la solución general:

$$g(t) = \left(x_s + \frac{\beta}{\alpha} \right) e^{-\alpha s} e^{\alpha t} - \frac{\beta}{\alpha}.$$

Simplificamos:

$$\begin{aligned} g(t) &= \left(x_s + \frac{\beta}{\alpha} \right) e^{-\alpha s} e^{\alpha t} - \frac{\beta}{\alpha} \\ &= \left(x_s + \frac{\beta}{\alpha} \right) e^{\alpha(t-s)} - \frac{\beta}{\alpha} \\ &= x_s e^{\alpha(t-s)} + \frac{\beta}{\alpha} (e^{\alpha(t-s)} - 1). \end{aligned}$$

por lo que concluimos que la solución única de nuestra ODE está dada por:

$$g(t) = x_s e^{\alpha(t-s)} + \frac{\beta}{\alpha} (e^{\alpha(t-s)} - 1).$$

Finalmente, la función de tendencia condicional del modelo es:

$$\mathbb{E}[X_t | X_s = x_s] = x_s e^{\alpha(t-s)} + \frac{\beta}{\alpha} (e^{\alpha(t-s)} - 1),$$

y asumiendo la condición inicial $P(x_{t_0}) = 1$, la función de tendencia del proceso es:

$$\mathbb{E}[X_t] = x_{t_0} e^{\alpha(t-t_0)} + \frac{\beta}{\alpha} (e^{\alpha(t-t_0)} - 1).$$

Notemos que, cuando $t \rightarrow \infty$, y $\alpha < 0$, $e^{\alpha(t-t_0)} \rightarrow 0$, por lo tanto el valor esperado converge a un valor finito. Específicamente, tiende al valor estacionario:

$$\lim_{t \rightarrow \infty} \mathbb{E}[X_t] = -\frac{\beta}{\alpha}.$$

Una vez caracterizada la evolución temporal del valor esperado del proceso, resulta natural extender el análisis al estudio de sus momentos. En particular, el comportamiento de los momentos permite entender la dispersión del proceso y su estabilidad en el tiempo.

1.4.2. Momentos transitorios

Vamos a obtener tanto los momentos transitorios, o de tiempo finito. Recordemos que la solución es:

$$X_t = e^{(\alpha - \frac{1}{2}\sigma^2)(t-t_0) + \sigma(W_t - W_{t_0})} \left(x_{t_0} + \beta \int_{t_0}^t e^{-(\alpha - \frac{1}{2}\sigma^2)(s-t_0) - \sigma(W_s - W_{t_0})} ds \right).$$

Para facilidades en los cálculos, simplificaremos la notación, por lo que veamos que podemos escribir la solución general como:

$$X_t = e^{Z(t)} \left(x_{t_0} + \beta \int_{t_0}^t e^{-Z(s)} ds \right),$$

donde:

$$Z(t) = \left(\alpha - \frac{\sigma^2}{2} \right) (t - t_0) + \sigma(W_t - W_{t_0}).$$

Entonces, tenemos:

$$\mathbb{E}[X_t] = \mathbb{E} \left[e^{Z(t)} \left(x_{t_0} + \beta \int_{t_0}^t e^{-Z(s)} ds \right) \right].$$

Descomponemos:

$$\mathbb{E}[X_t] = \underbrace{\mathbb{E} [e^{Z(t)} x_{t_0}]}_{\text{Término 1}} + \beta \underbrace{\mathbb{E} \left[e^{Z(t)} \int_{t_0}^t e^{-Z(s)} ds \right]}_{\text{Término 2}}.$$

Término 1: $\mathbb{E} [e^{Z(t)} x_{t_0}]$

Como $Z(t)$ es gaussiano [44]:

$$\begin{aligned}\mathbb{E}[e^{Z(t)}] &= \exp \left(\mathbb{E}[Z(t)] + \frac{1}{2} \text{Var}(Z(t)) \right) \\ &= \exp \left(\left(\alpha - \frac{\sigma^2}{2} \right) (t - t_0) + \frac{\sigma^2}{2} (t - t_0) \right) \\ &= e^{\alpha(t-t_0)}.\end{aligned}$$

Por tanto:

$$\mathbb{E} [e^{Z(t)} x_{t_0}] = x_{t_0} e^{\alpha(t-t_0)}.$$

Término 2: $\mathbb{E} \left[e^{Z(t)} \int_{t_0}^t e^{-Z(s)} ds \right]$

Intercambiando esperanza e integral:

$$\mathbb{E} \left[\int_{t_0}^t e^{Z(t)-Z(s)} ds \right] = \int_{t_0}^t \mathbb{E} [e^{Z(t)-Z(s)}] ds.$$

Calculamos:

$$\begin{aligned}\mathbb{E}[e^{Z(t)-Z(s)}] &= \exp \left(\left(\alpha - \frac{\sigma^2}{2} \right) (t - s) + \frac{\sigma^2}{2} (t - s) \right) \\ &= e^{\alpha(t-s)}.\end{aligned}$$

Integrando:

$$\int_{t_0}^t e^{\alpha(t-s)} ds = \frac{1}{\alpha} (e^{\alpha(t-t_0)} - 1).$$

Por lo tanto, tenemos que el primer momento es:

$$\mathbb{E}[X_t] = x_{t_0} e^{\alpha(t-t_0)} + \frac{\beta}{\alpha} (e^{\alpha(t-t_0)} - 1). \quad (1.6)$$

El cálculo explícito del segundo momento transitorio del proceso requiere la evaluación de esperanzas que involucran exponentes cuadráticos del movimiento browniano y términos integrales correlacionados en el tiempo, lo que conduce a expresiones algebraicamente extensas y de limitada interpretación económica. Dado que este desarrollo no aporta nueva intuición sobre la dinámica del modelo, pero resulta relevante para completar el análisis teórico, se ha optado por presentar el detalle completo de los cálculos en el Apéndice A. La expresión cerrada del segundo momento, obtenida a partir de dicho desarrollo, se presenta a continuación para referencia:

$$\begin{aligned}\mathbb{E}[X_t^2] &= x_{t_0}^2 e^{(2\alpha+\sigma^2)(t-t_0)} + 2\beta x_{t_0} \int_{t_0}^t e^{\left(\alpha-\frac{\sigma^2}{2}\right)(2t-s-t_0)+\frac{\sigma^2}{2}(4t-3s)} ds \\ &\quad + 2\beta^2 \int_{t_0}^t \int_{t_0}^s e^{\left(\alpha-\frac{\sigma^2}{2}\right)(2t-s-u-t_0)+\frac{\sigma^2}{2}(4t-3s-u)} du ds.\end{aligned}$$

El análisis de los momentos transitorios sugiere la existencia de un comportamiento estable a largo plazo. Para formalizar esta intuición, a continuación se estudia la distribución estacionaria del proceso y las condiciones bajo las cuales dicha distribución existe.

1.4.3. Distribución estacionaria

Determinaremos la distribución estacionaria del proceso (1.1). Sabemos que si un proceso de difusión $\{X_t\}_{t \geq t_0}$ tiene distribución estacionaria, ésta está dada por la teoría general de difusiones [34, 43]

$$\pi(x) = \frac{m(x)}{M},$$

donde

$$m(x) = \frac{1}{\sigma^2(x)s(x)},$$

es la medida de velocidad,

$$s(x) = \exp \left[-2 \int_{x_0}^x \frac{b(y)}{\sigma^2(y)} dy \right],$$

es la medida de escala y M la constante de normalización.

Sustituyendo $b(y) = \alpha y + \beta$ y $\sigma(y) = \sigma y$ en la medida de escala:

$$\begin{aligned} s(x) &= \exp \left[-2 \int_{x_0}^x \frac{\alpha y + \beta}{\sigma^2 y^2} dy \right] \\ &= \exp \left[-2 \int_{x_0}^x \left(\frac{\alpha y}{\sigma^2 y^2} + \frac{\beta}{\sigma^2 y^2} \right) dy \right] \\ &= \exp \left[-2 \left(\frac{\alpha}{\sigma^2} \ln \left(\frac{x}{x_0} \right) - \frac{\beta}{\sigma^2} \left(\frac{1}{x} - \frac{1}{x_0} \right) \right) \right] \\ &= \exp \left[-\frac{2\alpha}{\sigma^2} \ln \left(\frac{x}{x_0} \right) + \frac{2\beta}{\sigma^2} \left(\frac{1}{x} - \frac{1}{x_0} \right) \right] \\ &= \left(\frac{x}{x_0} \right)^{-\frac{2\alpha}{\sigma^2}} \exp \left[\frac{2\beta}{\sigma^2} \left(\frac{1}{x} - \frac{1}{x_0} \right) \right]. \end{aligned}$$

Definiendo $k = x_0^{-\frac{2\alpha}{\sigma^2}}$, se obtiene:

$$s(x) = kx^{-\frac{2\alpha}{\sigma^2}} \exp \left[\frac{2\beta}{\sigma^2 x} \right]. \quad (1.7)$$

Ahora, para la medida de velocidad, sustituimos:

$$\begin{aligned} m(x) &= \frac{1}{\sigma^2(x)s(x)} \\ &= \frac{1}{\sigma^2 x^2 kx^{-\frac{2\alpha}{\sigma^2}} \exp \left[\frac{2\beta}{\sigma^2 x} \right]} \\ &= \frac{1}{k\sigma^2} x^{\frac{2\alpha}{\sigma^2}-2} \exp \left(-\frac{2\beta}{\sigma^2 x} \right). \end{aligned}$$

Para que el proceso sea ergódico y tenga una distribución estacionaria, se deben cumplir dos condiciones fundamentales [34]:

1. $S(l, y] = S[x, r] = \infty$ (la integral de la función de densidad de escala diverge en los extremos del intervalo).
2. $\int_l^r m(u) du < \infty$ (La integral de la función de densidad de velocidad es finita).

Definimos:

$$S[x, y] = \int_x^y s(u) du, \quad S(l, y] = \lim_{x \rightarrow l} \int_x^y s(u) du, \quad S[x, r) = \lim_{y \rightarrow r} \int_x^y s(u) du.$$

Si se cumple que:

$$S(l, y] = S[x, r) = \infty \quad \text{y} \quad \int_l^r m(u) du < \infty,$$

entonces el proceso $\{X_t, t \geq 0\}$ es ergódico, y su función de densidad estacionaria es:

$$f(x) = \frac{m(x)}{\int_l^r m(u) du}.$$

Para $0 < x < y < \infty$:

$$S[x, y] = k \int_x^y u^{-\frac{2\alpha}{\sigma^2}} e^{\frac{2\beta}{\sigma^2} \frac{1}{u}} du.$$

Para llevar esta integral a una forma compatible con la función Gamma incompleta (o distribución Gamma inversa), aplicamos el cambio de variable $v = u^{-1}$. Sea la nueva variable:

$$v = \frac{1}{u} \implies u = v^{-1}.$$

Calculamos el diferencial du derivando respecto a v :

$$du = \frac{d}{dv}(v^{-1}) dv = -v^{-2} dv = -\frac{1}{v^2} dv.$$

Los límites originales están en términos de u . Debemos pasarlos a términos de v :

- Límite inferior: Si $u = x$, entonces $v = 1/x$.
- Límite superior: Si $u = y$, entonces $v = 1/y$.

Como se asume que $0 < x < y$, se cumple que $\frac{1}{y} < \frac{1}{x}$. Esto significa que el nuevo límite superior ($1/x$) es mayor que el inferior ($1/y$). Sustituimos u , du y los límites en la integral original:

$$S[x, y] = k \int_{1/y}^{1/x} \underbrace{(v^{-1})^{-\frac{2\alpha}{\sigma^2}}}_{\text{Término } u} \cdot \underbrace{\exp\left(\frac{2\beta}{\sigma^2(v^{-1})}\right)}_{\text{Exponencial}} \cdot \underbrace{(-v^{-2} dv)}_{\text{Diferencial } du}.$$

Procedemos a operar los términos, empezamos con el término u :

$$(v^{-1})^{-\frac{2\alpha}{\sigma^2}} = v^{\frac{2\alpha}{\sigma^2}}.$$

Multiplicamos este término por el v^{-2} que proviene del diferencial:

$$v^{\frac{2\alpha}{\sigma^2}} \cdot v^{-2} = v^{\frac{2\alpha}{\sigma^2} - 2}.$$

Exponencial:

$$\frac{1}{u} = v \implies \exp\left(\frac{2\beta}{\sigma^2 u}\right) = \exp\left(\frac{2\beta}{\sigma^2} v\right).$$

El diferencial aportó un signo menos ($-dv$). Usamos la propiedad de las integrales $\int_a^b -f(v)dv = \int_b^a f(v)dv$ para invertir los límites de integración y absorber el signo negativo.

$$-\int_{1/x}^{1/y} (\dots) dv = \int_{1/y}^{1/x} (\dots) dv.$$

Reuniendo todo, obtenemos:

$$S[x, y] = k \int_{1/y}^{1/x} v^{\frac{2\alpha}{\sigma^2}-2} e^{\frac{2\beta}{\sigma^2}v} dv.$$

Observamos que la expresión objetivo tiene un signo negativo en la exponencial ($e^{-\dots}$) y un factor 2 en la constante.

Para que esta integral converja (y corresponda a una densidad Gamma), el coeficiente de v en la exponencial debe ser negativo. Esto implica que en el modelo de Brennan-Schwartz original, el parámetro β se asume negativo ($\beta < 0$) para asegurar reversión a la media, o bien se ha realizado una redefinición de parámetros para trabajar con valores positivos. Algebraicamente, si $\beta < 0$, entonces $\frac{2\beta}{\sigma^2}$ es negativo, lo cual coincide con la forma $-\frac{2|\beta|}{\sigma^2}$.

Dado que la función de escala está definida salvo una constante multiplicativa, es posible reabsorber factores numéricos en la constante de normalización sin pérdida de generalidad. Al pasar a la forma canónica, es común redefinir la constante de normalización. Denotamos la nueva constante como $K' = 2k$ (o simplemente renombramos k) para ajustar la expresión a conveniencia. Finalmente, la expresión reordenada es:

$$S[x, y] = 2k \int_{1/y}^{1/x} v^{\frac{2\alpha}{\sigma^2}-2} e^{-\frac{2\beta}{\sigma^2}v} dv. \quad (1.8)$$

Este cambio resulta natural debido a la presencia del término $\frac{1}{u}$ en el exponente, y permite identificar condiciones de divergencia en los extremos del dominio. Entonces, tomando el límite cuando x tiende a cero en la ecuación (1.8), concluimos que, para $\beta > 0$, se cumple que $S(0, y) = \infty$. Tomando el límite cuando y tiende a ∞ en la ecuación (1.8), se tiene que, para $\alpha \leq \frac{\sigma^2}{2}$, se cumple que $S[x, \infty) = \infty$. En consecuencia, para $\alpha \leq \frac{\sigma^2}{2}$ y $\beta > 0$, se obtiene:

$$S[x, \infty) = S(0, y) = \infty.$$

La densidad de velocidad está dada por:

$$m(x) = \frac{1}{k\sigma^2} x^{\frac{2\alpha}{\sigma^2}-2} e^{-\frac{2\beta}{\sigma^2}x},$$

por lo que obtenemos:

$$\begin{aligned} \int_0^\infty m(x)dx &= \frac{1}{k\sigma^2} \int_0^\infty x^{\frac{2\alpha}{\sigma^2}-2} e^{-\frac{2\beta}{\sigma^2}x} dx \\ &= \frac{1}{k\sigma^2} \int_0^\infty v^{\frac{2\alpha}{\sigma^2}-2} e^{-\frac{2\beta}{\sigma^2}v} dv. \end{aligned}$$

Aplicando el cambio de variable $u = x^{-1}$ y usando el resultado de Gradshteyn y Ryzhik [26] para $\nu > 0$ y $\mu > 0$;, la integral se transforma en una forma estándar de la función Gamma.

$$\int_0^\infty x^{\nu-1} e^{-\mu x} dx = \mu^{-\nu} \Gamma(\nu),$$

para $\alpha < \frac{\sigma^2}{2}$ y $\beta > 0$, tenemos:

$$\int_0^\infty m(x)dx = \frac{1}{k\sigma^2} \left(\frac{2\beta}{\sigma^2} \right)^{\frac{2\alpha}{\sigma^2}-1} \Gamma \left(1 - \frac{2\alpha}{\sigma^2} \right) < \infty.$$

Así, combinando las dos condiciones anteriores, concluimos que para $\alpha < \frac{\sigma^2}{2}$ y $\beta > 0$, el proceso es ergódico y tiene una distribución estacionaria. La distribución estacionaria se obtiene normalizando la función de densidad de velocidad:

$$f(x) = \frac{m(x)}{\int_0^\infty m(u)du}.$$

Sustituyendo $m(x)$:

$$f(x) = \frac{\frac{1}{k\sigma^2} x^{\frac{2\alpha}{\sigma^2}-2} e^{-\frac{2\beta}{\sigma^2 x}}}{\int_0^\infty \frac{1}{k\sigma^2} u^{\frac{2\alpha}{\sigma^2}-2} e^{-\frac{2\beta}{\sigma^2 u}} du}.$$

Simplificando:

$$f(x) = \frac{x^{\frac{2\alpha}{\sigma^2}-2} e^{-\frac{2\beta}{\sigma^2 x}}}{\int_0^\infty u^{\frac{2\alpha}{\sigma^2}-2} e^{-\frac{2\beta}{\sigma^2 u}} du}.$$

Notemos que la integral en el denominador es la función Gamma $\mu^{-\nu}\Gamma(\nu) = \int_0^\infty u^{\nu-1}e^{-\mu u}$ con $\nu = 1 - \frac{2\alpha}{\sigma^2}$ y $\mu = \frac{2\beta}{\sigma^2}$, por lo que:

$$\int_0^\infty u^{\frac{2\alpha}{\sigma^2}-2} e^{-\frac{2\beta}{\sigma^2 u}} du = \left(\frac{2\beta}{\sigma^2} \right)^{1-\frac{2\alpha}{\sigma^2}} \Gamma \left(1 - \frac{2\alpha}{\sigma^2} \right).$$

Sustituyendo en $f(x)$:

$$f(x) = \frac{x^{\frac{2\alpha}{\sigma^2}-2} e^{-\frac{2\beta}{\sigma^2 x}}}{\left(\frac{2\beta}{\sigma^2} \right)^{1-\frac{2\alpha}{\sigma^2}} \Gamma \left(1 - \frac{2\alpha}{\sigma^2} \right)}.$$

Lo que es equivalente a:

$$f(x) = \frac{\left(\frac{2\beta}{\sigma^2} \right)^{1-\frac{2\alpha}{\sigma^2}} x^{\frac{2\alpha}{\sigma^2}-2} e^{-\frac{2\beta}{\sigma^2 x}}}{\Gamma \left(1 - \frac{2\alpha}{\sigma^2} \right)}. \quad (1.9)$$

Que no es más que la función de densidad de la distribución estacionaria del modelo propuesto [43], donde $\Gamma(\cdot)$ es la función Gamma. Además, la función $f(x)$ es la densidad de la inversa de la distribución Gamma con parámetros $1 - \frac{2\alpha}{\sigma^2}$ y $\frac{\sigma^2}{2\beta}$.

1.4.4. Momentos estacionarios

Ahora, para calcular los momentos estacionarios, tenemos que el momento de orden k se define como:

$$\mathbb{E}[X^k] = \int_0^\infty x^k f(x) dx.$$

Sustituyendo (1.9) en la integral:

$$\mathbb{E}[X^k] = \int_0^\infty x^k \cdot \frac{\left(\frac{2\beta}{\sigma^2} \right)^{1-\frac{2\alpha}{\sigma^2}} x^{\frac{2\alpha}{\sigma^2}-2} e^{-\frac{2\beta}{\sigma^2 x}}}{\Gamma \left(1 - \frac{2\alpha}{\sigma^2} \right)} dx.$$

Simplificando:

$$\mathbb{E}[X^k] = \frac{\left(\frac{2\beta}{\sigma^2}\right)^{1-\frac{2\alpha}{\sigma^2}}}{\Gamma(1-\frac{2\alpha}{\sigma^2})} \int_0^\infty x^{\frac{2\alpha}{\sigma^2}-2+k} e^{-\frac{2\beta}{\sigma^2 x}} dx.$$

Ahora aplicaremos un cambio de variable. Sea $t = \frac{2\beta}{\sigma^2 x}$, por lo que $x = \frac{2\beta}{\sigma^2 t}$. El diferencial dx es:

$$dx = -\frac{2\beta}{\sigma^2 t^2} dt.$$

Obsérvese que este cambio de variable invierte el sentido del dominio de integración, ya que cuando $x \rightarrow 0^+$ se tiene $t \rightarrow \infty$, y cuando $x \rightarrow \infty$, $t \rightarrow 0^+$. El signo negativo del diferencial se cancela al invertir los límites de integración, por lo que la integral resultante se evalúa nuevamente sobre $(0, \infty)$:

$$\int_0^\infty f(x) dx = \int_\infty^0 f(g(t))(-g'(t)) dt = \int_0^\infty f(g(t))g'(t) dt.$$

Sustituimos en la integral:

$$\begin{aligned} \int_0^\infty x^{\frac{2\alpha}{\sigma^2}-2+k} e^{-\frac{2\beta}{\sigma^2 x}} dx &= \int_0^\infty \left(\frac{2\beta}{\sigma^2 t}\right)^{\frac{2\alpha}{\sigma^2}-2+k} e^{-t} \left(-\frac{2\beta}{\sigma^2 t^2}\right) dt \\ &= \int_0^\infty \left(\frac{2\beta}{\sigma^2}\right)^{\frac{2\alpha}{\sigma^2}-2+k} t^{-(k+\frac{2\alpha}{\sigma^2}-2)} e^{-t} \left(-\frac{2\beta}{\sigma^2 t^2}\right) dt \\ &= \left(\frac{2\beta}{\sigma^2}\right)^{\frac{2\alpha}{\sigma^2}-2+k} \int_0^\infty t^{-(k+\frac{2\alpha}{\sigma^2}-2)-2} e^{-t} dt. \end{aligned}$$

La integral es ahora una forma de la función gamma:

$$\Gamma(\nu) = \int_0^\infty t^{\nu-1} e^{-t} dt.$$

Comparando, identificamos $\nu = 1 - (k + \frac{2\alpha}{\sigma^2} - 1) = 1 - k - \frac{2\alpha}{\sigma^2}$, por lo que la integral se puede escribir como:

$$\int_0^\infty t^{-(k+\frac{2\alpha}{\sigma^2}-2)-2} e^{-t} dt = \Gamma\left(1 - \frac{2\alpha}{\sigma^2} - k\right).$$

Sustituyendo la integral Gamma:

$$\mathbb{E}[X^k] = \frac{\left(\frac{2\beta}{\sigma^2}\right)^{1-\frac{2\alpha}{\sigma^2}}}{\Gamma(1-\frac{2\alpha}{\sigma^2})} \left(\frac{2\beta}{\sigma^2}\right)^{\frac{2\alpha}{\sigma^2}-2+k} \Gamma\left(1 - \frac{2\alpha}{\sigma^2} - k\right).$$

Reagrupando términos:

$$\mathbb{E}[X^k] = \frac{\left(\frac{2\beta}{\sigma^2}\right)^k \Gamma\left(1 - \frac{2\alpha}{\sigma^2} - k\right)}{\Gamma(1 - \frac{2\alpha}{\sigma^2})}.$$

Esta es la expresión final del momento de orden k de la distribución estacionaria.

Por otro lado, para que el momento $\mathbb{E}[X^k]$ exista, el argumento de la función Gamma en el numerador debe ser positivo:

$$1 - \frac{2\alpha}{\sigma^2} - k > 0 \Rightarrow k < 1 - \frac{2\alpha}{\sigma^2}. \quad (1.10)$$

Esto impone una restricción sobre el orden k del momento que se puede calcular. Por lo tanto, calculemos:

1. Momento de orden 1 (valor esperado):

$$\begin{aligned}\mathbb{E}[X] &= \frac{\left(\frac{2\beta}{\sigma^2}\right)^1 \Gamma\left(1 - \frac{2\alpha}{\sigma^2} - 1\right)}{\Gamma\left(1 - \frac{2\alpha}{\sigma^2}\right)} \\ &= \left(\frac{2\beta}{\sigma^2}\right) \cdot \frac{\Gamma\left(-\frac{2\alpha}{\sigma^2}\right)}{\Gamma\left(1 - \frac{2\alpha}{\sigma^2}\right)}.\end{aligned}$$

Usando la propiedad de la función Gamma $\Gamma(z+1) = z\Gamma(z)$, se obtiene:

$$\mathbb{E}[X] = \left(\frac{2\beta}{\sigma^2}\right) \cdot \frac{\Gamma\left(-\frac{2\alpha}{\sigma^2}\right)}{-\frac{2\alpha}{\sigma^2} \cdot \Gamma\left(-\frac{2\alpha}{\sigma^2}\right)} = \left(\frac{2\beta}{\sigma^2}\right) \cdot \frac{1}{-\frac{2\alpha}{\sigma^2}} = \left(\frac{2\beta}{\sigma^2}\right) \cdot \left(-\frac{\sigma^2}{2\alpha}\right) = -\frac{\beta}{\alpha}.$$

De donde podemos ver que:

- El valor esperado $\mathbb{E}[X] = -\frac{\beta}{\alpha}$ es el límite asintótico de la media del proceso X_t cuando $t \rightarrow \infty$.
- Este resultado nos dice que, a largo plazo, el proceso tiende a estabilizarse alrededor de $-\frac{\beta}{\alpha}$.
- α debe ser negativo para que $\mathbb{E}[X]$ sea positivo (ya que $\beta > 0$ y $\sigma^2 > 0$).

2. Momento de orden 2 (varianza):

$$\mathbb{E}[X^2] = \frac{\left(\frac{2\beta}{\sigma^2}\right)^2 \Gamma\left(1 - \frac{2\alpha}{\sigma^2} - 2\right)}{\Gamma\left(1 - \frac{2\alpha}{\sigma^2}\right)} = \frac{\left(\frac{2\beta}{\sigma^2}\right)^2 \Gamma\left(-1 - \frac{2\alpha}{\sigma^2}\right)}{\Gamma\left(1 - \frac{2\alpha}{\sigma^2}\right)}.$$

Y la varianza es:

$$\text{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2.$$

El desarrollo presentado en esta sección sigue de cerca el enfoque introducido en [43], adaptándolo al marco bayesiano considerado en esta tesis y explicitando algunos pasos intermedios que en el artículo original se omiten por brevedad, apoyando el desarrollo en [4].

Este resultado confirma que el valor esperado bajo la distribución estacionaria coincide con el límite asintótico de la esperanza del proceso, reforzando la consistencia interna del modelo.

En conjunto, estos resultados muestran que el modelo de Brennan–Schwartz presenta una dinámica media-revertente, con momentos bien definidos bajo condiciones naturales sobre los parámetros. La coincidencia entre el límite temporal de la esperanza y el primer momento de la distribución estacionaria confirma la ergodicidad del proceso, sentando las bases teóricas para los métodos de inferencia desarrollados en los capítulos siguientes.

Capítulo 2

La Problemática de la Estimación con Datos Discretos

2.1. Simulación Numérica y Validación del Modelo

En el capítulo anterior, logramos establecer los cimientos teóricos del modelo de Brennan-Schwartz. No solo definimos su estructura matemática, sino que también fuimos capaces de demostrar, mediante las herramientas del cálculo estocástico, que el modelo está bien planteado, es decir, que existe una solución única y que podemos representarla de forma explícita. Este paso es muy importante, pues nos da la seguridad de que estamos trabajando sobre una base sólida y no sobre una abstracción sin sustento matemático.

Sin embargo, cuando trasladamos estos conceptos del papel a la práctica financiera real, nos enfrentamos a un panorama distinto. En el mundo de las finanzas aplicadas, la gran mayoría de los modelos que describen el comportamiento de las tasas de interés son tan complejos que no permiten encontrar una solución cerrada o exacta. En esos casos, los matemáticos y analistas no tienen otra opción más que recurrir a los métodos numéricos [36, 25]. Estas herramientas son el motor que permite realizar simulaciones computacionales, ponerle precio a derivados financieros complejos y calcular el riesgo en escenarios donde las fórmulas tradicionales simplemente no llegan.

Por esta razón, antes de aventurarnos a modelos sin solución conocida, resulta metodológicamente muy valioso estudiar cómo se comportan los esquemas de discretización en un entorno donde sí conocemos la respuesta exacta (como es el caso del modelo de Brennan-Schwartz). Podemos pensar en esto como una fase de calibración o prueba de laboratorio: al tener la solución teórica a la mano, podemos comparar directamente qué tanto se aleja nuestra simulación computacional de la realidad matemática. Este escenario controlado es el único que nos permite medir con total rigor qué tan precisos son nuestros métodos, qué tanto error estamos acumulando en cada paso del tiempo y si las simulaciones realmente respetan las propiedades estadísticas que demostramos en el primer capítulo [31, 43].

2.1.1. Solución Exacta del Modelo

Recordemos que la dinámica del proceso está dada por

$$dX_t = (\alpha X_t + \beta) dt + \sigma X_t dW_t,$$

La solución explícita del modelo (1.5) fue obtenida en el capítulo anterior. Para simplicidad, en esta sección fijamos $t_0 = 0$, y por lo tanto la solución exacta puede expresarse como

$$X_t = \Phi_t \left(x_0 + \beta \int_0^t \Phi_s^{-1} ds \right),$$

donde el factor integrante estocástico viene definido por

$$\Phi_t = \exp \left((\alpha - \frac{1}{2}\sigma^2)t + \sigma W_t \right).$$

Esta representación resulta particularmente valiosa para fines de validación numérica, pues permite comparar directamente las trayectorias simuladas con el proceso continuo exacto construido a partir del mismo movimiento Browniano.

2.1.2. Métodos de Simulación

Para poder trasladar el modelo de Brennan-Schwartz del lenguaje de las funciones continuas al lenguaje de las computadoras, el primer paso necesario es realizar una discretización temporal. Dado que una computadora no puede calcular infinitos puntos en un intervalo de tiempo $[0, T]$, debemos dividir dicho intervalo en una cantidad finita de saltos o pasos de tiempo.

En este trabajo, optamos por una discretización uniforme. Esto significa que dividiremos el tiempo total de nuestra simulación en N subintervalos de la misma longitud, a la que llamaremos Δt . Matemáticamente, definimos estos instantes de tiempo como:

$$t_n = n\Delta t, \quad \text{donde } \Delta t = \frac{T}{N} \quad \text{y } n = 0, 1, \dots, N.$$

Bajo este esquema, introducimos una distinción de notación que será vital a lo largo de todo el análisis: utilizaremos X_t para referirnos al proceso continuo exacto (la solución teórica perfecta) y $\hat{X}_n$ para representar nuestra aproximación numérica en el instante t_n [53]. El objetivo de cualquier método de simulación es lograr que la diferencia entre $\hat{X}_n$ y X_t sea lo más pequeña posible.

Para que los resultados de nuestras simulaciones sean comparables y reproducibles, hemos seleccionado un conjunto de parámetros base. Estos valores no son arbitrarios, se eligen para situar al modelo en un régimen donde sus propiedades (como la reversión a la media o la volatilidad) sean claramente observables:

1. Coeficientes del modelo: Se fijan $\alpha = -0,5$ y $\beta = 1$. Estos parámetros determinan la “fuerza” con la que la tasa de interés tiende a regresar a su equilibrio de largo plazo.
2. Volatilidad: Definimos $\sigma = 0,3$, un valor que introduce un nivel de ruido estocástico suficiente para poner a prueba la estabilidad de los algoritmos numéricos.
3. Condiciones de contorno: Iniciamos la simulación con un valor $x_0 = 1$ y extendemos el horizonte temporal hasta $T = 10$.
4. Resolución temporal: Al elegir un paso de tiempo $\Delta t = 0,01$, estamos dividiendo nuestra ventana de 10 años en $N = 1000$ pasos de discretización. Esta resolución es un estándar balanceado que permite observar la convergencia sin exigir un costo computacional excesivo.

El análisis se centrará en dos de los pilares fundamentales de la simulación de Ecuaciones Diferenciales Estocásticas (EDE): el esquema de Euler-Maruyama y el esquema de Milstein [36, 42]. Como veremos a continuación, aunque ambos comparten una base común en el cálculo de Itô, la diferencia en su estructura matemática impacta directamente en qué tan cerca logran estar de la trayectoria real del proceso.

Esquema de Euler–Maruyama

El método de Euler–Maruyama constituye la extensión natural del esquema de Euler para ecuaciones diferenciales ordinarias al contexto del azar [36]. La lógica detrás de este método es intuitiva: si en una ecuación normal aproximamos los cambios pequeños mediante líneas rectas, aquí aproximamos los incrementos diferenciales dt (el tiempo) y dW_t (el ruido blanco) por sus contrapartes discretas Δt y ΔW_n .

Un detalle técnico crucial que debemos considerar es que el incremento del movimiento browniano, ΔW_n , no es un valor cualquiera, sino una variable aleatoria que sigue una distribución normal con media cero y varianza igual al paso de tiempo, es decir [44]:

$$\Delta W_n = W_{t_{n+1}} - W_{t_n} \sim \mathcal{N}(0, \Delta t).$$

Al aplicar esta lógica al modelo de Brennan–Schwartz, obtenemos la siguiente regla de actualización para nuestro proceso:

$$\hat{X}_{n+1} = \hat{X}_n + (\alpha \hat{X}_n + \beta) \Delta t + \sigma \hat{X}_n \Delta W_n.$$

En términos de precisión, este esquema posee lo que llamamos convergencia fuerte de orden $1/2$ y convergencia débil de orden 1 [36]. Lo que significa que, si bien el método es excelente para aproximar promedios o momentos estadísticos (convergencia débil), suele ser un poco peor al intentar calcar una trayectoria individual, presentando errores de magnitud $O(\Delta t^{1/2})$. Aun así, su sencillez lo convierte en el punto de partida obligado para cualquier simulación estocástica.

Para efectos de este trabajo, la lógica de este método se tradujo al lenguaje R mediante la función `simular_euler`, la cual recorre cada paso del tiempo actualizando el valor del proceso, el código de esta y todo el trabajo desarrollado se anexa en el apéndice.

Esquema de Milstein

A diferencia de otros modelos donde la volatilidad es constante, en el modelo de Brennan–Schwartz el coeficiente de difusión depende directamente del estado del sistema ($b(X) = \sigma X$). Esta característica abre la puerta a utilizar un método más refinado: el esquema de Milstein [42].

Este método no se queda solo con la aproximación lineal, sino que incorpora un término adicional derivado de un desarrollo de Itô–Taylor de orden superior. Podemos verlo como una corrección que toma en cuenta que el ruido estocástico no solo afecta al sistema de forma lineal, sino que interactúa consigo mismo conforme el tiempo avanza. La fórmula resultante añade un nuevo componente al final:

$$\hat{X}_{n+1} = \hat{X}_n + (\alpha \hat{X}_n + \beta) \Delta t + \sigma \hat{X}_n \Delta W_n + \frac{1}{2} \sigma^2 \hat{X}_n ((\Delta W_n)^2 - \Delta t).$$

Ese último término, $\frac{1}{2} \sigma^2 \hat{X}_n ((\Delta W_n)^2 - \Delta t)$, es precisamente lo que permite a Milstein dar un salto de calidad, alcanzando una convergencia fuerte de orden $1,0$ [42, 36]. En la

práctica, esto se traduce en una mejora sustancial en la fidelidad con la que seguimos las trayectorias individuales. Lo más interesante es que logramos esta precisión extra sin que la computadora tenga que trabajar mucho más, pues el cálculo adicional es mínimo comparado con el beneficio en exactitud.

La implementación en R se anexa en el Apéndice.

2.1.3. Simulación de Trayectorias

Con los esquemas numéricos ya definidos y los parámetros del modelo bien establecidos, el siguiente paso es poner a prueba el comportamiento dinámico de nuestras simulaciones. Necesitamos observar cómo se comportan las trayectorias resultantes y qué tan consistentes son entre sí.

Para realizar una comparación que sea verdaderamente rigurosa entre el método de Euler–Maruyama y el de Milstein, no se puede simplemente generar trayectorias al azar para cada uno. Si hiciéramos eso, no sabríamos si las diferencias en los resultados se deben a la eficiencia del método o simplemente a que a un método tuvo un ruido estocástico más volátil que a otro.

Por ello, hemos utilizado una técnica fundamental en la simulación Monte Carlo conocida como Common Random Numbers (Números Aleatorios Comunes) [25]. El procedimiento es el siguiente: generamos un conjunto fijo de cinco realizaciones de incrementos brownianos $\{\Delta W_n\}_{n=0}^{N-1}$ y alimentamos con estos mismos datos a ambos esquemas numéricos. Al compartir exactamente la misma fuente de azar, eliminamos cualquier ruido estadístico externo. De esta manera, cualquier discrepancia que observemos entre las trayectorias de Euler y las de Milstein será atribuible exclusivamente a la arquitectura interna del esquema de discretización y no a la suerte del azar [36].




Figura 2.1: Comparación de cinco trayectorias simuladas mediante los esquemas de Euler-Maruyama y Milstein, junto con la trayectoria promedio en cada caso.

Al observar los resultados en la Figura 2.1, la primera impresión es de una coincidencia casi total. Bajo una discretización suficientemente fina, como la que estamos usando ($\Delta t = 0,01$), ambos métodos producen trayectorias que resultan visualmente indistinguibles. Tanto las fluctuaciones rápidas como la tendencia general de regresión a la media y la dispersión de los datos coinciden de forma notable en ambos casos.

Este resultado es consistente con la teoría de convergencia débil de los esquemas numéricos [36]. La teoría nos indica que, conforme el paso del tiempo Δt se aproxima a cero, ambos métodos están diseñados para converger hacia el mismo proceso límite. Por lo tanto, en una malla temporal bien refinada, es natural que a simple vista no se perciban diferencias significativas en la evolución del proceso.

Sin embargo, es vital advertir que esta similitud visual no debe confundirse con una igualdad cuantitativa exacta. Aunque en la gráfica las líneas parezcan estar una sobre otra, existen discrepancias sutiles pero matemáticamente muy importantes. Estas diferencias pequeñas en la precisión trayectoria a trayectoria son las que realmente definen la calidad de un método sobre otro. Para desvelar estas diferencias, es necesario realizar un análisis del error fuerte, el cual mide de forma numérica qué tanto se aleja cada aproximación de la solución real bajo una misma realización del movimiento browniano.

2.1.4. Comparación Numérica: Media, Varianza y Error

Una vez que hemos comprendido de manera visual cómo se comportan las trayectorias, el siguiente paso es abandonar la interpretación subjetiva y pasar a una evaluación rigurosa y cuantitativa. Para lograr esto, ya no es suficiente observar unas cuantas simulaciones, así que se ha incrementado el número de trayectorias independientes a 1,000.

Al trabajar con 1,000 simulaciones, estamos utilizando el poder de la ley de los grandes números a través del método de Monte Carlo [16, 25]. Esto nos permite aproximar las esperanzas mediante promedios muestrales, reduciendo el error estadístico y garantizando que los resultados que estamos midiendo sean representativos del modelo y no fluctuaciones temporales de una sola corrida.

En este análisis, nuestra métrica principal será el Error Fuerte, evaluado específicamente en el instante final del horizonte temporal ($T = 10$). Dado que nuestra discretización termina en el paso N , tenemos que $\hat{X}_T = \hat{X}_N$. Definimos formalmente este error mediante la raíz del error cuadrático medio (RMSE, por sus siglas en inglés) [36]:

$$\text{RMSE} = \sqrt{\mathbb{E} \left[(\hat{X}_T - X_T)^2 \right]}.$$

En esta ecuación, X_T representa la solución exacta “perfecta” que obtuvimos analíticamente en el capítulo anterior, mientras que $\hat{X}_T$ es la aproximación que arrojó nuestra computadora. En la práctica, como no podemos calcular la esperanza matemática de infinitas trayectorias, utilizamos el promedio de las diferencias al cuadrado sobre nuestra muestra de $M = 1000$ trayectorias:

$$\widehat{\text{RMSE}} = \sqrt{\frac{1}{M} \sum_{i=1}^M \left(\hat{X}_T^{(i)} - X_T^{(i)} \right)^2}.$$

Esta medida es fundamental porque penaliza de forma más severa las desviaciones grandes, dándonos una idea clara de qué tan “fiel” es el método a la trayectoria real en un escenario de estrés o volatilidad. Los resultados obtenidos de esta comparación numérica se presentan a continuación:

Método	Orden de Convergencia	RMSE
Euler-Maruyama	0.5 (Fuerte)	0.012650388
Milstein	1.0 (Fuerte)	0.004812893
<i>Mejora de Milstein sobre Euler: 61.95 %</i>		

Cuadro 2.1: Comparación cuantitativa del error fuerte entre los esquemas de discretización.

Los datos arrojan una conclusión contundente que respalda la teoría de ecuaciones diferenciales estocásticas [36, 42]. Aunque anteriormente dijimos que ambos métodos se veían parecidos en una gráfica, el análisis numérico revela que el esquema de Milstein es significativamente más preciso.

Mientras que Euler-Maruyama opera con un orden de convergencia de $1/2$, el término de corrección adicional que incorporamos en el esquema de Milstein le permite alcanzar un orden de convergencia de 1. En términos prácticos, esta diferencia teórica se traduce en una reducción del error de más del 60 %. Esto demuestra que, incluso bajo una discretización fina como la que estamos usando ($\Delta t = 0,01$), elegir el algoritmo correcto tiene un impacto

masivo en la fiabilidad de los resultados financieros, especialmente cuando se busca una precisión alta en la valoración de activos o en el cálculo de riesgos.

Fuera del análisis detallado trayectoria a trayectoria, que nos permitió identificar la precisión individual de cada método, resulta igualmente relevante estudiar el comportamiento de los primeros dos momentos del proceso: la media y la varianza. En el contexto de las finanzas, estos momentos representan, respectivamente, el valor esperado de la tasa de interés en el futuro y la incertidumbre o riesgo asociado a dicho valor.

Para realizar este estudio, aprovechamos nuevamente nuestras 1,000 trayectorias simuladas. En lugar de mirar cada una por separado, calculamos en cada instante de tiempo t_n la media empírica y la varianza empírica. Este enfoque de Monte Carlo nos permite observar cómo evolucionan las propiedades estadísticas del modelo de Brennan-Schwartz conforme pasa el tiempo, comparando los resultados obtenidos por Euler-Maruyama frente a los de Milstein.




Figura 2.2: Evolución temporal de la media y la varianza estimadas mediante simulación Monte Carlo con 1000 trayectorias.

Al observar la Figura 2.2, el resultado es sumamente revelador. A diferencia de lo que

ocurrió con el error fuerte, donde Milstein mostró una clara ventaja, aquí las estimaciones de la media y la varianza para ambos métodos son prácticamente idénticas a lo largo de todo el horizonte temporal de 10 años. Las líneas que representan a cada esquema se superponen casi a la perfección, siguiendo la tendencia teórica esperada.

Este comportamiento confirma un concepto fundamental en el análisis numérico estocástico: la convergencia débil [36]. Mientras que el error fuerte nos habla de la capacidad de calcar una trayectoria específica, la convergencia débil se refiere a la capacidad del método para reproducir la distribución de probabilidad del proceso y, por ende, sus momentos estadísticos.

En términos prácticos, este resultado es una validación de que ambos esquemas son consistentes a nivel poblacional. En muchas aplicaciones financieras, como la valuación de opciones o el cálculo de precios promedio, el interés principal no radica en predecir una trayectoria única (lo cual es imposible debido al ruido estocástico), sino en calcular expectativas o valores promedio, bajo este enfoque, ambos métodos resultan ser herramientas confiables, siempre que el número de simulaciones sea lo suficientemente grande como para que el error estadístico de Monte Carlo se estabilice.

2.1.5. Distribución Estacionaria

En el estudio de las Ecuaciones Diferenciales Estocásticas, no basta con que un método sea preciso en los primeros pasos de tiempo, también debemos garantizar que, conforme el tiempo avanza, la simulación sea capaz de converger hacia la distribución estacionaria (o invariante) del modelo original.

Como se derivó analíticamente en el capítulo anterior, el modelo de Brennan–Schwartz posee una propiedad matemática muy valiosa, pues bajo ciertas condiciones de estabilidad, el proceso no se dispersa indefinidamente, sino que tiende a estabilizarse en una distribución de probabilidad específica. En este caso, la distribución del proceso continuo está dada por una Gamma Inversa [43], cuya función de densidad de probabilidad viene definida por:

$$f(x) = \frac{\left(\frac{2\beta}{\sigma^2}\right)^{1-\frac{2\alpha}{\sigma^2}} x^{\frac{2\alpha}{\sigma^2}-2} e^{-\frac{2\beta}{\sigma^2 x}}}{\Gamma\left(1 - \frac{2\alpha}{\sigma^2}\right)}.$$

Para que esta función sea integrable (es decir, para que sea una probabilidad válida), el parámetro de forma $a = 1 - \frac{2\alpha}{\sigma^2}$ debe ser estrictamente positivo. Esto nos impone la condición de estabilidad [34]:

$$2\alpha < \sigma^2.$$

Físicamente, esta condición nos dice que la fuerza de la reversión a la media debe ser suficiente para contrarrestar la dispersión causada por la volatilidad. En nuestro experimento, con los parámetros $\alpha = -0,5$ y $\sigma = 0,3$, la condición se cumple ampliamente, lo que nos permite esperar que nuestras simulaciones se asienten sobre esta campana de probabilidad teórica tras un tiempo suficientemente largo ($T = 10$).




Figura 2.3: Histograma de los valores finales X_T y comparación con la densidad estacionaria teórica (Gamma Inversa).

Como se puede apreciar en la Figura 2.3, los resultados son sumamente satisfactorios. El histograma, que representa la distribución empírica de los valores finales de nuestras 1,000 trayectorias, encaja de manera casi perfecta con la curva de la densidad teórica de la Gamma Inversa.

Para corroborar estadísticamente esta similitud visual, se aplicó la prueba de bondad de ajuste de Kolmogorov–Smirnov (K–S). Esta prueba permite contrastar la hipótesis nula (H_0) de que la muestra de valores finales $\{X_T^{(i)}\}_{i=1}^{1000}$ proviene de la distribución Gamma Inversa calculada analíticamente. Los resultados obtenidos para ambos esquemas de discretización se presentan en el Cuadro 2.2.

Método	Estadístico D	p -value
Euler–Maruyama	0.010375	0.231976
Milstein	0.010214	0.247720

Cuadro 2.2: Resultados de la prueba de bondad de ajuste Kolmogorov–Smirnov para $T = 10$.

Dado que en ambos casos el estadístico D es reducido y los valores- p son superiores al nivel de significancia estándar de 0,05, no existe evidencia estadística suficiente pa-

ra rechazar la hipótesis nula. Esto respalda la consistencia entre las simulaciones y la distribución estacionaria teórica del modelo.

Esta coincidencia representa una validación doble. Por un lado, confirma que la implementación numérica de los esquemas de Euler y Milstein es estadísticamente coherente y no introduce sesgos artificiales a largo plazo. Por otro lado, valida las propiedades ergódicas del proceso continuo que demostramos y vimos en la teoría [43, 37]. En conclusión, los métodos implementados han demostrado ser herramientas robustas, capaces de reproducir fielmente tanto la dinámica inmediata del modelo como su estructura probabilística de equilibrio, cerrando así el ciclo de validación de nuestra metodología de simulación.

2.1.6. Análisis de Sensibilidad de Parámetros

Con el objetivo de comprender cómo influyen los distintos parámetros del modelo de Brennan-Schwartz en la evolución del proceso X_t , se realizó un análisis de sensibilidad numérico utilizando el esquema de Milstein debido a su probada precisión superior. Para ello, se generaron múltiples trayectorias simuladas variando uno a uno los parámetros α , β y σ , manteniendo los otros constantes. En cada caso se comparan 5 trayectorias para distintos valores del parámetro en estudio.

Variación del parámetro α (Velocidad de Reversión)

Se consideraron los valores $\alpha = -0,05, -0,5, -2, -5$, manteniendo constantes $\beta = 1$ y $\sigma = 0,3$. El parámetro α gobierna la velocidad de ajuste del proceso hacia su nivel de equilibrio de largo plazo [12, 43]. En el modelo de Brennan-Schwartz, dado que $\alpha < 0$, este término actúa como una fuerza restauradora: cuanto mayor es su magnitud absoluta, más intensa es la atracción hacia la media.




Figura 2.4: Trayectorias simuladas para distintos valores de α con $\beta = 1$ y $\sigma = 0,3$.

Como observamos en la Figura 2.4, los regímenes de reversión cambian drásticamente la memoria del proceso. Para valores cercanos a cero ($\alpha = -0,05$), la tasa de interés parece tener una memoria larga, se comporta de forma persistente, como un paseo aleatorio donde los cambios tardan mucho en disiparse. Por el contrario, cuando forzamos una reversión agresiva ($\alpha = -5,0$), las trayectorias se ven confinadas en un rango muy estrecho. Cualquier desviación es corregida de forma casi instantánea, este comportamiento corresponde a un régimen de alta velocidad de reversión, donde las desviaciones respecto al equilibrio se corrigen rápidamente.

Variación del parámetro β (Nivel de Equilibrio)

Se fijaron $\alpha = -0,5$ y $\sigma = 0,3$, y se consideraron los valores $\beta = 0,5, 1, 3, 5$. El parámetro β , en conjunción con α , determina el nivel asintótico o tendencia central de las tasas de interés, dado por la relación $\theta = -\beta/\alpha$ [12]. Manteniendo constante la velocidad de reversión y la volatilidad, un incremento en β desplaza la distribución estacionaria del proceso hacia la derecha. Si α es la fuerza que tira de la tasa, el parámetro β es el que define hacia dónde está tirando esa fuerza.




Figura 2.5: Trayectorias simuladas para distintos valores de β con $\alpha = -0,5$ y $\sigma = 0,3$.

En el análisis de sensibilidad mostrado en la Figura 2.5 se ilustra este desplazamiento. Se observa cómo el parámetro β funciona como un mecanismo de elevación que al aumentar su valor, simplemente estamos desplazando toda la distribución de las tasas hacia arriba. Por ejemplo, con $\alpha = -0,5$, un $\beta = 0,5$ sitúa el equilibrio en 1,0, mientras que un $\beta = 5,0$ lo eleva a 10,0, simulando un entorno de tasas nominales elevadas típico de periodos inflacionarios o crisis financieras. Es crucial notar que, aunque el nivel medio cambia, la estructura de la volatilidad relativa y la velocidad de corrección se mantienen inalteradas.

Variación del parámetro σ (Volatilidad Difusiva)

Finalmente, se evaluó el impacto del parámetro de volatilidad σ , utilizando los valores $\sigma = 0,05, 0,2, 0,5, 0,9$, con $\alpha = -0,5$ y $\beta = 1$. El parámetro σ cuantifica la intensidad de las fluctuaciones estocásticas [44]. En el modelo Brennan-Schwartz, el término de difusión es multiplicativo ($\sigma X_t dW_t$), lo que implica que la varianza del proceso depende del nivel actual de la tasa [12].




Figura 2.6: Trayectorias simuladas para distintos valores de σ con $\alpha = -0,5$ y $\beta = 1$.

La Figura 2.6 compara trayectorias bajo distintos regímenes de incertidumbre. Con un $\sigma = 0,05$, la dinámica es predominantemente determinista, gobernada casi exclusivamente por la parte de deriva (drift). A medida que aumentamos el parámetro hacia $\sigma = 0,9$, el “ruido” del mercado comienza a dominar la señal. En este régimen de alta volatilidad, las trayectorias exhiben excursiones extremas, aumentando la probabilidad de alcanzar valores atípicos, lo cual representa un desafío significativo para la gestión de riesgos y la valoración de derivados sensibles a la cola de la distribución.

En conjunto, el análisis de sensibilidad confirma la interpretación económica de los parámetros del modelo y refuerza su interpretabilidad en el contexto financiero:

- α controla la velocidad de reversión hacia el equilibrio o persistencia de los choques.
- β determina, de forma proporcional, el nivel de largo plazo de la tasa.
- σ regula la intensidad de la incertidumbre y la dispersión de los posibles estados futuros.

2.2. Estimación Clásica: Máxima Verosimilitud y Método de Momentos.

Una vez que hemos validado la capacidad de los métodos numéricos para replicar la dinámica del modelo, nos enfrentamos al problema inverso, que es el núcleo de la estadística aplicada: ¿cómo podemos estimar los parámetros del modelo a partir de los datos observados?

En esta sección abordamos el problema central de inferencia del modelo propuesto, la estimación de sus parámetros a partir de una trayectoria observada del proceso. Dado que el modelo está formulado como una ecuación diferencial estocástica, los métodos clásicos de regresión no son directamente aplicables. En su lugar, recurrimos a herramientas específicas de inferencia para procesos de difusión [53, 37, 43].

En particular, los parámetros de deriva α y β se estiman mediante el método de máxima verosimilitud bajo muestreo continuo, aprovechando la estructura lineal del término determinista. Para el parámetro de difusión σ utilizamos el método de momentos, lo que permite obtener un estimador consistente basado en las propiedades cuadráticas del proceso [1]. De esta forma, combinamos dos enfoques clásicos de inferencia que se adaptan naturalmente a la estructura del modelo.

2.2.1. Estimación de máxima verosimilitud de los parámetros de deriva

Partimos de la definición original de nuestra Ecuación Diferencial Estocástica (EDE) (1.1) para el modelo de Brennan-Schwartz:

$$dX_t = (\alpha X_t + \beta)dt + \sigma X_t dW_t, X_{t_0} = x_0.$$

En esta expresión, el cambio en el tiempo de la variable X_t está compuesto por una parte determinista (la deriva) $(\alpha X_t + \beta)$ y una componente de ruido estocástico $(\sigma X_t dW_t)$. Para facilitar la estimación, resulta conveniente reescribir el modelo en una forma vectorial más general [4]. Esta notación no solo es más elegante, sino que permite tratar a los parámetros α y β de manera conjunta dentro de un marco de álgebra lineal:

$$dX_t = A_t(X_t)\theta + B_t(X_t)dW_t, \quad t_0 \leq t \leq T.$$

Bajo esta estructura, los componentes de nuestro proceso se definen como:

$$A_t(X_t) = (X_t, 1), \quad \theta = \begin{pmatrix} \alpha \\ \beta \end{pmatrix} \quad B_t(X_t) = \sigma X_t.$$

Aquí, $\theta \in \mathbb{R}^2$ representa el vector de parámetros que deseamos encontrar, A_t es el vector de diseño que acompaña a la deriva, y B_t encapsula la volatilidad. Asumiendo que esta ecuación posee una solución única para cada θ , podemos recurrir a la teoría de estimación para procesos de difusión [37, 53]. El estimador de máxima verosimilitud para el vector θ se obtiene resolviendo el sistema de ecuaciones normales, cuya solución tiene la forma:

$$\hat{\theta} = S_T^{-1} H_T,$$

donde H_T es el siguiente vector de información k -dimensional:

$$H_T = \int_{t_0}^T A_s^\top(x_s) (B_s(x_s) B_s(x_s))^{-1} dx_s,$$

y S_T es la matriz de información de Fisher $k \times k$ [43]:

$$S_T = \int_{t_0}^T A_s^\top(x_s) (B_s(x_s) B_s(x_s))^{-1} A_s(x_s) ds,$$

ambos acumulan la información de la trayectoria conforme el tiempo avanza. $Y^\top$ denota la transposición.

Tenemos que $B_s(x_s) = \sigma x_s$, entonces:

$$(B_s(x_s))^2 = \sigma^2 x_s^2 \quad \Rightarrow \quad ((B_s(X_t))^2)^{-1} = \frac{1}{\sigma^2 x_s^2}.$$

Al sustituir esto en las definiciones anteriores, podemos calcular explícitamente H_T y S_T . En el caso de H_T , obtenemos un vector que pondera los incrementos del proceso dx_s por el inverso de la varianza:

$$\begin{aligned} H_T &= \int_{t_0}^T \begin{pmatrix} x_s \\ 1 \end{pmatrix} \cdot \frac{1}{\sigma^2 x_s^2} \cdot dx_s = \frac{1}{\sigma^2} \begin{pmatrix} \int_{t_0}^T \frac{1}{x_s} dx_s \\ \int_{t_0}^T \frac{1}{x_s^2} dx_s \end{pmatrix} \\ &\Rightarrow H_T^\top = \frac{1}{\sigma^2} \left(\int_{t_0}^T \frac{dx_s}{x_s}, \int_{t_0}^T \frac{dx_s}{x_s^2} \right). \end{aligned}$$

y para S_T , recordemos que

$$A_s(x_s) = (x_s, 1), \quad A_s^\top = \begin{pmatrix} x_s \\ 1 \end{pmatrix}.$$

Entonces:

$$A_s^\top A_s = \begin{pmatrix} x_s \\ 1 \end{pmatrix} (x_s, 1) = \begin{pmatrix} x_s^2 & x_s \\ x_s & 1 \end{pmatrix}.$$

Ahora multiplicamos $A_s^\top A_s$ por $((B_s(X_t))^2)^{-1} = \frac{1}{\sigma^2 x_s^2}$, y luego integramos respecto a s para obtener S_T :

$$S_T = \frac{1}{\sigma^2} \int_{t_0}^T \begin{pmatrix} 1 & \frac{1}{x_s} \\ \frac{1}{x_s} & \frac{1}{x_s^2} \end{pmatrix} ds = \frac{1}{\sigma^2} \begin{pmatrix} T - t_0 & \int_{t_0}^T \frac{ds}{x_s} \\ \int_{t_0}^T \frac{ds}{x_s} & \int_{t_0}^T \frac{ds}{x_s^2} \end{pmatrix}.$$

Queremos calcular $\hat{\theta} = \begin{pmatrix} \hat{\alpha} \\ \hat{\beta} \end{pmatrix} = S_T^{-1} H_T$, ya tenemos H_T y S_T . Utilizando la fórmula para la inversa de una matriz de 2×2 , llegamos a:

$$S_T^{-1} = \sigma^2 \cdot \frac{1}{(T - t_0) \left(\int_{t_0}^T \frac{ds}{x_s^2} \right) - \left(\int_{t_0}^T \frac{ds}{x_s} \right)^2} \begin{pmatrix} \int_{t_0}^T \frac{ds}{x_s^2} & - \int_{t_0}^T \frac{ds}{x_s} \\ - \int_{t_0}^T \frac{ds}{x_s} & T - t_0 \end{pmatrix}.$$

Entonces, tenemos que:

$$\hat{\theta} = S_T^{-1} H_T = \sigma^2 \cdot \frac{1}{(T - t_0) \left(\int_{t_0}^T \frac{ds}{x_s^2} \right) - \left(\int_{t_0}^T \frac{ds}{x_s} \right)^2} \begin{pmatrix} \int_{t_0}^T \frac{ds}{x_s^2} & - \int_{t_0}^T \frac{ds}{x_s} \\ - \int_{t_0}^T \frac{ds}{x_s} & T - t_0 \end{pmatrix} \cdot \frac{1}{\sigma^2} \begin{pmatrix} \int_{t_0}^T \frac{dx_s}{x_s} \\ \int_{t_0}^T \frac{dx_s}{x_s^2} \end{pmatrix}.$$

Al multiplicar S_T^{-1} por H_T , observamos una propiedad interesante: el parámetro de volatilidad σ^2 se cancela. Esto nos indica que, bajo observación continua, la estimación de

la deriva es independiente del valor de la volatilidad, lo que simplifica enormemente el problema de optimización:

$$\begin{aligned}\hat{\theta} &= S_T^{-1} H_T = \frac{1}{(T - t_0) \left(\int_{t_0}^T \frac{ds}{x_s^2} \right) - \left(\int_{t_0}^T \frac{ds}{x_s} \right)^2} \begin{pmatrix} \int_{t_0}^T \frac{ds}{x_s^2} & - \int_{t_0}^T \frac{ds}{x_s} \\ - \int_{t_0}^T \frac{ds}{x_s} & T - t_0 \end{pmatrix} \cdot \begin{pmatrix} \int_{t_0}^T \frac{dx_s}{x_s} \\ \int_{t_0}^T \frac{dx_s}{x_s^2} \end{pmatrix} \\ &= \frac{1}{(T - t_0) \left(\int_{t_0}^T \frac{ds}{x_s^2} \right) - \left(\int_{t_0}^T \frac{ds}{x_s} \right)^2} \begin{pmatrix} \left(\int_{t_0}^T \frac{ds}{x_s^2} \cdot \int_{t_0}^T \frac{dx_s}{x_s} \right) - \left(\int_{t_0}^T \frac{ds}{x_s} \cdot \int_{t_0}^T \frac{dx_s}{x_s^2} \right) \\ \left(- \int_{t_0}^T \frac{ds}{x_s} \cdot \int_{t_0}^T \frac{dx_s}{x_s} \right) + \left((T - t_0) \cdot \int_{t_0}^T \frac{dx_s}{x_s^2} \right) \end{pmatrix}.\end{aligned}$$

Con esto, tenemos que las expresiones de los estimadores son:

$$\begin{aligned}\hat{\alpha} &= \frac{\int_{t_0}^T \frac{ds}{x_s^2} \int_{t_0}^T \frac{dx_s}{x_s} - \int_{t_0}^T \frac{ds}{x_s} \int_{t_0}^T \frac{dx_s}{x_s^2}}{(T - t_0) \int_{t_0}^T \frac{ds}{x_s^2} - \left(\int_{t_0}^T \frac{ds}{x_s} \right)^2}, \\ \hat{\beta} &= \frac{(T - t_0) \int_{t_0}^T \frac{dx_s}{x_s^2} - \int_{t_0}^T \frac{ds}{x_s} \int_{t_0}^T \frac{dx_s}{x_s}}{(T - t_0) \int_{t_0}^T \frac{ds}{x_s^2} - \left(\int_{t_0}^T \frac{ds}{x_s} \right)^2}.\end{aligned}$$

Sin embargo, las expresiones anteriores aún contienen integrales estocásticas de la forma $\int \frac{dx_s}{x_s}$, las cuales no son directamente evaluables como integrales de Riemann comunes. Para transformar estas expresiones en cantidades que podamos calcular a partir de una trayectoria observada, aplicamos la fórmula de Itô [44, 33]. Esto nos permite limpiar los términos estocásticos y expresarlos en función de los valores finales e iniciales del proceso:

$$\begin{aligned}\int_{t_0}^T \frac{dx_s}{x_s} &= \log(X_T) - \log(X_{t_0}) + \frac{\sigma^2}{2}(T - t_0), \\ \int_{t_0}^T \frac{dx_s}{x_s^2} &= \frac{1}{X_{t_0}} - \frac{1}{X_T} + \sigma^2 \int_{t_0}^T \frac{ds}{x_s}.\end{aligned}$$

Sustituyendo estos resultados en las componentes de $\hat{\theta}$, obtenemos finalmente las fórmulas cerradas para nuestros estimadores:

$$\hat{\alpha} = \frac{\int_{t_0}^T \frac{ds}{x_s^2} \left[\log \left(\frac{X_T}{X_{t_0}} \right) + \frac{\sigma^2}{2}(T - t_0) \right] - \left[\frac{1}{X_{t_0}} - \frac{1}{X_T} + \sigma^2 \int_{t_0}^T \frac{ds}{x_s} \right] \int_{t_0}^T \frac{ds}{x_s}}{(T - t_0) \int_{t_0}^T \frac{ds}{x_s^2} - \left(\int_{t_0}^T \frac{ds}{x_s} \right)^2}, \quad (2.1)$$

$$\hat{\beta} = \frac{(T - t_0) \left[\frac{1}{X_{t_0}} - \frac{1}{X_T} + \sigma^2 \int_{t_0}^T \frac{ds}{x_s} \right] - \left[\log \left(\frac{X_T}{X_{t_0}} \right) + \frac{\sigma^2}{2}(T - t_0) \right] \int_{t_0}^T \frac{ds}{x_s}}{(T - t_0) \int_{t_0}^T \frac{ds}{x_s^2} - \left(\int_{t_0}^T \frac{ds}{x_s} \right)^2}. \quad (2.2)$$

Las expresiones anteriores muestran que los estimadores dependen únicamente de la trayectoria observada del proceso en el intervalo $[t_0, T]$ y de σ . En particular, intervienen tanto los valores extremos X_{t_0} y X_T , integrales funcionales de la trayectoria, y la volatilidad estimada del proceso (σ^2) [53, 54]. Esto refleja la naturaleza acumulativa de la información en modelos de tiempo continuo, toda la historia de la trayectoria, cada oscilación y cada tendencia intermedia, aporta información valiosa para reducir la incertidumbre sobre la velocidad de reversión y el nivel de equilibrio.

2.2.2. Estimación del parámetro de difusión σ mediante variación cuadrática

La estimación del parámetro de difusión σ representa un desafío técnico distinto al de los parámetros de deriva. Intuitivamente, mientras que α y β controlan la tendencia del proceso, σ determina la intensidad de las fluctuaciones instantáneas.

Es importante destacar que no se utiliza el Estimador de Máxima Verosimilitud (EMV) continuo basado en el teorema de Girsanov para σ . Esto se debe en primera instancia a que, en tiempo continuo, las medidas de probabilidad inducidas por difusiones con distinta volatilidad son mutuamente singulares [53, 37]. En términos más simples: si observamos una trayectoria de manera continua sin intervalos, el cálculo de su variación cuadrática nos revela el valor exacto de σ sin ningún margen de error. Al ser una cantidad determinista bajo observación continua, el concepto estadístico de “buscar el valor más probable” pierde sentido y el enfoque clásico de máxima verosimilitud se vuelve inaplicable.

Aunque en la realidad solo contamos con observaciones discretas y σ podría estimarse aproximando la verosimilitud, este enfoque requiere discretizaciones adicionales y puede inducir sesgos en muestras finitas. Por esta razón, se emplea una metodología basada en la variación cuadrática y los incrementos relativos del proceso. Este enfoque, formalizado en trabajos clásicos de econometría financiera [18, 8], permite aislar el componente de volatilidad aprovechando las propiedades asintóticas de los procesos de Itô, proporcionando así un estimador consistente y computacionalmente robusto, con menos complicaciones técnicas y de implementación que si usáramos EMV.

El objetivo central es segregar el término de difusión de los términos de tendencia (drift). Partimos de la Ecuación Diferencial Estocástica (EDE) del modelo de Brennan-Schwartz definida en (1.1):

$$dX_t = (\alpha X_t + \beta)dt + \sigma X_t dW_t. \quad (2.3)$$

Para aislar σ , analizamos la variación cuadrática infinitesimal del proceso, obtenida al elevar al cuadrado el diferencial dX_t :

$$(dX_t)^2 = ((\alpha X_t + \beta)dt + \sigma X_t dW_t)^2.$$

Desarrollando este binomio al cuadrado, obtenemos tres términos:

$$(dX_t)^2 = (\alpha X_t + \beta)^2(dt)^2 + 2(\alpha X_t + \beta)(\sigma X_t)dt dW_t + (\sigma X_t)^2(dW_t)^2.$$

En este punto, aplicamos las reglas de multiplicación del cálculo estocástico (Álgebra de Itô) [44]. Estas reglas se basan en la velocidad con la que cada término se desvanece cuando el paso del tiempo dt se hace infinitamente pequeño:

- $(dW_t)^2 = dt$: Esta es la propiedad fundamental del movimiento Browniano. El ruido elevado al cuadrado se “estabiliza” y se convierte exactamente en un diferencial de tiempo, converge exactamente al paso del tiempo (es de orden $O(dt)$).
- $(dt)^2 = 0$: El tiempo al cuadrado es un infinitésimo de orden superior ($O(dt^2)$). Es tan pequeño que desaparece.
- $dt \cdot dW_t = 0$: Al ser de orden $O(dt^{3/2})$, el producto entre tiempo y ruido también se desvanece en el límite continuo [46].

Aplicando estas reglas al desarrollo del binomio, observamos que los términos que contienen el diferencial de tiempo al cuadrado y el producto cruzado se anulan por completo. El único término que subsiste es el componente estocástico al cuadrado:

$$\begin{aligned}(dX_t)^2 &= (\alpha X_t + \beta)^2 \cdot 0 + 2(\alpha X_t + \beta)(\sigma X_t) \cdot 0 + \sigma^2 X_t^2 dt \\ (dX_t)^2 &= \sigma^2 X_t^2 dt.\end{aligned}$$

Esta es una propiedad fundamental de las difusiones: a nivel microscópico, la variación cuadrática de la trayectoria está dictada exclusivamente por el término de volatilidad, haciendo que la deriva (drift) sea irrelevante para este cálculo [41].

Entonces, podemos denotar la variación cuadrática acumulada del proceso X_t como $[X, X]_t$, y entonces, su diferencial captura la esencia de la volatilidad del sistema:

$$d[X, X]_t = (dX_t)^2 = \sigma^2 X_t^2 dt. \quad (2.4)$$

Para extraer el parámetro constante σ^2 , necesitamos eliminar la dependencia del nivel de la tasa X_t^2 . Debido a que en el modelo de Brennan-Schwartz la difusión es una función del estado ($b(X) = \sigma X$), el diferencial de la variación cuadrática depende del nivel actual de la tasa X_t^2 , definimos entonces el proceso de rendimientos relativos $R_t = \frac{dX_t}{X_t}$ (que representa el cambio porcentual de la tasa) [57]. Si dividimos nuestra ecuación anterior entre X_t^2 , obtenemos la variación cuadrática de los rendimientos, denotada como $d[R, R]_t$:

$$d[R, R]_t = \frac{(dX_t)^2}{X_t^2} = \sigma^2 dt. \quad (2.5)$$

Al integrar ambos lados de esta expresión sobre el horizonte de tiempo total $[0, T]$, obtenemos una relación exacta en tiempo continuo:

$$\int_0^T d[R, R]_t = \int_0^T \sigma^2 dt = \sigma^2 T. \quad (2.6)$$

Hasta ahora, el desarrollo ha sido en tiempo continuo (teórico). Sin embargo, en la práctica contamos con una muestra discreta de n observaciones. Para trasladar estos conceptos de tiempo continuo a una implementación con datos discretos, realizamos una aproximación de los diferenciales mediante incrementos finitos [31], aproximamos los diferenciales continuos mediante incrementos finitos observados entre los instantes de tiempo $t - 1$ y t .

Así, definimos $dX_t \approx \Delta X_t = X_t - X_{t-1}$ y el diferencial de tiempo como Δt . Para el denominador X_t^2 , aproximamos el denominador continuo utilizando el valor conocido al inicio del paso, X_{t-1} , pues de acuerdo con la definición de la integral de Itô [44], el integrando debe ser evaluado en el límite inferior del intervalo para preservar la propiedad de adaptabilidad del proceso (siguiendo la convención de Itô de no-anticipación). Sustituyendo estas aproximaciones discretas, la relación del integrando se transforma en:

$$\frac{(X_t - X_{t-1})^2}{X_{t-1}^2} = \left(\frac{X_t - X_{t-1}}{X_{t-1}} \right)^2 \approx \sigma^2 \Delta t.$$

Para obtener el estimador global a partir de la serie de tiempo de n observaciones, la integral se aproxima mediante la suma de Riemann de esta relación sobre todos los

incrementos disponibles [31]. Dado que requerimos el valor previo X_{t-1} , la suma consta de $n - 1$ términos, iniciando desde $t = 2$:

$$\sum_{t=2}^n \left(\frac{X_t - X_{t-1}}{X_{t-1}} \right)^2 \approx \sum_{t=2}^n \sigma^2 \Delta t.$$

Dado que σ^2 y Δt son constantes bajo el supuesto de un paso de tiempo equidistante, podemos extraerlos de la suma. La suma de los pasos de tiempo corresponde al tiempo total transcurrido del proceso, denotado como $T = (n - 1)\Delta t$:

$$\sum_{t=2}^n \left(\frac{X_t - X_{t-1}}{X_{t-1}} \right)^2 \approx \sigma^2 \left(\sum_{t=2}^n \Delta t \right) = \sigma^2 T.$$

Finalmente, al despejar σ^2 y extraer la raíz cuadrada para regresar a la unidad de medida original de la tasa, definimos el estimador consistente basado en variación cuadrática como [1, 41]:

$$\hat{\sigma} = \sqrt{\frac{1}{T} \sum_{t=2}^n \left(\frac{X_t - X_{t-1}}{X_{t-1}} \right)^2}. \quad (2.7)$$

Este estimador destaca por su estabilidad numérica y eficiencia computacional. En un esquema de muestreo denso (infill asymptotics), donde el intervalo entre observaciones tiende a cero ($\Delta t \rightarrow 0$), el estimador converge de manera robusta al valor verdadero del parámetro [1, 8]. Su relevancia metodológica en esta tesis reside en que su precisión es independiente de la correcta especificación de la deriva [41], lo que proporciona una base sólida para la posterior estimación de los parámetros de tendencia α y β .

2.2.3. Normalidad asintótica de los estimadores

Una vez que hemos definido cómo obtener los estimadores para los parámetros de nuestro modelo, el siguiente paso fundamental es determinar qué tan confiables son estos valores conforme aumentamos el tamaño de nuestra muestra o el tiempo de observación. Para ello, recurrimos al análisis asintótico, el cual nos permite describir el comportamiento de los estimadores cuando el tiempo de observación T tiende a infinito [37, 53].

Como se demostró en el Capítulo 1, bajo las restricciones $\alpha < \frac{\sigma^2}{2}$ y $\beta > 0$, es posible confirmar las condiciones de ergodicidad para el modelo de Brennan-Schwartz [4]. En este contexto, la ergodicidad garantiza que el proceso estocástico asociado al modelo converge en distribución hacia un régimen estacionario (una medida invariante), lo cual es fundamental para el análisis asintótico de los estimadores [37].

Dado que nuestro modelo satisface estas propiedades ergódicas, por lo tanto, para σ conocido y para el vector de parámetros $\theta = (\alpha, \beta)^\top \in (\alpha_1, \alpha_2) \times (\beta_1, \beta_2)$, con $\alpha_1 < \alpha_2 < \frac{\sigma^2}{2}$ y $\beta_1 > 0$, se cumple que [4, 37]:

$$\mathcal{L}_\theta \left(\sqrt{T}(\hat{\theta} - \theta) \right) \xrightarrow{d} \mathcal{N}_2(0, I^{-1}(\theta)), \quad \text{cuando } T \rightarrow \infty. \quad (2.8)$$

En esta expresión, $\hat{\theta}$ representa un estimador consistente de θ (específicamente el de máxima verosimilitud) y la flecha denota convergencia en distribución. Este resultado es una manifestación del Teorema Central del Límite aplicado a martingalas en procesos ergódicos [38], y es lo que nos permite, en la práctica, tratar a nuestros errores de

estimación como si provinieran de una distribución normal conforme acumulamos más información.

Para cuantificar la precisión de estos estimadores, introducimos la matriz $I(\theta)$, la matriz de información de Fisher. Esta matriz actúa como una métrica de la cantidad de información que la trayectoria observada contiene sobre el parámetro θ [4, 53]. En el caso de los procesos de difusión, esta matriz se expresa como el valor esperado de la sensibilidad de la deriva respecto a la distribución estacionaria [4, 37]:

$$I(\theta) = \mathbb{E}_\theta \left(\frac{\dot{a}(X, \theta) \dot{a}^\top(X, \theta)}{b^2(X)} \right),$$

donde:

- X representa una variable aleatoria en el espacio de estados del proceso, distribuida según la medida estacionaria.
- $a(X, \theta)$ es el coeficiente de deriva (drifting) del modelo que depende de los datos X y del parámetro θ . Para mantener la consistencia con las derivadas que generan la matriz de información de nuestro modelo, definimos $a(X, \theta) = \alpha X + \beta$.
- $b(X)$ es el coeficiente de difusión del modelo, es decir, σX para nuestra EDE, de modo que $b^2(X) = \sigma^2 X^2$.
- $\dot{a}(X, \theta)$ es el vector gradiente de $a(X, \theta)$ con respecto a los parámetros α y β , dado por:

$$\dot{a}(X, \theta) = \nabla_\theta a(X, \theta) = \begin{pmatrix} \frac{\partial a(X, \theta)}{\partial \alpha} \\ \frac{\partial a(X, \theta)}{\partial \beta} \end{pmatrix}.$$

Al realizar el cálculo explícito de las derivadas parciales para nuestra función de deriva, obtenemos que $\frac{\partial}{\partial \alpha}(\alpha X + \beta) = X$ y $\frac{\partial}{\partial \beta}(\alpha X + \beta) = 1$. De esta forma, el vector gradiente que captura la sensibilidad del modelo es:

$$\dot{a}(X, \theta) = \begin{pmatrix} X \\ 1 \end{pmatrix}.$$

Esta forma de la matriz de información de Fisher surge al considerar la estructura de la log-verosimilitud bajo el modelo continuo [4], en la que las derivadas de $a(X, \theta)$ capturan qué tan sensible es la trayectoria del proceso ante cambios en α y β . Al promediar esta sensibilidad bajo la distribución estacionaria (tomando la esperanza), obtenemos una medida de la precisión promedio de esa sensibilidad a largo plazo.

Recuperando la definición de la matriz, procedemos a calcular el producto exterior del vector gradiente $\dot{a}(X, \theta) \dot{a}^\top(X, \theta)$:

$$\dot{a}(X, \theta) \dot{a}^\top(X, \theta) = \begin{pmatrix} X \\ 1 \end{pmatrix} \begin{pmatrix} X & 1 \end{pmatrix} = \begin{pmatrix} X \cdot X & X \cdot 1 \\ 1 \cdot X & 1 \cdot 1 \end{pmatrix} = \begin{pmatrix} X^2 & X \\ X & 1 \end{pmatrix}.$$

Al sustituir este resultado y la función de difusión $b^2(X) = \sigma^2 X^2$ en la definición original de la matriz de información de Fisher, obtenemos:

$$I(\theta) = \mathbb{E}_\theta \left[\frac{1}{\sigma^2 X^2} \begin{pmatrix} X^2 & X \\ X & 1 \end{pmatrix} \right].$$

Al introducir el escalar $\frac{1}{\sigma^2 X^2}$ dentro de la matriz, y simplificando término a término la dependencia de X , obtenemos:

$$I(\theta) = \mathbb{E}_\theta \left[\frac{1}{\sigma^2} \begin{pmatrix} \frac{X^2}{X^2} & \frac{X}{X^2} \\ \frac{X}{X^2} & \frac{1}{X^2} \end{pmatrix} \right] = \frac{1}{\sigma^2} \mathbb{E}_\theta \begin{pmatrix} 1 & \frac{1}{X} \\ \frac{1}{X} & \frac{1}{X^2} \end{pmatrix}.$$

Gracias a la linealidad del operador esperanza, podemos distribuirlo sobre cada uno de los elementos de la matriz de manera independiente:

$$I(\theta) = \frac{1}{\sigma^2} \begin{pmatrix} \mathbb{E}_\theta[1] & \mathbb{E}_\theta \left[\frac{1}{X} \right] \\ \mathbb{E}_\theta \left[\frac{1}{X} \right] & \mathbb{E}_\theta \left[\frac{1}{X^2} \right] \end{pmatrix}.$$

Para resolver estas esperanzas, recordamos lo demostrado en la sección de Distribución Estacionaria: la variable transformada $Y = \frac{1}{X}$ sigue una distribución Gamma $\Gamma(\lambda, \mu)$ con parámetros $\lambda = 1 - \frac{2\alpha}{\sigma^2}$ y $\mu = \frac{2\beta}{\sigma^2}$ [43]. Su densidad está dada por:

$$f(y) = \frac{\mu^\lambda}{\Gamma(\lambda)} y^{\lambda-1} e^{-\mu y}, \quad \text{para } y > 0.$$

Para encontrar las esperanzas requeridas en la matriz, calculamos los dos primeros momentos de Y . El primer momento es la esperanza de Y :

$$\mathbb{E}_\theta[Y] = \int_0^\infty y f(y) dy = \int_0^\infty y \frac{\mu^\lambda}{\Gamma(\lambda)} y^{\lambda-1} e^{-\mu y} dy = \frac{\lambda}{\mu} \int_0^\infty \frac{\mu^{\lambda+1}}{\Gamma(\lambda+1)} y^{(\lambda+1)-1} e^{-\mu y} dy.$$

Puesto que la integral corresponde a la densidad de una distribución $\Gamma(\lambda+1, \mu)$ sobre todo su dominio, su valor es 1, resultando en:

$$\mathbb{E}_\theta \left[\frac{1}{X} \right] = \mathbb{E}_\theta[Y] = \frac{\lambda}{\mu}.$$

De manera análoga, para el segundo momento (no central), evaluamos la integral de y^2 :

$$\mathbb{E}_\theta[Y^2] = \int_0^\infty y^2 f(y) dy = \int_0^\infty y^2 \frac{\mu^\lambda}{\Gamma(\lambda)} y^{\lambda-1} e^{-\mu y} dy = \int_0^\infty \frac{\mu^\lambda}{\Gamma(\lambda)} y^{\lambda+1} e^{-\mu y} dy.$$

Utilizando la propiedad recursiva de la función Gamma, $\Gamma(\lambda+2) = (\lambda+1)\lambda\Gamma(\lambda)$, multiplicamos y dividimos la expresión por μ^2 y por $\lambda(\lambda+1)$ para identificar nuevamente una densidad Gamma:

$$\mathbb{E}_\theta[Y^2] = \frac{\lambda(\lambda+1)}{\mu^2} \int_0^\infty \frac{\mu^{\lambda+2}}{\Gamma(\lambda+2)} y^{(\lambda+2)-1} e^{-\mu y} dy.$$

Como la integral corresponde a la densidad completa de una $\Gamma(\lambda+2, \mu)$, evalúa a 1, resultando en:

$$\mathbb{E}_\theta[Y^2] = \frac{\lambda(\lambda+1)}{\mu^2}.$$

Sustituyendo estos momentos en la matriz de información, concluimos que $I(\theta)$ toma la siguiente forma:

$$I(\theta) = \frac{1}{\sigma^2} \begin{pmatrix} 1 & \frac{\lambda}{\mu} \\ \frac{\lambda}{\mu} & \frac{\lambda(1+\lambda)}{\mu^2} \end{pmatrix}.$$

Para encontrar la matriz de covarianza asintótica $I^{-1}(\theta)$, necesaria para nuestras regiones de confianza, procedemos a invertir esta matriz. Primero calculamos el determinante de la matriz interna M :

$$\det(M) = (1) \left(\frac{\lambda(1+\lambda)}{\mu^2} \right) - \left(\frac{\lambda}{\mu} \right) \left(\frac{\lambda}{\mu} \right) = \frac{\lambda + \lambda^2}{\mu^2} - \frac{\lambda^2}{\mu^2} = \frac{\lambda}{\mu^2}.$$

Recordando que para una matriz $A = \begin{pmatrix} a & b \\ c & d \end{pmatrix}$, su inversa es $A^{-1} = \frac{1}{\det(A)} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}$. Además, por las propiedades de la inversa de una matriz multiplicada por un escalar, sabemos que $(cA)^{-1} = c^{-1}A^{-1}$. Aplicando esto a nuestra matriz con el escalar $c = \frac{1}{\sigma^2}$, el escalar de la inversa se convierte en σ^2 :

$$I^{-1}(\theta) = \sigma^2 \begin{pmatrix} \frac{\mu^2}{\lambda} & -\frac{\lambda}{\mu} \\ -\frac{\lambda}{\mu} & 1 \end{pmatrix}.$$

Distribuyendo el factor $\frac{\mu^2}{\lambda}$ dentro de la matriz, se simplifican los términos:

$$I^{-1}(\theta) = \sigma^2 \begin{pmatrix} \lambda + 1 & -\mu \\ -\mu & \frac{\mu^2}{\lambda} \end{pmatrix}. \quad (2.9)$$

De 2.8 tenemos que, cuando $T \rightarrow \infty$, el vector aleatorio bidimensional definido por la diferencia reescalada entre el estimador y el parámetro real, $\sqrt{T}(\hat{\theta} - \theta)$, se distribuye asintóticamente como una normal bivariada con media cero y matriz de covarianza $\Sigma = I^{-1}(\theta)$ [4, 37].

Con la matriz de covarianza asintótica en mano, podemos definir la geometría de nuestros errores. De la teoría de vectores aleatorios, sabemos que si un vector converge a una normal $Z \xrightarrow{d} \mathcal{N}_k(0, \Sigma)$, su forma cuadrática asociada (distancia de Mahalanobis), dada por $Q = Z^\top \Sigma^{-1} Z$, converge a una distribución chi-cuadrado con k grados de libertad, es decir, $Q \xrightarrow{d} \chi_k^2$ [59]. Aplicando esto a nuestro caso bidimensional ($k = 2$):

$$Z = \sqrt{T}(\hat{\theta} - \theta) \xrightarrow{d} \mathcal{N}_2(0, I^{-1}(\theta)).$$

Sustituyendo Z y la matriz de precisión $\Sigma^{-1} = I(\theta)$ en la forma cuadrática:

$$\left(\sqrt{T}(\hat{\theta} - \theta) \right)^\top \cdot I(\theta) \cdot \left(\sqrt{T}(\hat{\theta} - \theta) \right) \xrightarrow{d} \chi_2^2.$$

Desarrollando la transpuesta y agrupando los escalares T :

$$\left(\sqrt{T} \right)^2 (\hat{\theta} - \theta)^\top I(\theta) (\hat{\theta} - \theta) \xrightarrow{d} \chi_2^2,$$

lo cual nos lleva a:

$$T(\hat{\theta} - \theta)^\top I(\theta) (\hat{\theta} - \theta) \xrightarrow{d} \chi_2^2.$$

Dado que la forma cuadrática es simétrica respecto a sus argumentos, es matemáticamente equivalente escribir $(\theta - \hat{\theta})^\top I(\theta) (\theta - \hat{\theta})$. De ahí, deducimos que el estadístico, en el

límite asintótico, se acota dentro de una región que contiene a θ con probabilidad $1 - \gamma$ [59].

$$P \left[T(\theta - \hat{\theta})^\top I(\theta)(\theta - \hat{\theta}) \leq \chi_{2,1-\gamma}^2 \right] = 1 - \gamma.$$

En la práctica estadística, el parámetro verdadero θ que parametriza la matriz de información es desconocido. Apoyándonos en el Teorema de Slutsky [59] y la consistencia de $\hat{\theta}$, reemplazamos los parámetros teóricos en $I(\theta)$ por sus respectivos estimadores, obteniendo la matriz de información estimada $\hat{I}(\hat{\theta})$. Así, establecemos la siguiente probabilidad asintótica:

$$P \left[T(\theta - \hat{\theta})^\top \hat{I}(\hat{\theta})(\theta - \hat{\theta}) \leq \chi_{2,1-\gamma}^2 \right] \approx 1 - \gamma.$$

Por lo tanto, la región de confianza asintótica simultánea para $\theta = (\alpha, \beta)^\top$ está dada, para una longitud de trayectoria T suficientemente grande, por el conjunto:

$$\left\{ \theta \in \mathbb{R}^2 : T(\theta - \hat{\theta})^\top \hat{I}(\hat{\theta})(\theta - \hat{\theta}) \leq \chi_{2,1-\gamma}^2 \right\},$$

donde $\hat{I}(\hat{\theta})$ es la matriz de información evaluada en los estimadores $\hat{\alpha}$ y $\hat{\beta}$, y $\chi_{2,1-\gamma}^2$ representa el cuantil de orden $1 - \gamma$ de la distribución chi-cuadrado con 2 grados de libertad.

Geoméricamente, esta expresión define una elipse de confianza en el plano de los parámetros (α, β) . Esta región, centrada en el estimador puntual $\hat{\theta}$, contiene al valor verdadero de los parámetros con una confianza asintótica de $1 - \gamma$, proporcionando una herramienta visual y estadística poderosa para validar la precisión de nuestra calibración del modelo de Brennan-Schwartz [4].

2.2.4. Intervalos de confianza marginales asintóticos

Una vez establecida la normalidad asintótica conjunta para el vector de parámetros θ , el interés práctico suele centrarse en obtener medidas de precisión individuales para cada uno de sus componentes, α y β . Mientras que la elipse de confianza analizada anteriormente nos habla de la incertidumbre compartida, los intervalos de confianza marginales nos permiten aislar el error de cada parámetro por separado. Estos se derivan directamente de las propiedades de la distribución normal multivariada, que nos asegura que las distribuciones marginales de un vector normal son, a su vez, normales [59].

A partir del resultado principal [4, 37]:

$$\sqrt{T}(\hat{\theta} - \theta) \xrightarrow{d} \mathcal{N}_2(0, I^{-1}(\theta)),$$

sabemos que cualquier componente i -ésima del vector $\sqrt{T}(\hat{\theta} - \theta)$ converge en distribución a una normal univariada cuya varianza es el elemento ii de la matriz de covarianza asintótica [59]. Recuperando la matriz de precisión inversa obtenida en (2.9):

$$I^{-1}(\theta) = \sigma^2 \begin{pmatrix} \lambda + 1 & -\mu \\ -\mu & \frac{\mu^2}{\lambda} \end{pmatrix},$$

donde las constantes dependen de los parámetros del modelo mediante $\lambda = 1 - \frac{2\alpha}{\sigma^2}$ y $\mu = \frac{2\beta}{\sigma^2}$. Designamos como $\Sigma_{11} = \sigma^2(\lambda + 1)$ y $\Sigma_{22} = \sigma^2 \frac{\mu^2}{\lambda}$ a las varianzas asintóticas de los componentes. Por lo tanto, para cada estimador de forma individual, se cumple que [4]:

$$\sqrt{T}(\hat{\alpha} - \alpha) \xrightarrow{d} \mathcal{N}(0, \sigma^2(\lambda + 1)), \quad \sqrt{T}(\hat{\beta} - \beta) \xrightarrow{d} \mathcal{N}\left(0, \frac{\sigma^2 \mu^2}{\lambda}\right).$$

Para construir los intervalos, procedemos a estandarizar estas variables aleatorias [16]. Recordemos que si una variable aleatoria W converge a una normal $\mathcal{N}(0, V)$, entonces la variable estandarizada $\frac{W}{\sqrt{V}}$ converge a una normal estándar $\mathcal{N}(0, 1)$ [10, 59].

Aplicando este principio al estimador de α , dividimos la variable original entre la raíz cuadrada de su varianza asintótica:

$$\frac{\sqrt{T}(\hat{\alpha} - \alpha)}{\sqrt{\sigma^2(\lambda + 1)}} \xrightarrow{d} \mathcal{N}(0, 1).$$

Desarrollando la raíz en el denominador obtenemos $\sigma\sqrt{\lambda + 1}$. Por propiedades algebraicas de las fracciones, multiplicar por el numerador $\sqrt{T}$ es equivalente a dividir el denominador entre $\sqrt{T}$, lo cual nos permite reescribir el estadístico de prueba Z_α de una forma más intuitiva, donde el denominador representa el error estándar del estimador:

$$Z_\alpha = \frac{\sqrt{T}(\hat{\alpha} - \alpha)}{\sigma\sqrt{\lambda + 1}} = \frac{\hat{\alpha} - \alpha}{\frac{\sigma\sqrt{\lambda+1}}{\sqrt{T}}} = \frac{\hat{\alpha} - \alpha}{\sigma\sqrt{\frac{\lambda+1}{T}}} \xrightarrow{d} \mathcal{N}(0, 1).$$

Siguiendo un procedimiento completamente análogo para el estimador de β , dividimos entre la raíz cuadrada de su varianza asintótica:

$$\frac{\sqrt{T}(\hat{\beta} - \beta)}{\sqrt{\frac{\sigma^2 \mu^2}{\lambda}}} \xrightarrow{d} \mathcal{N}(0, 1).$$

Extrayendo las constantes σ y μ de la raíz del denominador y bajando el factor $\sqrt{T}$, definimos el estadístico de prueba Z_β :

$$Z_\beta = \frac{\sqrt{T}(\hat{\beta} - \beta)}{\sigma\mu\sqrt{\frac{1}{\lambda}}} = \frac{\hat{\beta} - \beta}{\frac{\sigma\mu}{\sqrt{\lambda}} \cdot \frac{1}{\sqrt{T}}} = \frac{\hat{\beta} - \beta}{\sigma\mu\sqrt{\frac{1}{\lambda T}}} \xrightarrow{d} \mathcal{N}(0, 1).$$

Dado que para una variable Z con distribución normal estándar, la probabilidad de encontrarse dentro de los límites de un valor crítico ξ_γ es [16, 59]:

$$P(-\xi_\gamma \leq Z \leq \xi_\gamma) = 1 - \gamma,$$

donde ξ_γ es el percentil $1 - \gamma/2$ de la distribución $\mathcal{N}(0, 1)$ (por ejemplo, 1.96 para un nivel de confianza del 95 %), podemos plantear las desigualdades para nuestros parámetros [16]:

$$P\left(\left|\frac{\hat{\alpha} - \alpha}{\sigma\sqrt{\frac{\lambda+1}{T}}}\right| \leq \xi_\gamma\right) = 1 - \gamma, \quad P\left(\left|\frac{\hat{\beta} - \beta}{\sigma\mu\sqrt{\frac{1}{\lambda T}}}\right| \leq \xi_\gamma\right) = 1 - \gamma.$$

Partiendo de la probabilidad de que el estadístico estandarizado se encuentre dentro de los cuantiles de la normal estándar:

$$P\left(\left|\frac{\hat{\alpha} - \alpha}{\sigma\sqrt{\frac{\lambda+1}{T}}}\right| \leq \xi_\gamma\right) = 1 - \gamma.$$

Nos enfocamos en la desigualdad dentro de la probabilidad. Por definición del valor absoluto, la desigualdad se puede reescribir desdoblándola en dos límites [16]:

$$-\xi_\gamma \leq \frac{\hat{\alpha} - \alpha}{\sigma \sqrt{\frac{\lambda+1}{T}}} \leq \xi_\gamma.$$

Dado que la desviación estándar asintótica en el denominador es estrictamente positiva, podemos multiplicar todas las partes de la desigualdad por el término $\sigma \sqrt{\frac{\lambda+1}{T}}$ sin alterar el sentido de las desigualdades:

$$-\xi_\gamma \sigma \sqrt{\frac{\lambda+1}{T}} \leq \hat{\alpha} - \alpha \leq \xi_\gamma \sigma \sqrt{\frac{\lambda+1}{T}}.$$

El objetivo es aislar el parámetro verdadero α en el centro. Para ello, restamos el estimador $\hat{\alpha}$ en los tres miembros de la desigualdad:

$$-\hat{\alpha} - \xi_\gamma \sigma \sqrt{\frac{\lambda+1}{T}} \leq -\alpha \leq -\hat{\alpha} + \xi_\gamma \sigma \sqrt{\frac{\lambda+1}{T}}.$$

Para eliminar el signo negativo de α , multiplicamos toda la expresión por -1 . Al hacer esto, recordando las propiedades de las desigualdades, los símbolos de dirección se invierten ($\leq$ cambia a $\geq$):

$$\hat{\alpha} + \xi_\gamma \sigma \sqrt{\frac{\lambda+1}{T}} \geq \alpha \geq \hat{\alpha} - \xi_\gamma \sigma \sqrt{\frac{\lambda+1}{T}}.$$

Reordenando la expresión para leerla convencionalmente de menor a mayor (de izquierda a derecha), obtenemos:

$$\hat{\alpha} - \xi_\gamma \sigma \sqrt{\frac{\lambda+1}{T}} \leq \alpha \leq \hat{\alpha} + \xi_\gamma \sigma \sqrt{\frac{\lambda+1}{T}}.$$

Finalmente, reincorporando esta desigualdad resuelta dentro del operador de probabilidad y expresándola en notación de conjuntos, llegamos a la forma del intervalo de confianza para el parámetro α :

$$P \left(\alpha \in \left[\hat{\alpha} - \xi_\gamma \sigma \sqrt{\frac{\lambda+1}{T}}, \quad \hat{\alpha} + \xi_\gamma \sigma \sqrt{\frac{\lambda+1}{T}} \right] \right) = 1 - \gamma.$$

De forma análoga, para el parámetro β , partimos de la probabilidad de su error estandarizado:

$$P \left(\left| \frac{\hat{\beta} - \beta}{\sigma \mu \sqrt{\frac{1}{\lambda T}}} \right| \leq \xi_\gamma \right) = 1 - \gamma.$$

Aplicando la misma secuencia de despejes algebraicos (desdoblamiento de la desigualdad del valor absoluto, multiplicación por la desviación estándar asintótica e inversión de signos), se llega a la expresión del intervalo de confianza marginal para β :

$$P \left(\beta \in \left[\hat{\beta} - \xi_\gamma \sigma \mu \sqrt{\frac{1}{\lambda T}}, \quad \hat{\beta} + \xi_\gamma \sigma \mu \sqrt{\frac{1}{\lambda T}} \right] \right) = 1 - \gamma.$$

Es fundamental notar que, en la realidad, los parámetros poblacionales λ y μ son desconocidos. Para solventar esto, invocamos nuevamente el Teorema de Slutsky [51]. Al ser $\hat{\alpha}$ y $\hat{\beta}$ estimadores consistentes, podemos sustituirlos en las expresiones de la varianza sin perder la validez asintótica de los intervalos [4]. Definimos entonces los estimadores de los parámetros auxiliares como:

$$\hat{\lambda} = 1 - \frac{2\hat{\alpha}}{\sigma^2}, \quad \hat{\mu} = \frac{2\hat{\beta}}{\sigma^2}.$$

Este análisis asume que el parámetro de difusión σ es conocido o ha sido estimado previamente de forma consistente (por ejemplo, mediante el método de momentos analizado en secciones anteriores) [43], permitiendo cerrar de manera robusta el sistema de inferencia para el modelo de Brennan-Schwartz.

Respecto a las propiedades en muestras finitas, es pertinente señalar que los estimadores de máxima verosimilitud en procesos de difusión con reversión a la media suelen presentar sesgo cuando el horizonte temporal T es moderado o pequeño [54]. En particular, los estimadores $\hat{\alpha}$ y $\hat{\beta}$ no son estrictamente insesgados en tiempo finito, mostrando una tendencia a sobreestimar la velocidad de reversión hacia la media.

No obstante, bajo condiciones de regularidad y ergodicidad, ambos estimadores son consistentes y asintóticamente normales cuando el horizonte temporal se expande ($T \rightarrow \infty$), convergiendo en probabilidad hacia los valores verdaderos de los parámetros.

Por otro lado, el estimador del parámetro de difusión $\hat{\sigma}$ presenta un comportamiento estadístico fundamentalmente distinto. A diferencia de los estimadores de deriva, la estimación de la volatilidad basada en la variación cuadrática es insesgada, incluso si el horizonte temporal T es corto. Esto ocurre porque su consistencia no depende de observar el proceso durante muchos años, sino de la resolución o densidad temporal de los datos. Es decir, la precisión de $\hat{\sigma}$ mejora al aumentar la frecuencia de observación dentro de un mismo intervalo (*infill asymptotics*, donde $\Delta t \rightarrow 0$) [1]. En este contexto, basta con tener una muestra discretizada lo suficientemente fina para que la suma de los incrementos al cuadrado aísle las fluctuaciones instantáneas de manera cada vez más precisa, proporcionando así un estimador consistente, con un sesgo despreciable en muestras finas y robusto para la volatilidad del proceso.

2.2.5. Estimación de parámetros a partir de simulaciones

Una vez construida la estructura teórica que sustenta la obtención de los estimadores de máxima verosimilitud para la deriva y el estimador basado en variación cuadrática para la volatilidad, hay que trasladar estas fórmulas al terreno de la computación para validar su comportamiento en un entorno controlado. Este paso funciona como un escenario de laboratorio numérico donde, al conocer de antemano los parámetros reales que generan la dinámica del proceso, podemos medir con total objetividad qué tan precisas son nuestras herramientas de inferencia.

Para este experimento de validación, se diseñó un protocolo de simulación Monte Carlo consistente en la generación de 1,000 trayectorias independientes del modelo de Brennan-Schwartz, utilizando para ello el esquema de discretización de Milstein que, como se demostró anteriormente, ofrece una fidelidad superior en la aproximación de trayectorias individuales. La configuración del experimento se fijó con los parámetros base $\alpha = -0,5$, $\beta = 1$ y $\sigma = 0,3$, partiendo de una condición inicial $x_0 = 1$ y extendiendo la observación sobre un horizonte temporal extenso de $T = 100$ años, una decisión metodológica crucial

para mitigar el sesgo de estimación en los parámetros de deriva, con una resolución de $N = 10,000$ pasos de tiempo, lo que equivale a un incremento discreto $\Delta t = 0,01$.

La implementación computacional de este proceso de recuperación de parámetros, al igual que todo el código de el trabajo, se realizó en el lenguaje R, integrando en una sola función lógica tanto el cálculo de las integrales estocásticas aproximadas por sumas de Riemann como el despeje de los estimadores analíticos derivados en las secciones previas. En la programación de esta función, se incluyó una salvaguarda numérica para evitar la división por cero en caso de que el proceso se aproxime excesivamente al origen, garantizando así la estabilidad del algoritmo durante las mil repeticiones del experimento. El bloque de código que encapsula esta lógica de estimación conjunta se presenta en el apéndice.

Al procesar las mil trayectorias bajo este esquema de estimación, en el cual el algoritmo debe deducir los parámetros basándose exclusivamente en la información contenida en las trayectorias simuladas, se obtuvieron las distribuciones muestrales que se presentan en la figura 2.7. En dichos histogramas, la línea roja continua marca el valor real de los parámetros, mientras que la línea negra punteada señala el promedio obtenido por el estimador tras la totalidad de las simulaciones.

Los resultados visualizados en la Figura 2.7 confirman el buen desempeño general del esquema de estimación, aunque hay que identificar matices estadísticos importantes. Primero, el parámetro de difusión $\hat{\sigma}$ muestra una precisión excepcional, con una distribución estrecha y centrada casi perfectamente en el valor real de 0,3. En contraste, las distribuciones de los parámetros de deriva, $\hat{\alpha}$ y $\hat{\beta}$, si bien exhiben la morfología gaussiana predicha por la normalidad asintótica, presentan un ligero pero perceptible desplazamiento sistemático respecto a sus valores teóricos.

Específicamente, el promedio de las estimaciones de α se sitúa a la izquierda del valor real, lo que indica una tendencia a sobreestimar la magnitud de la velocidad de reversión a la media. Por su parte, el estimador de β muestra un desplazamiento hacia la derecha, situando el nivel de equilibrio ligeramente por encima del valor real. Este comportamiento es una evidencia empírica del sesgo de estimación en tiempo finito, fenómeno presente en modelos de difusión con reversión a la media [54, 28]. Este resultado remarca que, mientras la volatilidad se beneficia de la alta frecuencia de observación (*infill asymptotics*), la deriva requiere de horizontes temporales más grandes para disipar el sesgo inducido por el ruido estocástico sobre la tendencia. A pesar del sesgo, la forma normal de las distribuciones obtenidas justifica el uso de la matriz de Fisher para medir la precisión de los parámetros, siempre que el proceso sea estable en el tiempo.




Figura 2.7: Distribuciones de los estimadores $\hat{\alpha}$, $\hat{\beta}$ y $\hat{\sigma}$ sobre 1000 trayectorias simuladas con $T = 100$ y $N = 10000$.

Para profundizar en el análisis de estos resultados, se calcularon las métricas de sesgo, desviación estándar y error estándar para cada parámetro, las cuales se detallan en la tabla 2.3. Estas cifras permiten cuantificar la eficiencia de la inferencia realizada y sirven como prueba de la consistencia de los estimadores desarrollados.

Parámetro	Valor real	Media muestral	Sesgo	Desv. estándar	Error estándar
α	-0,5	-0,54196	-0,04196	0,11485	0,00363
β	1,0	1,07758	0,07758	0,20277	0,00641
σ	0,3	0,30054	0,00054	0,00209	0,00007

Cuadro 2.3: Resumen estadístico de los estimadores obtenidos a partir de 1000 trayectorias simuladas.

Resulta fundamental contrastar la dispersión observada en el experimento con las predicciones de precisión derivadas en la sección 2.2.4. A partir de los parámetros de simulación ($\alpha = -0,5$, $\beta = 1$, $\sigma = 0,3$), calculamos los parámetros auxiliares:

$$\lambda = 1 - \frac{2\alpha}{\sigma^2} = 1 - \frac{2(-0,5)}{0,09} \approx 12,1111, \quad \mu = \frac{2\beta}{\sigma^2} = \frac{2(1)}{0,09} \approx 22,2222.$$

Al aplicar las fórmulas de la varianza asintótica divididas por el horizonte $T = 100$, obtenemos las desviaciones estándar teóricas:

$$SD_\alpha = \sqrt{\frac{\sigma^2(\lambda + 1)}{T}} = \sqrt{\frac{0,09(13,1111)}{100}} \approx 0,10867,$$

$$SD_\beta = \sqrt{\frac{\sigma^2\mu^2}{\lambda T}} = \sqrt{\frac{0,09(493,8271)}{12,1111(100)}} \approx 0,19156.$$

Para la volatilidad, usando la asintótica de variación cuadrática, se tiene:

$$SD_\sigma = \frac{\sigma}{\sqrt{2N}} = \frac{0,3}{\sqrt{20,000}} \approx 0,00212.$$

Al comparar estas cifras con la columna de Desviación Estándar Muestral de la tabla anterior, se observa una concordancia casi exacta (por ejemplo, 0,114 muestral vs 0,108 teórico para α), lo que ratifica que las fórmulas de los intervalos de confianza marginales derivadas en (2.9) son representaciones fieles de la incertidumbre del modelo. Por otro lado, la columna de Error Estándar representa el error de Monte Carlo ($SE = SD/\sqrt{1000}$), el cual cuantifica la precisión del promedio de nuestro experimento [25]. Al obtener valores del orden de 10^{-3} para la deriva y de 10^{-5} para la difusión, se garantiza que el sesgo reportado es estadísticamente significativo y no un artefacto del azar, confirmando que el experimento de validación ha convergido satisfactoriamente.

Los resultados obtenidos permiten extraer conclusiones fundamentales sobre la naturaleza de la inferencia en procesos estocásticos. El estimador de la volatilidad σ es extraordinariamente preciso, presentando un sesgo residual de apenas 0,00054, lo cual es consistente con la teoría que establece que la volatilidad es una propiedad recuperable mediante la asintótica de tipo infill [1, 31], es decir, aumentando la frecuencia de observación en un periodo dado. Sin embargo, el aspecto más relevante de este análisis es el desempeño de los estimadores de deriva α y β , los cuales presentan sesgos de $-0,04196$ y $0,07758$, respectivamente. Esta precisión se debe directamente a la elección de un horizonte temporal extenso de $T = 100$ [45].

Es pertinente explicar que si hubiésemos optado por un horizonte temporal más corto, como un $T = 10$, y una menor densidad de pasos N , el sesgo estadístico en la deriva habría sido considerablemente mayor [54]. Esto ocurre porque la inferencia sobre la tendencia en modelos de reversión a la media depende de la asintótica de largo plazo (long-span asymptotics) [37], el estimador requiere observar al proceso regresar a su media múltiples veces para distinguir la fuerza de atracción de la deriva frente al ruido estocástico de corto plazo [53]. Por lo tanto, el uso de $T = 100$ permite que la información acumulada sea suficiente para que el estimador conjunto sea funcional y estadísticamente consistente. La ligera persistencia de sesgo en los parámetros de deriva puede atribuirse a la estructura no lineal de las integrales de $1/X_t$ y $1/X_t^2$ que, en regiones cercanas al origen, pueden amplificar pequeñas discrepancias numéricas. No obstante, la cercanía de las medias muestrales a los valores reales y la magnitud reducida de los errores estándar validan la robustez de nuestra metodología, proporcionando el sustento necesario para aplicar estos mismos criterios de estimación a series de tiempo de tasas de interés reales con un alto grado de confianza [4].

En conclusión, el ejercicio de validación numérica permite confirmar que el sistema de estimación propuesto es robusto y teóricamente coherente, pues al emplear un horizonte temporal amplio y una discretización fina, los estimadores logran vencer la incertidumbre

estocástica y recuperar los parámetros originales con un margen de error mínimo. Además, la magnitud reducida de los errores y su estricta concordancia con la matriz de varianza-covarianza asintótica validan la robustez de la metodología propuesta.

Este resultado es fundamental para el desarrollo de esta tesis, ya que transforma las fórmulas de inferencia en herramientas validadas y confiables, despejando el camino para que el análisis de tasas de interés reales no sea solo una exploración empírica, sino una aplicación rigurosa de los principios de la estadística de procesos de difusión.

Sin embargo, esta robustez depende críticamente de la alta frecuencia de observación, en la siguiente sección se explorará cómo esta precisión se colapsa ante la escasez de datos o muestreos discretos espaciados, fenómeno que motiva la necesidad de transitar hacia un enfoque Bayesiano asistido por técnicas de aumento de datos [4, 22, 48].

Capítulo 3

Metodología Bayesiana y Aumento de Datos

3.1. El Sesgo de Discretización y el Problema de Datos Faltantes.

Tras haber consolidado en los capítulos anteriores tanto la formulación analítica del modelo de Brennan-Schwartz como la eficacia de los métodos de estimación en entornos controlados, es necesario confrontar estos resultados con las limitaciones en la práctica.

Hasta este punto, el desarrollo de la investigación ha transcurrido bajo la premisa de que el tiempo es un flujo continuo y que, por lo tanto, las Ecuaciones Diferenciales Estocásticas pueden resolverse o simularse con una precisión arbitrariamente alta. Sin embargo, al trasladar el modelo del laboratorio numérico hacia el análisis de entornos reales, nos encontramos con una desconexión fundamental entre la elegancia de la teoría continua y la aspereza de la información fragmentada, donde los datos no fluyen de manera ininterrumpida, sino que se presentan como una sucesión de instantes discretos, a menudo separados por intervalos que distan mucho de ser infinitesimales [1, 53].

3.1.1. La brecha entre la teoría continua y la observación discreta

El modelado de tasas de interés encuentra su cimiento en los procesos de difusión, los cuales asumen que somos capaces de capturar la dinámica de la variable X_t en cada instante de su evolución [12, 20, 60]. El modelo de Brennan-Schwartz describe esta trayectoria mediante una estructura que presupone cambios infinitesimales impulsados por una tendencia determinista y una volatilidad estocástica.

No obstante, surge una discrepancia crítica cuando intentamos aplicar estas construcciones ideales a la realidad empírica, ya que existe una desconexión fundamental entre la continuidad que exige la teoría y la intermitencia que ofrece la práctica [1]. Mientras que los modelos asumen una observación continua o de muy alta frecuencia ($\Delta t \rightarrow 0$), los datos reales a menudo presentan problemas de datos faltantes o son observados en intervalos discretos amplios (es decir, hay baja frecuencia en los datos), lo cual representa un reto no solo para la matemática financiera, sino para cualquier disciplina que emplee difusiones para modelar la naturaleza [5, 53, 48].

Esta escasez de información, que se manifiesta como observaciones en intervalos discre-

tos amplios o directamente como datos faltantes, es un problema transversal en la ciencia aplicada [48, 53, 5]. En el ámbito de la ingeniería, por ejemplo, los sensores encargados de monitorear un proceso físico pueden presentar periodos de inactividad debido a fallos técnicos o limitaciones energéticas, mientras que en la biología experimental, las mediciones de crecimiento celular suelen estar condicionadas por los ciclos de laboratorio, lo que impide observar la dinámica estocástica en su totalidad [48, 53]. Incluso en las ciencias ambientales, factores climáticos extremos pueden dañar las estaciones de registro, generando huecos en las series de tiempo que ocultan la verdadera volatilidad del sistema.

Específicamente en el ámbito financiero, esta problemática se agrava debido a que la falta de información responde a la estructura misma del sistema de mercados [22]. Los fines de semana, los días festivos, los cierres inesperados por volatilidad extrema o los fallos en los sistemas de registro de las instituciones generan interrupciones que fragmentan la trayectoria del proceso [32]. También existen otras limitaciones en la estructura del sistema financiero, como sucede con ciertos indicadores macroeconómicos fundamentales que solo se publican de forma mensual o trimestral, ocultando todas las fluctuaciones que ocurren en el corto plazo.

Para un modelo como el de Brennan-Schwartz, que requiere de la observación de la trayectoria completa para identificar correctamente la volatilidad y la fuerza restauradora de la deriva, cada uno de estos silencios informativos representa una pérdida de la memoria instantánea del proceso. Al ignorar lo que sucede entre dos puntos observados, la inferencia tradicional colapsa, ya que asume erróneamente que no hubo actividad estocástica relevante en los intervalos donde no hubo registro, comprometiendo así la precisión de cualquier medida de riesgo o predicción futura [22, 48].

3.1.2. Sesgo de discretización

La verdadera gravedad de ignorar estos intervalos de silencio informativo reside en el denominado sesgo de discretización [4, 36]. Los métodos de estimación desarrollados en el Capítulo 2, como la Máxima Verosimilitud, descansan sobre la suposición de que el intervalo entre observaciones es lo suficientemente pequeño como para que una aproximación lineal de la trayectoria sea válida. Sin embargo, cuando la distancia temporal entre dos puntos aumenta, la suposición de que la integral del proceso puede aproximarse mediante una suma simple, dada por $\int X_s ds \approx \sum X_i \Delta t$, se vuelve matemáticamente errónea [2, 31].

Este error de aproximación tiene consecuencias directas sobre la recuperación de los parámetros estructurales. Al incrementar el valor de Δt , la discretización lineal ignora toda la variabilidad y las fluctuaciones estocásticas que ocurrieron dentro del intervalo no observado, lo que provoca que el modelo perciba una trayectoria artificialmente suavizada [22, 31].

Para el parámetro de volatilidad σ , esto suele traducirse en un sesgo catastrófico, ya que el estimador es incapaz de contabilizar los “brincos” que la tasa dio entre una observación y otra, lo que conduce a una mala interpretación del riesgo real [2, 41]. De igual manera, la velocidad de reversión a la media, gobernada por α , se distorsiona al no captar la fuerza restauradora en los instantes latentes [53, 54]. En última instancia, ignorar la discretización equivale a pretender que el proceso estocástico se detuvo mientras no estábamos mirando, una premisa inaceptable en el contexto de la matemática aplicada.

3.1.3. Inferencia Bayesiana y Aumento de Datos

Ante este escenario de información incompleta, el presente capítulo tiene un propósito doble. En primera instancia, se busca demostrar que los métodos de estimación convencionales (Máxima Verosimilitud y Variación Cuadrática, métodos que pertenecen a la escuela frecuentista o clásica y fueron desarrollados en el capítulo 2), a los que denominaremos métodos ingenuos o Naive, son insuficientes para capturar la complejidad del modelo Brennan-Schwartz cuando los datos son escasos o irregulares [22, 48]. Una vez establecida esta limitación, el capítulo se enfoca en el desarrollo de una solución robusta para este problema.

No podemos conformarnos con una interpolación lineal que simplemente rellene los huecos con líneas rectas, ya que esto eliminaría la naturaleza estocástica que define al modelo de Brennan-Schwartz [22, 48]. En su lugar, se propone el uso de la Inferencia Bayesiana con Aumento de Datos (Data Augmentation), una metodología que representa un cambio de paradigma al tratar los datos faltantes no como información perdida, sino como variables latentes que poseen su propia distribución de probabilidad [5, 56].

A lo largo de las siguientes secciones, se formalizará el uso de la transformación de Lamperti para obtener una volatilidad unitaria [29] y se derivará una función de verosimilitud aumentada en forma exponencial. Este andamiaje matemático permitirá implementar un esquema iterativo de Cadenas de Markov con Monte Carlo (MCMC), específicamente un muestreador de Gibbs que incorpora un paso de Metropolis-Hastings para la volatilidad [4, 24]. Este enfoque no solo permite reconstruir probabilísticamente las trayectorias ocultas mediante Puentes de difusión, sino que recupera los parámetros estructurales incorporando la incertidumbre inherente a los silencios informativos, logrando una precisión que los métodos tradicionales, limitados por la observación discreta, no pueden alcanzar [22, 48].

Este enfoque será validado en los siguientes capítulos, primero mediante un entorno controlado de simulación bajo el esquema de Milstein, demostrando cómo se corrige el sesgo ante la pérdida sistemática de información, para finalmente aplicarse a la serie histórica de los Cetes a 28 días en el mercado mexicano [4, 7]. El análisis de este periodo, que abarca de 2023 a 2025, buscará evidenciar que el enfoque bayesiano logra capturar la verdadera estructura de riesgo de nuestra economía con una precisión que los métodos tradicionales, limitados por la observación discreta, no pueden alcanzar [5, 22, 43].

3.2. Simulación de Escasez de Datos y Evaluación del Error.

Tras haber fundamentado la necesidad teórica de un enfoque más robusto, es imperativo cuantificar la magnitud del error al que se enfrenta un analista cuando utiliza métodos convencionales ante información fragmentada. Para ello, se diseñó un experimento controlado en nuestro “laboratorio numérico”, donde generamos una trayectoria sintética que será considerada la trayectoria latente verdadera para efectos experimentales contra la cual compararemos el desempeño de los estimadores.

En los capítulos anteriores se utilizaron horizontes temporales extensos ($T = 100$) y densidades de muestreo masivas ($N = 10,001$) con el objetivo de validar la consistencia asintótica de los estimadores de Brennan-Schwartz. Sin embargo, para los fines de este capítulo, hemos decidido migrar hacia un escenario de escala humana o “terrenal”. En la práctica financiera, es poco común contar con series de tiempo de tasas de interés que

mantengan propiedades estructurales constantes durante un siglo. Por ello, ajustaremos nuestra simulación a una ventana de observación de una década, lo cual representa un reto mayor para la convergencia de los parámetros y refleja de forma más fiel las limitaciones de un analista real.

3.2.1. El Esquema de Milstein como Verdad del Proceso

Para discretizar el proceso continuo dado por la EDE (1.1) minimizando el error de aproximación, se utilizó el esquema de integración numérica de Milstein. Como vimos en el capítulo 1, a diferencia del método de Euler-Maruyama, Milstein incorpora un término de corrección de segundo orden derivado del lema de Itô, lo que mejora significativamente la convergencia fuerte del modelo.

La simulación se configuró con los parámetros reales $\alpha = -0,5$, $\beta = 1,0$ y $\sigma = 0,3$. El horizonte temporal se fijó en $T = 10$, con una resolución de $n = 3,650$ pasos, lo que equivale a una frecuencia de registro diaria durante diez años. Esto genera un paso de tiempo de $\Delta t \approx 0,0027$, suficiente para considerar esta trayectoria como el “continuo” o la realidad oculta del mercado.




Figura 3.1: Trayectoria completa simulada mediante el esquema de Milstein. Esta serie representa la “verdad” del proceso estocástico con información perfecta.

Esta serie de alta frecuencia 3.1 representa la evolución teórica real de la tasa con información perfecta. Al aplicar el estimador conjunto desarrollado en el capítulo previo sobre esta trayectoria completa, los resultados confirman una recuperación casi exacta de los parámetros, validando la precisión de nuestra herramienta en condiciones ideales:

Parámetro	Valor Real	Valor Estimado (Base)	Diferencia Absoluta
Alpha (α)	-0,5	-0,46465	0,0353529
Beta (β)	1,0	1,01321	0,0132070
Sigma (σ)	0,3	0,30780	0,0077968

Cuadro 3.1: Resultados de estimación sobre la trayectoria base de alta frecuencia ($N = 3650$).

3.2.2. Reducción de Datos y El Fenómeno del Submuestreo

Para replicar la problemática de baja frecuencia que caracteriza a los mercados financieros reales, se aplicó un proceso de submuestreo sistemático a la trayectoria original. Se definió un factor de recorte $k = 15$, lo que simula una transición de una captura de datos diaria a una frecuencia aproximadamente bisemanal. Esta operación reduce el tamaño de la muestra de 3,651 a solo 244 puntos observados, aumentando el paso de tiempo efectivo de $\Delta t \approx 0,0027$ a un $\Delta t_{nuevo} \approx 0,041$.




Figura 3.2: Comparativa de Pérdida de Información. La línea azul muestra la trayectoria real continua, mientras que los puntos rojos representan los datos observados tras el proceso de submuestreo.

El impacto visual de este recorte se aprecia en la Figura 3.2. Aunque una densidad de 244 puntos podría parecer suficiente a simple vista, la línea azul revela que se ignora una cantidad masiva de variación cuadrática intra-período. Los saltos entre los puntos rojos suavizan artificialmente la trayectoria, ocultando las micro-fluctuaciones que definen la verdadera textura estocástica del sistema y que son fundamentales para una estimación precisa de la volatilidad [5, 2].

Al someter esta serie submuestreada al método de estimación convencional de Brennan-Schwartz, los resultados evidencian una degradación significativa en la fidelidad de los parámetros recuperados.

Parámetro	Valor Real	Estimado ($k = 15$)	Diferencia Absoluta
Alpha (α)	-0,5	-0,1401	0,3599
Beta (β)	1,0	0,6704	0,3296
Sigma (σ)	0,3	0,4593	0,1593

Cuadro 3.2: Resultados de la estimación clásica sobre la serie recortada.

Como se evidencia en la Tabla 3.2, el estimador clásico incurre en errores que desvirtúan la naturaleza económica del modelo. En este experimento, el estimador produce una sobreestimación de la volatilidad de aproximadamente 53 % (pasando de 0,3 a 0,4593). Esto ocurre porque el estimador interpreta los saltos de baja frecuencia como una varianza mayor a la real, al no poder observar el ruido de alta frecuencia que compensa el movimiento en el corto plazo [2].

Sin embargo, el hallazgo más preocupante radica en el parámetro α . El valor estimado (-0,1401) es considerablemente más cercano a cero que el valor real (-0,5). Desde una perspectiva financiera, esto implica una subestimación drástica de la velocidad de reversión a la media [53, 54]. El modelo resultante sugeriría que las tasas de interés son mucho más persistentes de lo que realmente son, comportándose casi como un paseo aleatorio con una deriva débil.

Este fenómeno demuestra que, ante la escasez de datos, el método tradicional pierde la capacidad de distinguir entre la tendencia de largo plazo y el ruido acumulado. La incapacidad de capturar la fuerza con la que el proceso regresa a su nivel de equilibrio justifica la implementación del enfoque de Data Augmentation que se desarrollará en las siguientes secciones, con el fin de reconstruir la trayectoria latente y restaurar el rigor estadístico de la inferencia [22, 48].

3.3. Introducción a la Inferencia Bayesiana en EDEs

Nuevamente partimos del proceso $\{X_t\}_{t \geq 0}$ solución de la EDE de Brennan-Schwartz con difusión proporcional al estado:

$$dX_t = (\alpha X_t + \beta) dt + \sigma X_t dW_t,$$

donde los parámetros de deriva son $\alpha, \beta \in \mathbb{R}$ y el parámetro de difusión es $\sigma > 0$. Para facilitar el desarrollo analítico, definimos formalmente las funciones de deriva y difusión como:

$$b_{\alpha, \beta}(x) = \alpha x + \beta, \tag{3.1}$$

$$\sigma(x) = \sigma x. \tag{3.2}$$

Observamos que la varianza infinitesimal del proceso está dada por

$$\sigma(x)^2 = \sigma^2 x^2,$$

lo cual implica que la volatilidad depende linealmente del nivel del proceso.

Esta característica, aunque común, complica el cálculo directo de la verosimilitud. Dado que nuestros datos empíricos son observaciones discretas pero deseamos trabajar con la formulación de verosimilitud en tiempo continuo, aplicamos la transformación de Lamperti [29]. Esta transformación estabiliza la varianza y reduce el término de difusión a la unidad.

3.3.1. Transformación de Lamperti

El objetivo de la transformación de Lamperti es mapear un proceso con volatilidad dependiente del estado a uno con difusión constante. En términos generales, se define a través de la integral de la inversa de la función de difusión:

$$h(x) = \int_{x^*}^x \frac{1}{\sigma(u)} du.$$

En el modelo de Brennan-Schwartz, donde $\sigma(u) = \sigma u$, seleccionamos el punto base $x^* = 1$ para garantizar que el logaritmo esté bien definido y evitar singularidades. El cálculo resulta en:

$$h(x) = \int_1^x \frac{1}{\sigma u} du = \frac{1}{\sigma} \int_1^x \frac{1}{u} du = \frac{1}{\sigma} \ln(x).$$

Esta transformación requiere que el proceso se mantenga estrictamente en el dominio positivo $(0, \infty)$, y dado que asumimos $X_t > 0$, eliminamos el valor absoluto y obtenemos.

Definimos entonces el nuevo proceso transformado como:

$$Y_t = h(X_t) = \frac{\ln(X_t)}{\sigma}. \quad (3.3)$$

Para regresar al espacio original, derivamos la función inversa despejando x de la ecuación $y = \frac{1}{\sigma} \ln(x)$:

$$\begin{aligned} y &= \frac{1}{\sigma} \ln(x), \\ \sigma y &= \ln(x), \\ x &= e^{\sigma y}. \end{aligned}$$

Por lo tanto,

$$h^{-1}(y) = e^{\sigma y}. \quad (3.4)$$

3.3.2. Aplicación del Lema de Itô

Para hallar la EDE que gobierna a Y_t , no basta con aplicar el cálculo diferencial ordinario, debemos emplear el Lema de Itô para considerar el término de corrección derivado de la naturaleza estocástica del proceso [44, 33]. Primero, calculamos las derivadas necesarias de nuestra función de transformación $h(x)$:

$$h'(x) = \frac{d}{dx} \left(\frac{1}{\sigma} \ln(x) \right) = \frac{1}{\sigma} \frac{1}{x} = \frac{1}{\sigma x}, \quad (3.5)$$

$$h''(x) = \frac{d}{dx} \left(\frac{1}{\sigma x} \right) = -\frac{1}{\sigma x^2}. \quad (3.6)$$

El Lema de Itô establece que:

$$dY_t = h'(X_t)dX_t + \frac{1}{2}h''(X_t)(dX_t)^2.$$

Sustituimos las derivadas y la dinámica original dX_t en la expansión de Itô, además recordemos que $(dX_t)^2 = (\sigma^2 X_t^2 dt)$:

$$dY_t = \frac{1}{\sigma X_t} [(\alpha X_t + \beta)dt + \sigma X_t dW_t] + \frac{1}{2} \left(-\frac{1}{\sigma X_t^2} \right) (\sigma^2 X_t^2 dt). \quad (3.7)$$

$$= \frac{1}{\sigma X_t} [(\alpha X_t + \beta)dt] + \frac{1}{\sigma X_t} (\sigma X_t dW_t) + \frac{1}{2} \left(-\frac{1}{\sigma X_t^2} \right) (\sigma^2 X_t^2 dt). \quad (3.8)$$

Vamos a simplificar término por término. Primero, el término lineal:

$$\frac{1}{\sigma X_t} [(\alpha X_t + \beta)dt] = \left(\frac{\alpha X_t}{\sigma X_t} + \frac{\beta}{\sigma X_t} \right) dt = \left(\frac{\alpha}{\sigma} + \frac{\beta}{\sigma X_t} \right) dt.$$

Después, el término estocástico:

$$\frac{1}{\sigma X_t} (\sigma X_t dW_t) = dW_t.$$

Por último, el término de corrección de Itô:

$$\frac{1}{2} \left(-\frac{1}{\sigma X_t^2} \right) (\sigma^2 X_t^2 dt) = -\frac{1}{2} \frac{\sigma^2 X_t^2}{\sigma X_t^2} dt = -\frac{\sigma}{2} dt.$$

Por lo tanto,

$$dY_t = \left(\frac{\alpha}{\sigma} + \frac{\beta}{\sigma X_t} \right) dt + dW_t - \frac{\sigma}{2} dt = \left(\frac{\alpha}{\sigma} + \frac{\beta}{\sigma X_t} - \frac{\sigma}{2} \right) dt + dW_t. \quad (3.9)$$

Sustituimos ahora $X_t = h^{-1}(Y_t) = e^{\sigma Y_t}$:

$$\frac{1}{X_t} = e^{-\sigma Y_t}.$$

Finalmente obtenemos

$$dY_t = \left[\left(\frac{\alpha}{\sigma} - \frac{\sigma}{2} \right) + \frac{\beta}{\sigma} e^{-\sigma Y_t} \right] dt + dW_t. \quad (3.10)$$

Dentro del paréntesis tenemos la parte constante de la deriva, mientras que fuera tenemos el término dependiente del estado, aunque sabemos que estos paréntesis son irrelevantes para el cálculo por la propiedad asociativa de la suma.

Como resultado, el proceso transformado Y_t posee ahora una difusión unitaria. Esta propiedad es fundamental, pues nos permitirá aplicar el teorema de Girsanov y otras técnicas de simulación de trayectorias (como los puentes brownianos) de manera mucho más eficiente en las secciones posteriores.

3.3.3. Funciones auxiliares $s_{\alpha,\beta}(x)$ y $H_{\alpha,\beta}(x)$

Para formular la función de verosimilitud de manera analítica, es conveniente definir dos funciones auxiliares que actúan como bloques de construcción para la densidad de transición [43, 4]. La primera es $s_{\alpha,\beta}(x)$, que se relaciona con la función de escala del proceso:

$$s_{\alpha,\beta}(x) = \int_1^x \frac{b_{\alpha,\beta}(u)}{\sigma(u)^2} du. \quad (3.11)$$

Desarrollando el término dentro de la integral:

$$\frac{b_{\alpha,\beta}(u)}{\sigma(u)^2} = \frac{\alpha u + \beta}{\sigma^2 u^2} = \frac{\alpha u}{\sigma^2 u^2} + \frac{\beta}{\sigma^2 u^2} = \frac{\alpha}{\sigma^2 u} + \frac{\beta}{\sigma^2 u^2} = \frac{\alpha}{\sigma^2} \cdot \frac{1}{u} + \frac{\beta}{\sigma^2} \cdot \frac{1}{u^2}.$$

Volvemos a $s_{\alpha,\beta}(x)$:

$$s_{\alpha,\beta}(x) = \int_1^x \left(\frac{\alpha}{\sigma^2} \cdot \frac{1}{u} + \frac{\beta}{\sigma^2} \cdot \frac{1}{u^2} \right) du = \frac{\alpha}{\sigma^2} \int_1^x \frac{1}{u} du + \frac{\beta}{\sigma^2} \int_1^x \frac{1}{u^2} du.$$

Resolviendo las integrales, obtenemos una expresión que depende logarítmicamente del nivel de la tasa:

$$\begin{aligned} s_{\alpha,\beta}(x) &= \frac{\alpha}{\sigma^2} [\ln(u)]_1^x + \frac{\beta}{\sigma^2} \left[-\frac{1}{u} \right]_1^x = \frac{\alpha}{\sigma^2} [\ln(x) - \ln(1)] + \frac{\beta}{\sigma^2} \left[-\frac{1}{x} - \left(-\frac{1}{1} \right) \right] \\ &= \frac{\alpha}{\sigma^2} \ln(x) + \frac{\beta}{\sigma^2} \left(-\frac{1}{x} + 1 \right) = \frac{\alpha}{\sigma^2} \ln(x) - \frac{\beta}{\sigma^2 x} + \frac{\beta}{\sigma^2}. \end{aligned}$$

Finalmente, definimos la función $H_{\alpha,\beta}(x)$, la cual integra tanto la deriva como el impacto de la varianza en la escala logarítmica:

$$H_{\alpha,\beta}(x) = \underbrace{s_{\alpha,\beta}(x)}_{\text{Término 1}} - \underbrace{\frac{1}{2} \ln(\sigma(x)^2)}_{\text{Término 2}}. \quad (3.12)$$

Sustituyendo $\sigma(x)^2 = \sigma^2 x^2$ y simplificando los logaritmos en el término 2:

$$\frac{1}{2} \ln(\sigma^2 x^2) = \frac{1}{2} (\ln(\sigma^2) + \ln(x^2)) = \ln(\sigma) + \ln(x) = \ln(\sigma x).$$

Por lo tanto, sustituyendo en $H_{\alpha,\beta}(x)$:

$$H_{\alpha,\beta}(x) = \frac{\alpha}{\sigma^2} \ln(x) - \frac{\beta}{\sigma^2 x} + \frac{\beta}{\sigma^2} - \ln(\sigma x). \quad (3.13)$$

La función $H_{\alpha,\beta}(x)$ juega un papel central en la construcción de la densidad de transición del proceso y en la aplicación del teorema de Girsanov, herramientas fundamentales para formular la verosimilitud exacta a partir de observaciones discretas [4, 43].

3.4. Reconstrucción de Trayectorias mediante Puentes de Difusión

En el contexto de la inferencia bayesiana para ecuaciones diferenciales estocásticas observadas de forma discreta, surge un problema, y es que la trayectoria del proceso entre dos observaciones consecutivas es desconocida. Sin embargo, los procedimientos de estimación, como el muestreador de Gibbs con aumento de datos, requieren una aproximación de dicha trayectoria para evaluar las integrales que aparecen en la verosimilitud continua [48, 5].

Recordemos nuevamente el proceso definido por la ecuación diferencial estocástica original (1.1):

$$dX_t = (\alpha X_t + \beta)dt + \sigma X_t dW_t, \quad (3.14)$$

donde el término de difusión depende directamente del nivel de la tasa. Supondremos que este proceso es capturado en una partición discreta $\{t_0, t_1, \dots, t_m\}$, generando el conjunto de observaciones $\{x_0, x_1, \dots, x_m\}$. Dadas dos observaciones consecutivas x_{i-1} y x_i , separadas por un intervalo temporal $\Delta = t_i - t_{i-1}$, nuestro objetivo consiste en reconstruir una trayectoria aproximada en el intervalo cerrado $[t_{i-1}, t_i]$ que satisfaga las condiciones de frontera:

$$X_{t_{i-1}} = x_{i-1} \quad \text{y} \quad X_{t_i} = x_i.$$

Simular directamente trayectorias condicionadas para el proceso X_t resulta analíticamente complejo debido a que su coeficiente de difusión depende del estado, $\sigma(X_t) = \sigma X_t$. Esta dependencia introduce una geometría estocástica no lineal que impide la construcción directa de puentes mediante métodos normales. Para superar este obstáculo, recurrimos nuevamente a la transformación de Lamperti introducida en la sección previa 3.3:

$$Y_t = h(X_t) = \frac{\ln X_t}{\sigma}. \quad (3.15)$$

Como vimos anteriormente, al aplicar el lema de Itô, el proceso transformado Y_t satisface la EDE:

$$dY_t = \left(\frac{\alpha}{\sigma} - \frac{\sigma}{2} + \frac{\beta}{\sigma} e^{-\sigma Y_t} \right) dt + dW_t. \quad (3.16)$$

La propiedad fundamental de esta transformación es que el coeficiente de difusión del proceso transformado es constante e igual a la unidad. En consecuencia, las fluctuaciones de alta frecuencia de Y_t poseen la misma estructura que un movimiento browniano estándar. Esta característica permite construir trayectorias condicionadas utilizando puentes brownianos en lugar de recurrir a simulaciones complejas [5, 25].

Consideremos el intervalo $[t_{i-1}, t_i]$ de longitud Δ . Introducimos una malla temporal fina dividiendo dicho intervalo en n subintervalos de longitud uniforme $\delta t = \frac{\Delta}{n}$. Definimos la partición temporal interna como $t_k = t_{i-1} + k\delta t$, para $k = 0, 1, \dots, n$. Nuestro propósito es construir una trayectoria discreta $\{Y_k^*\}_{k=0}^n$ que conecte las observaciones proyectadas al espacio de Lamperti:

$$Y_0 = \frac{\ln(x_{i-1})}{\sigma}, \quad Y_n = \frac{\ln(x_i)}{\sigma}. \quad (3.17)$$

3.4.1. Construcción del Puente Browniano

La construcción del puente browniano se realiza en dos etapas. Primero, generamos incrementos gaussianos independientes $\Delta W_j \sim \mathcal{N}(0, \delta t)$ para $j = 0, \dots, n-1$. A partir de estos, construimos un movimiento browniano discreto acumulado partiendo desde el origen:

$$W_0 = 0, \quad (3.18)$$

$$W_k = \sum_{j=0}^{k-1} \Delta W_j, \quad k = 1, \dots, n. \quad (3.19)$$

Este proceso W_k posee la varianza estocástica correcta, pero su valor final W_n es el resultado de una suma aleatoria y, por lo tanto, no regresará naturalmente a cero. Para garantizar que la trayectoria regrese exactamente al punto de origen en el instante final, aplicamos un ajuste geométrico lineal que ancla el proceso. Definimos el puente browniano estándar Z_k como:

$$Z_k = W_k - \frac{k}{n} W_n. \quad (3.20)$$

Para comprobar que este ajuste cumple con las condiciones de frontera de un puente estándar, evaluamos la expresión en los extremos. En el instante inicial ($k = 0$):

$$Z_0 = W_0 - \frac{0}{n} W_n = 0 - 0 = 0.$$

Y en el instante final ($k = n$):

$$Z_n = W_n - \frac{n}{n} W_n = W_n - W_n = 0.$$

De este modo, $\{Z_k\}$ constituye un puente browniano puro definido sobre la partición temporal considerada, el cual inicia y termina en cero.

Una vez generado el puente browniano anclado en cero, lo trasladamos para conectar los valores observados Y_0 y Y_n . Para ello utilizamos una interpolación determinista lineal entre los extremos y le superponemos el ruido estocástico del puente Z_k :

$$Y_k^* = Y_0 + \frac{k}{n}(Y_n - Y_0) + Z_k. \quad (3.21)$$

La validez de esta construcción se demuestra al evaluar la trayectoria estocástica en los bordes del intervalo. Para el inicio de la trayectoria ($k = 0$), sabiendo que $Z_0 = 0$:

$$Y_0^* = Y_0 + \frac{0}{n}(Y_n - Y_0) + Z_0 = Y_0 + 0 + 0 = Y_0.$$

De manera análoga, para el final de la trayectoria ($k = n$), sabiendo que $Z_n = 0$:

$$Y_n^* = Y_0 + \frac{n}{n}(Y_n - Y_0) + Z_n = Y_0 + (Y_n - Y_0) + 0 = Y_n.$$

Esta formulación garantiza matemáticamente que la ecuación (3.21) satisface exactamente las condiciones de frontera requeridas. La componente lineal describe la tendencia promedio de la tasa, mientras que el término Z_k aporta la textura estocástica fundamental.

Para utilizar esta trayectoria en la evaluación del modelo, es necesario revertir la transformación y regresar al espacio original del proceso X_t . Aplicando la función inversa de Lamperti $h^{-1}(y) = e^{\sigma y}$, obtenemos la trayectoria reconstruida final:

$$X_k^* = \exp(\sigma Y_k^*). \quad (3.22)$$

Notemos que la función exponencial garantiza que $X_k^* > 0$ para todo k , preservando de forma natural la restricción de positividad inherente a las tasas de interés nominales, algo que una interpolación lineal directa en el espacio original no podría asegurar.

Al concatenar las trayectorias reconstruidas $\{X_k^*\}$ de cada subintervalo a lo largo de todas las observaciones (omitendo el punto final duplicado de cada empalme), se obtiene una trayectoria latente global y continua X^* definida sobre todo el horizonte temporal de la muestra $[0, T]$.

En el marco del aumento de datos (Data Augmentation), esta trayectoria global X^* actúa como el reemplazo continuo de los datos discretos originales [5]. Disponer de una ruta ininterrumpida es el requisito teórico fundamental para poder aplicar las herramientas del cálculo estocástico en tiempo continuo, específicamente el Teorema de Girsanov, sobre la función de verosimilitud del modelo [4].

De este modo, la trayectoria estocástica generada mediante los puentes de Lamperti constituye el insumo directo que permitirá evaluar las integrales de trayectoria sobre el intervalo $[0, T]$ (tales como $\int_0^T X_s^{-1} ds$ o $\int_0^T X_s^{-2} ds$). Como se formalizará en la siguiente sección, la evaluación de dichas integrales definirá los estadísticos suficientes que alimentan las distribuciones condicionales exactas en el muestreador de Gibbs.

3.4.2. Validación Monte Carlo de la Reconstrucción

Tras identificar el colapso de los métodos tradicionales ante la escasez de información, vamos a validar cómo la reconstrucción estocástica mediante la Transformación de Lamperti puede revertir esta degradación estadística [5, 22]. A diferencia de las interpolaciones lineales simples, este enfoque permite mitigar el sesgo de discretización al rellenar los intervalos vacíos con trayectorias que preservan la variación cuadrática teórica del modelo de Brennan-Schwartz.

La Figura 3.3 ilustra la eficacia de este método: mientras que los puntos rojos representan la escasa información disponible tras el submuestreo ($k = 15$), la línea verde muestra la trayectoria reconstruida. Se observa cómo la reconstrucción estocástica recupera la textura y la frecuencia de la trayectoria real (gris), capturando el ruido de alta frecuencia que es invisible para los métodos de estimación clásicos.




Figura 3.3: Reconstrucción de la trayectoria latente. La línea verde (Puentes) recupera la volatilidad perdida entre los puntos observados (rojos), alineándose con la dinámica real (gris).

Para validar la robustez de este método, se realizaron experimentos controlados utilizando los parámetros reales ($\alpha = -0,5$, $\beta = 1,0$, $\sigma = 0,3$). Primero se aplicó la reconstrucción a una única trayectoria submuestreada (observada gráficamente en 3.3) para observar la capacidad de recuperación puntual. Los resultados, detallados en la Tabla 3.3, muestran una corrección drástica: el método ingenuo sobreestimó σ en más de un 53 % (0,4593) y subestimó la fuerza de reversión α en un 71 % ($-0,1401$). En contraste, la reconstrucción con la Transformación de Lamperti logró una estimación de $\hat{\sigma} = 0,3050$, reduciendo el error relativo en la volatilidad a un mínimo del 1.67 %.

Parámetro	Valor Real	Reducida ($k = 15$)	Reconstruida	Error Rec. %
Alpha (α)	$-0,5$	$-0,1401$	$-0,4432$	11,36 %
Beta (β)	1,0	0,6704	0,9855	1,45 %
Sigma (σ)	0,3	0,4593	0,3050	1,67 %

Cuadro 3.3: Comparativa de estimadores para una trayectoria única. La reconstrucción restaura la arquitectura de los parámetros.

Con el fin de descartar que este éxito fuera producto de una simulación afortunada y para confirmar la consistencia del método, se ejecutó un experimento de Monte Carlo con 100 simulaciones independientes. En cada iteración se generó una trayectoria nueva, se diezmó sistemáticamente, se reconstruyó mediante la Transformación de Lamperti y se re-estimaron los parámetros. Los promedios de este ejercicio, presentados en la Tabla 3.4, ratifican la superioridad de la técnica. Mientras que el estimador de baja frecuencia

para la volatilidad se desvía significativamente (0,4470), el estimador promedio mediante puentes de Lamperti (0,3077) converge con notable precisión hacia el valor real.

Parámetro	Valor Real	Reducido (Prom)	Reconstruido (Prom)
Alpha (α)	-0,5	-0,15747	-0,44499
Beta (β)	1,0	0,65581	0,94510
Sigma (σ)	0,3	0,44708	0,30770

Cuadro 3.4: Resultados promedio tras 100 simulaciones de Monte Carlo. Se confirma la estabilidad del método para recuperar los parámetros de la EDE.

Si bien la reconstrucción mediante la Transformación de Lamperti es altamente efectiva, su implementación directa enfrenta un problema: para construir el puente estocástico óptimo entre dos observaciones, el algoritmo requiere conocer a priori los parámetros verdaderos del modelo (α, β, σ) , parámetros que de hecho son la incógnita que deseamos estimar.

Para superar esta limitación, el presente trabajo adopta el marco de la Inferencia Bayesiana con Aumento de Datos (Data Augmentation). Este enfoque no trata los datos faltantes no como huecos estáticos, sino como variables latentes que se actualizan iterativamente en sintonía con los parámetros. Mediante algoritmos de Monte Carlo vía Cadenas de Markov (MCMC), específicamente el muestreador de Gibbs, es posible simular las trayectorias ocultas bajo un set de parámetros propuestos y, acto seguido, utilizar dicha trayectoria completa para actualizar la distribución posterior de los parámetros [5, 56]. Esta metodología permite incorporar la incertidumbre de la estimación de manera coherente, rompiendo el ciclo de dependencia y recuperando la estructura del modelo sin los sesgos de discretización tradicionales. A continuación, se desarrolla la formalización matemática de este esquema de verosimilitud aumentada, partiendo de la transformación de Lamperti y el teorema de Girsanov.

3.5. Función de Verosimilitud Aumentada y Forma Exponencial

3.5.1. Verosimilitud de Girsanov en Tiempo Continuo

Como se demostró en la sección anterior, tras aplicar la transformación de Lamperti $Y_t = \frac{\ln X_t}{\sigma}$, el proceso transformado satisface la ecuación diferencial estocástica:

$$dY_t = \mu_{\alpha, \beta}(Y_t)dt + dW_t, \quad (3.23)$$

donde la deriva transformada es lineal en los parámetros de interés $\theta = (\alpha, \beta)^\top$:

$$\mu_{\alpha, \beta}(y) = \left(\frac{\alpha}{\sigma} - \frac{\sigma}{2} \right) + \frac{\beta}{\sigma} e^{-\sigma y}. \quad (3.24)$$

Dado que el término de difusión de este nuevo proceso es constante y unitario, se cumplen las condiciones de regularidad necesarias para aplicar el Teorema de Girsanov [33, 44]. Este teorema actúa como el equivalente estocástico del cambio de variable en integración, permitiéndonos definir la densidad de Radon–Nikodym. Sea $\mathbb{P}_0$ la medida de probabilidad inducida por un movimiento browniano estándar, la verosimilitud evaluada sobre la trayectoria aumentada Y^* se expresa como:

$$L(\alpha, \beta \mid Y^*) = \exp \left(\int_0^T \mu_{\alpha, \beta}(Y_s) dY_s - \frac{1}{2} \int_0^T \mu_{\alpha, \beta}(Y_s)^2 ds \right). \quad (3.25)$$

Al sustituir la expresión de la deriva en la primera integral del exponente, procedemos a una expansión lineal que facilita el cálculo:

$$\begin{aligned} \int_0^T \mu_{\alpha, \beta}(Y_s) dY_s &= \int_0^T \left(\frac{\alpha}{\sigma} - \frac{\sigma}{2} + \frac{\beta}{\sigma} e^{-\sigma Y_s} \right) dY_s \\ &= \left(\frac{\alpha}{\sigma} - \frac{\sigma}{2} \right) \int_0^T dY_s + \frac{\beta}{\sigma} \int_0^T e^{-\sigma Y_s} dY_s. \end{aligned} \quad (3.26)$$

La primera integral resulta en $\int_0^T dY_s = Y_T - Y_0$. Recordando que $Y_t = \frac{\ln X_t}{\sigma}$, tenemos que:

$$Y_T - Y_0 = \frac{1}{\sigma} \ln \left(\frac{x_T}{x_0} \right). \quad (3.27)$$

El término que acompaña a β contiene una integral estocástica. Aplicando el Lema de Itô [33] a la función $f(y) = -\frac{1}{\sigma} e^{-\sigma y}$, obtenemos el diferencial $df(Y_t) = e^{-\sigma Y_t} dY_t - \frac{\sigma}{2} e^{-\sigma Y_t} dt$. Al integrar en $[0, T]$ y regresar a la variable original $X_t = e^{\sigma Y_t}$, la integral se resuelve exactamente como:

$$\int_0^T e^{-\sigma Y_s} dY_s = \frac{1}{\sigma} \left(\frac{1}{x_0} - \frac{1}{x_T} \right) + \frac{\sigma}{2} \int_0^T \frac{ds}{X_s}. \quad (3.28)$$

Integrando estos resultados en el término lineal de la verosimilitud, llegamos a la siguiente expresión:

$$\int_0^T \mu_{\alpha, \beta}(Y_s) dY_s = \alpha \left[\frac{1}{\sigma^2} \ln \left(\frac{x_T}{x_0} \right) \right] + \beta \left[\frac{1}{\sigma^2} \left(\frac{1}{x_0} - \frac{1}{x_T} \right) + \frac{1}{2} \int_0^T \frac{ds}{X_s} \right] - \frac{1}{2} \ln \left(\frac{x_T}{x_0} \right). \quad (3.29)$$

Para el segundo término de Girsanov, expandimos el cuadrado de la deriva:

$$\begin{aligned} \mu_{\alpha, \beta}(Y_s)^2 &= \left(\left(\frac{\alpha}{\sigma} - \frac{\sigma}{2} \right) + \frac{\beta}{\sigma X_s} \right)^2 \\ &= \frac{\alpha^2}{\sigma^2} - \alpha + \frac{\sigma^2}{4} + \frac{2\alpha\beta}{\sigma^2 X_s} - \frac{\beta}{X_s} + \frac{\beta^2}{\sigma^2 X_s^2}. \end{aligned} \quad (3.30)$$

Multiplicando por $-\frac{1}{2}$ e integrando respecto a ds , obtenemos el componente cuadrático del funcional:

$$-\frac{1}{2} \int_0^T \mu_{\alpha, \beta}(Y_s)^2 ds = -\frac{1}{2} \left(\frac{\alpha^2}{\sigma^2} T + \frac{2\alpha\beta}{\sigma^2} \int_0^T \frac{ds}{X_s} + \frac{\beta^2}{\sigma^2} \int_0^T \frac{ds}{X_s^2} \right) + \frac{\alpha}{2} T + \frac{\beta}{2} \int_0^T \frac{ds}{X_s} - \frac{\sigma^2}{8} T. \quad (3.31)$$

3.5.2. Definición de Estadísticos Suficientes y Forma Cuadrática

Dado que la verosimilitud de Girsanov se obtiene sumando la integral estocástica (3.29) y la integral determinista (3.31) dentro de la función exponencial, realizamos dicha suma

explícitamente:

$$\begin{aligned} & \int_0^T \mu_{\alpha,\beta}(Y_s) dY_s - \frac{1}{2} \int_0^T \mu_{\alpha,\beta}(Y_s)^2 ds = \\ & \alpha \left[\frac{1}{\sigma^2} \ln \left(\frac{x_T}{x_0} \right) \right] + \beta \left[\frac{1}{\sigma^2} \left(\frac{1}{x_0} - \frac{1}{x_T} \right) + \frac{1}{2} \int_0^T \frac{ds}{X_s} \right] - \frac{1}{2} \ln \left(\frac{x_T}{x_0} \right) \\ & - \frac{1}{2} \left(\frac{\alpha^2}{\sigma^2} T + \frac{2\alpha\beta}{\sigma^2} \int_0^T \frac{ds}{X_s} + \frac{\beta^2}{\sigma^2} \int_0^T \frac{ds}{X_s^2} \right) + \frac{\alpha}{2} T + \frac{\beta}{2} \int_0^T \frac{ds}{X_s} - \frac{\sigma^2}{8} T. \end{aligned}$$

Para simplificar la notación y preparar la estructura matricial del algoritmo, es conveniente aislar las cantidades que dependen exclusivamente de la trayectoria empírica y aumentada $\{X_s\}_{s \in [0,T]}$ y del tiempo transcurrido. A estos valores de frontera e integrales de trayectoria se les denomina estadísticos suficientes [59]. Por el Teorema de Factorización de Fisher-Neyman aplicado a la familia exponencial, estos estadísticos condensan absolutamente toda la información de los datos necesaria para inferir los parámetros de la deriva, sin requerir la trayectoria completa de forma explícita en cada paso del cálculo.

La selección de estos estadísticos responde directamente a los términos aislados al expandir el funcional de Girsanov. Siguiendo la formulación estándar de la literatura para la estimación bayesiana en ecuaciones diferenciales estocásticas [53], los estadísticos se definen de la siguiente manera:

$$D_1 = \ln \left(\frac{x_T}{x_0} \right), \quad D_2 = \frac{1}{x_0} - \frac{1}{x_T}, \quad D_3 = T, \quad D_5 = \int_0^T \frac{ds}{X_s^2}, \quad D_6 = \int_0^T \frac{ds}{X_s}. \quad (3.32)$$

Es pertinente señalar la omisión del índice D_4 en esta nomenclatura. En marcos de modelación más generales (como los modelos de Vasicek o Cox-Ingersoll-Ross), la expansión de la verosimilitud genera la integral de estado $\int X_s ds$, convencionalmente denotada como D_4 . Sin embargo, dada la estructura particular de reversión a la media acoplada a una difusión proporcional al estado en el modelo de Brennan-Schwartz, dicho término se anula analíticamente en la escala de Lamperti, por lo que se omite para preservar la consistencia notacional con la literatura establecida.

Cada estadístico tiene una interpretación analítica precisa dentro de la dinámica del modelo:

- D_1 y D_2 (Valores de frontera): D_1 representa el log-retorno total del proceso, surgiendo naturalmente al integrar el componente de tendencia. D_2 captura el cambio neto en el recíproco del estado, actuando como el balance de frontera para el parámetro β .
- D_3 (Exposición temporal): Actúa como el tiempo total de observación, funcionando técnicamente como el término de precisión base (varianza inversa) para la estimación de la deriva de largo plazo α .
- D_5 y D_6 (Integrales de trayectoria): Estos términos son fundamentales para capturar la no linealidad introducida por el parámetro β . Mientras que D_6 pondera la influencia del nivel inverso del proceso sobre la deriva, D_5 cuantifica la variabilidad local acumulada en el recíproco al cuadrado, necesaria para estabilizar la forma cuadrática de la verosimilitud en regiones cercanas al origen.

Esta estructura asegura que, una vez aproximadas estas integrales mediante la discretización de la trayectoria aumentada, la actualización de los parámetros (α, β) en el muestreador de Gibbs se reduzca a una operación matricial directa sobre un núcleo Gaussiano.

Sustituyendo estos estadísticos en la suma anterior, obtenemos:

$$\int_0^T \mu_{\alpha, \beta}(Y_s) dY_s - \frac{1}{2} \int_0^T \mu_{\alpha, \beta}(Y_s)^2 ds = \alpha \left(\frac{D_1}{\sigma^2} \right) + \beta \left(\frac{D_2}{\sigma^2} + \frac{D_6}{2} \right) - \frac{D_1}{2} - \frac{1}{2\sigma^2} (\alpha^2 D_3 + 2\alpha\beta D_6 + \beta^2 D_5) + \frac{\alpha}{2} D_3 + \frac{\beta}{2} D_6 - \frac{\sigma^2}{8} D_3.$$

Ahora, nuestro objetivo es aislar una forma cuadrática en el vector de parámetros $\theta = (\alpha, \beta)^\top$. Para ello, agrupamos por un lado todos los términos lineales que multiplican a α y β , y por otro lado los términos puramente cuadráticos $(\alpha^2, \beta^2, \alpha\beta)$.

Los términos restantes que no dependen de la deriva los agrupamos en una función $C(\sigma) = -\frac{1}{2}D_1 - \frac{\sigma^2}{8}D_3$. Es vital notar que $C(\sigma)$ actúa como una constante de proporcionalidad únicamente respecto a la actualización de (α, β) , sin embargo, en el paso del muestreador de Gibbs correspondiente a la volatilidad, esta función será no trivial y contribuirá significativamente a la distribución marginal de σ^2 .

La reorganización queda de la siguiente manera:

$$\begin{aligned} \int_0^T \mu_{\alpha, \beta}(Y_s) dY_s - \frac{1}{2} \int_0^T \mu_{\alpha, \beta}(Y_s)^2 ds = \\ \left[\alpha \left(\frac{D_1}{\sigma^2} + \frac{D_3}{2} \right) + \beta \left(\frac{D_2}{\sigma^2} + \frac{D_6}{2} + \frac{D_6}{2} \right) \right] - \frac{1}{2\sigma^2} (\alpha^2 D_3 + 2\alpha\beta D_6 + \beta^2 D_5) + C(\sigma) = \\ \left[\alpha \left(\frac{D_1}{\sigma^2} + \frac{D_3}{2} \right) + \beta \left(\frac{D_2}{\sigma^2} + D_6 \right) \right] - \frac{1}{2\sigma^2} (\alpha^2 D_3 + 2\alpha\beta D_6 + \beta^2 D_5) + C(\sigma). \end{aligned}$$

Llegados a este punto, podemos reconocer de inmediato la estructura del producto matricial. El primer corchete corresponde al producto punto entre el vector transpuesto $\theta^\top = (\alpha, \beta)$ y un vector columna que llamaremos ν_σ . El segundo corchete corresponde a la forma cuadrática $\theta^\top \Lambda_\sigma \theta$, donde Λ_σ es una matriz simétrica de 2×2 .

Por lo tanto, la verosimilitud puede expresarse estrictamente como:

$$L(\theta | Y^*) = \exp \left(\theta^\top \nu_\sigma - \frac{1}{2} \theta^\top \Lambda_\sigma \theta + C(\sigma) \right), \quad (3.33)$$

donde, por inspección directa de los coeficientes desarrollados, los componentes que definen el núcleo de la distribución multivariada están dados por:

$$\nu_\sigma = \begin{pmatrix} \frac{D_1}{\sigma^2} + \frac{D_3}{2} \\ \frac{D_2}{\sigma^2} + D_6 \end{pmatrix} = \frac{1}{\sigma^2} \begin{pmatrix} D_1 + \frac{\sigma^2}{2} D_3 \\ D_2 + \sigma^2 D_6 \end{pmatrix} \quad \Lambda_\sigma = \frac{1}{\sigma^2} \begin{pmatrix} D_3 & D_6 \\ D_6 & D_5 \end{pmatrix}. \quad (3.34)$$

Esta representación es la pieza central del algoritmo MCMC. Al identificar el exponente con el núcleo de una distribución gaussiana multivariada, la matriz Λ_σ se interpreta matemáticamente como la matriz de precisión (la inversa de la matriz de covarianza). Como se detallará a continuación, esto garantiza que, condicionada a la trayectoria aumentada y al parámetro de difusión, la distribución posterior de la deriva sea de la forma $\mathcal{N}(\Lambda_\sigma^{-1} \nu_\sigma, \Lambda_\sigma^{-1})$, permitiendo su muestreo directo y eficiente a través de los estadísticos $D_1, \dots, D_6$, los cuales se actualizan en cada iteración del muestreador de Gibbs.

3.5.3. Completitud del Cuadrado y Distribución Condicional de la Deriva

Para validar formalmente la estructura normal anunciada, es necesario realizar el procedimiento de completitud del cuadrado sobre el exponente de la verosimilitud aumentada. Partimos de la densidad condicional de los parámetros de deriva θ , asumiendo la volatilidad σ como una cantidad conocida y fija en este paso del muestreador. Bajo esta condición, el término $C(\sigma)$ se comporta como una constante multiplicativa que no depende de θ , por lo que, al aplicar el principio de proporcionalidad, la densidad resulta:

$$L(\theta | Y^*, \sigma^2) \propto \exp \left(-\frac{1}{2} \theta^\top \Lambda_\sigma \theta + \theta^\top \nu_\sigma \right). \quad (3.35)$$

Para derivar la distribución posterior exacta de $\theta = (\alpha, \beta)^\top$, incorporamos la información a priori. Bajo la asignación de un prior no informativo plano $\pi(\theta) \propto 1$, y aplicando el Teorema de Bayes, la densidad condicional posterior mantiene la forma funcional de la verosimilitud:

$$\pi(\theta | Y^*, \sigma^2) \propto \exp \left(-\frac{1}{2} \theta^\top \Lambda_\sigma \theta + \theta^\top \nu_\sigma \right). \quad (3.36)$$

Para identificar esta expresión con una distribución conocida, buscamos asociarla con la forma canónica de una densidad Normal Multivariada [59] $\exp \left(-\frac{1}{2} (\theta - \mu_p)^\top \Sigma_p^{-1} (\theta - \mu_p) \right)$ (donde Σ_p es la varianza y μ_p es la media) cuyo exponente desarrollamos algebraicamente aprovechando la simetría de la matriz de precisión Σ_p^{-1} :

$$\begin{aligned} \exp \left(-\frac{1}{2} (\theta - \mu_p)^\top \Sigma_p^{-1} (\theta - \mu_p) \right) &= \exp \left[\left(-\frac{1}{2} \theta^\top + \frac{1}{2} \mu_p^\top \right) (\Sigma_p^{-1} \theta - \Sigma_p^{-1} \mu_p) \right] \\ &= \exp \left(-\frac{1}{2} \theta^\top \Sigma_p^{-1} \theta + \frac{1}{2} \mu_p^\top \Sigma_p^{-1} \theta + \frac{1}{2} \theta^\top \Sigma_p^{-1} \mu_p - \frac{1}{2} \mu_p^\top \Sigma_p^{-1} \mu_p \right) \\ &= \exp \left(-\frac{1}{2} \theta^\top \Sigma_p^{-1} \theta + \theta^\top \Sigma_p^{-1} \mu_p - \frac{1}{2} \mu_p^\top \Sigma_p^{-1} \mu_p \right). \end{aligned}$$

Para identificar los parámetros de la distribución, recurrimos a la propiedad de identificación de núcleos de la familia exponencial. Al igualar los coeficientes de los términos cuadráticos y lineales entre ambas expresiones, y absorbiendo los términos constantes respecto a θ en la constante de normalización, se obtienen las siguientes equivalencias fundamentales:

$$\begin{aligned} \Sigma_p^{-1} &= \Lambda_\sigma \implies \Sigma_p = \Lambda_\sigma^{-1}, \\ \Sigma_p^{-1} \mu_p &= \nu_\sigma \implies \mu_p = \Lambda_\sigma^{-1} \nu_\sigma. \end{aligned}$$

De este modo, queda demostrado que la distribución condicional completa para los parámetros de la deriva es, en efecto, una Normal Multivariada [59]:

$$\theta | \sigma^2, Y^* \sim \mathcal{N}(\Lambda_\sigma^{-1} \nu_\sigma, \Lambda_\sigma^{-1}). \quad (3.37)$$

Esta expresión cerrada constituye el núcleo operativo del muestreador de Gibbs para la deriva. Al reducir el problema de inferencia estocástica a una operación de álgebra lineal directa (la inversión de la matriz simétrica Λ_σ de 2×2), se garantiza una implementación numérica robusta y de bajo costo computacional.

3.6. Algoritmo MCMC: Gibbs Sampler y Metropolis-within-Gibbs

3.6.1. Distribución posteriori exacta y completitud del cuadrado

Para iniciar con el esquema de muestreo, debemos considerar que la densidad condicional completa se compone de dos partes fundamentales: el término asociado a la deriva, derivado del teorema de Girsanov, y el término difusivo, que proviene de la variación cuadrática de la trayectoria discreta. Al combinar estos elementos, encontramos que la función de verosimilitud aumentada completa es proporcional a la siguiente expresión [38, 37, 33]:

$$L(\theta, \sigma \mid Y_{obs}, Y_{miss}) \propto (\sigma^2)^{-\frac{N}{2}} \exp\left(-\frac{1}{2}\theta^\top \Lambda_\sigma \theta + \theta^\top \nu_\sigma + C(\sigma)\right) \exp\left(-\sum_{k=1}^N \frac{(\Delta \ln X_k)^2}{2\sigma^2 \Delta t_k}\right), \quad (3.38)$$

donde N representa el número total de incrementos utilizados en la trayectoria aumentada. Asimismo, el término $C(\sigma) = -\frac{1}{2}D_1 - \frac{\sigma^2}{8}D_3$ actúa como una constante de normalización respecto a la deriva, pero será crucial al actualizar la volatilidad debido a las correcciones de Itô.

Para identificar con precisión la estructura de la deriva, es necesario realizar un desarrollo algebraico detallado de la Suma de Errores (E_{SSE}). Para ello, retomamos las expresiones explícitas del vector ν_σ y la matriz Λ_σ que obtuvimos anteriormente. Al definir el vector de parámetros como $\theta = (\alpha, \beta)^\top$, recordemos que las componentes quedan estructuradas de la siguiente forma:

$$\nu_\sigma = \frac{1}{\sigma^2} \begin{pmatrix} D_1 + \frac{\sigma^2}{2}D_3 \\ D_2 + \sigma^2 D_6 \end{pmatrix}, \quad \Lambda_\sigma = \frac{1}{\sigma^2} \begin{pmatrix} D_3 & D_6 \\ D_6 & D_5 \end{pmatrix}.$$

Desarrollemos el producto interno $\theta^\top \nu_\sigma$:

$$\begin{aligned} \theta^\top \nu_\sigma &= \alpha \left(\frac{D_1}{\sigma^2} + \frac{D_3}{2} \right) + \beta \left(\frac{D_2}{\sigma^2} + D_6 \right) \\ &= \frac{1}{\sigma^2} (\alpha D_1 + \beta D_2) + \frac{\alpha D_3}{2} + \beta D_6. \end{aligned} \quad (3.39)$$

A continuación, desarrollamos la forma cuadrática $-\frac{1}{2}\theta^\top \Lambda_\sigma \theta$:

$$\begin{aligned} -\frac{1}{2}\theta^\top \Lambda_\sigma \theta &= -\frac{1}{2\sigma^2} \begin{pmatrix} \alpha & \beta \end{pmatrix} \begin{pmatrix} D_3 & D_6 \\ D_6 & D_5 \end{pmatrix} \begin{pmatrix} \alpha \\ \beta \end{pmatrix} \\ &= -\frac{1}{2\sigma^2} (\alpha^2 D_3 + 2\alpha\beta D_6 + \beta^2 D_5). \end{aligned} \quad (3.40)$$

Al sumar ambos componentes y factorizar el término común $-\frac{1}{2\sigma^2}$, podemos reescribir el exponente dependiente de los parámetros en una forma mucho más manejable para el algoritmo de muestreo:

$$-\frac{1}{2}\theta^\top \Lambda_\sigma \theta + \theta^\top \nu_\sigma = -\frac{1}{2\sigma^2} [\alpha^2 D_3 + 2\alpha\beta D_6 + \beta^2 D_5 - 2(\alpha D_1 + \beta D_2)] + \frac{\alpha D_3}{2} + \beta D_6. \quad (3.41)$$

Esta manipulación algebraica nos permite identificar finalmente el término contenido entre corchetes como la Suma de Errores Cuadráticos Estándar (E_{SSE}):

$$E_{SSE} = \alpha^2 D_3 + 2\alpha\beta D_6 + \beta^2 D_5 - 2(\alpha D_1 + \beta D_2). \quad (3.42)$$

Notemos que los términos residuales fuera del corchete, es decir, $\frac{\alpha D_3}{2} + \beta D_6$, dependen exclusivamente de la deriva y no involucran al parámetro de difusión σ^2 . Como resultado, estos términos se integrarán naturalmente en la constante de proporcionalidad al momento de derivar la distribución condicional de σ^2 dados los parámetros (α, β) dentro del esquema de Gibbs.

3.6.2. Derivación de la distribución condicional posterior de σ^2

Para avanzar en la implementación del muestreador de Gibbs, el siguiente paso es derivar la distribución condicional posterior del parámetro de difusión, σ^2 . A diferencia de los parámetros de deriva, la actualización de la volatilidad presenta una complejidad técnica superior debido a que este parámetro no solo regula la dispersión de los incrementos brownianos, sino que también interviene en la escala de la transformación de Lamperti y en las correcciones de Itô que surgen al realizar el cambio de medida. En términos de la inferencia bayesiana, nuestro objetivo es encontrar la densidad de σ^2 condicionada a los parámetros de deriva (α, β) y a las trayectorias latentes reconstruidas Y^* .

Por el Teorema de Bayes, la densidad posterior es proporcional al producto de la distribución a priori y la función de verosimilitud completa, expresándose formalmente como

$$\pi(\sigma^2 | Y^*, \alpha, \beta) \propto \pi(\sigma^2) \times L(\sigma^2 | Y^*, \alpha, \beta).$$

Para desglosar la verosimilitud condicional en términos de σ^2 , partimos directamente de la función de verosimilitud aumentada completa definida al inicio de la sección (3.38):

$$L(\theta, \sigma | Y_{obs}, Y_{miss}) \propto (\sigma^2)^{-\frac{N}{2}} \exp\left(-\frac{1}{2}\theta^\top \Lambda_\sigma \theta + \theta^\top \nu_\sigma + C(\sigma)\right) \exp\left(-\sum_{k=1}^N \frac{(\Delta \ln X_k)^2}{2\sigma^2 \Delta t_k}\right). \quad (3.43)$$

Dado que buscamos aislar únicamente la dependencia funcional respecto a la volatilidad para la distribución condicional, identificamos las tres fuentes que contienen a σ^2 y aplicamos el principio de proporcionalidad, donde cualquier factor multiplicativo independiente de σ^2 se absorbe en la constante de normalización:

1. **El Jacobiano de la transformación:** Al aplicar el cambio de variable de Lamperti a los N incrementos de la trayectoria aumentada, se mantiene intacto el factor de escala inicial $(\sigma^2)^{-\frac{N}{2}}$.
2. **La Deriva de Girsanov y $C(\sigma)$:** Como demostramos en el desarrollo algebraico anterior, el exponente de la deriva se descompuso en $-\frac{E_{SSE}}{2\sigma^2}$ más los términos residuales $(\frac{\alpha D_3}{2} + \beta D_6)$. Dado que estos residuales son independientes de σ^2 , su exponencial es una constante en este paso y se descarta. Por su parte, la función constante $C(\sigma) = -\frac{1}{2}D_1 - \frac{\sigma^2 D_3}{8}$ se divide de manera similar: el término $-\frac{1}{2}D_1$ se absorbe, dejando únicamente la corrección de Itô $-\frac{\sigma^2 D_3}{8}$.
3. **El componente difusivo puro:** En la exponencial correspondiente a los incrementos brownianos, factorizamos el coeficiente escalar $\frac{1}{2\sigma^2}$ hacia afuera de la suma. Para

aislar la información pura de la trayectoria, definimos esta suma como la *Variación Cuadrática Aumentada* (Q_{aug}):

$$Q_{\text{aug}} = \sum_{k=1}^N \frac{(\ln X_k - \ln X_{k-1})^2}{\Delta t_k}. \quad (3.44)$$

Al agrupar estos tres componentes, la verosimilitud vista como función de la volatilidad se reestructura como:

$$L(\sigma^2 | \cdot) \propto \underbrace{(\sigma^2)^{-\frac{N}{2}}}_{\text{Jacobiano}} \cdot \underbrace{\exp\left(-\frac{E_{\text{SSE}}}{2\sigma^2}\right) \cdot \exp\left(-\frac{\sigma^2 D_3}{8}\right)}_{\text{Deriva de Girsanov y } C(\sigma)} \cdot \underbrace{\exp\left(-\frac{Q_{\text{aug}}}{2\sigma^2}\right)}_{\text{Difusión}}. \quad (3.45)$$

Para completar la aplicación del Teorema de Bayes, debemos especificar nuestra distribución a priori para el parámetro de difusión, denotada como $\pi(\sigma^2)$. En la estadística bayesiana, cuando la verosimilitud presenta términos donde el parámetro de interés aparece en el denominador de un exponente (es decir, en factores proporcionales a $\exp(-\text{constante}/\sigma^2)$), la elección matemática natural es una distribución de la familia Gamma Inversa. Esta elección garantiza la propiedad de conjugación, lo que significa que el producto de las densidades conservará la misma estructura algebraica [16, 55].

Adoptamos por tanto el prior $\sigma^2 \sim \text{IG}(a_0, b_0)$, donde a_0 representa el parámetro de forma y b_0 el parámetro de escala. La función de densidad de probabilidad de esta distribución está dada por:

$$\pi(\sigma^2) \propto (\sigma^2)^{-(a_0+1)} e^{-\frac{b_0}{\sigma^2}}. \quad (3.46)$$

El paso final consiste en multiplicar este prior por la verosimilitud $L(\sigma^2 | \cdot)$ estructurada en el paso anterior. Al realizar este producto explícito, aplicamos las leyes de los exponentes para agrupar, por un lado, las potencias de la base (σ^2) y, por otro, los argumentos de las funciones exponenciales que comparten el recíproco $1/\sigma^2$. El término de corrección de Itô, al estar multiplicado por σ^2 en el numerador, se mantiene factorizado al final de la expresión. De esta forma, desarrollamos la densidad condicional posterior exacta:

$$\begin{aligned} \pi(\sigma^2 | Y^*, \alpha, \beta) &\propto \underbrace{(\sigma^2)^{-(a_0+1)} e^{-\frac{b_0}{\sigma^2}}}_{\text{Prior } \pi(\sigma^2)} \cdot \underbrace{(\sigma^2)^{-\frac{N}{2}} \cdot \exp\left(-\frac{E_{\text{SSE}}}{2\sigma^2}\right) \cdot \exp\left(-\frac{\sigma^2 D_3}{8}\right) \cdot e^{-\frac{Q_{\text{aug}}}{2\sigma^2}}}_{\text{Verosimilitud } L(\sigma^2 | \cdot)} \\ &\propto \left[(\sigma^2)^{-(a_0+1)} (\sigma^2)^{-\frac{N}{2}} \right] \exp\left(-\frac{b_0}{\sigma^2} - \frac{E_{\text{SSE}}}{2\sigma^2} - \frac{Q_{\text{aug}}}{2\sigma^2}\right) \exp\left(-\frac{D_3}{8} \sigma^2\right) \\ &\propto (\sigma^2)^{-(a_0 + \frac{N}{2} + 1)} \exp\left(-\frac{1}{\sigma^2} \left[b_0 + \frac{E_{\text{SSE}} + Q_{\text{aug}}}{2}\right]\right) \exp\left(-\frac{D_3}{8} \sigma^2\right). \end{aligned} \quad (3.47)$$

Esta expresión es el núcleo de nuestro esquema de estimación para la volatilidad. Al analizarla, observamos que los datos (tanto los observados como los aumentados) actualizan los parámetros de la Gamma Inversa, donde el nuevo parámetro de forma es $\tilde{a} = a_0 + \frac{N}{2}$ y el de escala es $\tilde{b} = b_0 + \frac{E_{\text{SSE}} + Q_{\text{aug}}}{2}$. Sin embargo, la presencia del término exponencial residual $\exp(-\frac{D_3}{8} \sigma^2)$ introduce una complicación analítica que impide el muestreo directo, lo que motiva la implementación de una estrategia de simulación más avanzada.

3.6.3. Estrategia de muestreo: Metropolis-within-Gibbs

La forma funcional obtenida anteriormente revela que la distribución posterior de σ^2 casi pertenece a la familia Gamma Inversa, de no ser por el término $\exp(-D_3\sigma^2/8)$. Este factor adicional es un residuo de las correcciones de Itô necesarias para mantener la consistencia entre la escala original de las tasas y la escala logarítmica de Lamperti durante el cambio de medida. Debido a que este término rompe la conjugación estricta, la distribución resultante no puede muestrearse de forma directa mediante algoritmos convencionales. Para superar este obstáculo, el algoritmo implementa un paso de Metropolis-Hastings Independiente dentro del muestreador de Gibbs, una técnica conocida como Metropolis-within-Gibbs [56, 48].

La lógica de esta estrategia consiste en utilizar la distribución Gamma Inversa “base” (la que surge de ignorar el término de Itô) como una distribución de propuesta, denotada por $q(\sigma^2) = \text{IG}(\tilde{a}, \tilde{b})$. En cada iteración del muestreador, se genera un valor candidato σ_*^2 directamente de esta propuesta. Dado que la verdadera distribución objetivo π se puede ver como el producto de esta propuesta y la perturbación exponencial de Itô, la probabilidad de aceptación de este candidato se simplifica drásticamente. En lugar de evaluar densidades complejas, solo necesitamos comparar el impacto del término de Itô en el valor propuesto frente al valor actual de la cadena.

En un algoritmo de Metropolis-Hastings Independiente, la probabilidad de aceptación γ para transitar de un estado actual σ_{actual}^2 a un estado candidato σ_*^2 propuesto por una densidad $q(\cdot)$, se define de manera general como:

$$\gamma = \min \left(1, \frac{\pi(\sigma_*^2 | \cdot)}{\pi(\sigma_{\text{actual}}^2 | \cdot)} \times \frac{q(\sigma_{\text{actual}}^2)}{q(\sigma_*^2)} \right).$$

Como se demostró en el desarrollo algebraico previo, la distribución objetivo exacta $\pi(\sigma^2 | \cdot)$ puede factorizarse analíticamente como el producto de la densidad de propuesta (el núcleo de la Gamma Inversa, q) y el factor de perturbación exponencial proveniente del Lema de Itô. Es decir:

$$\pi(\sigma^2 | \cdot) \propto q(\sigma^2) \exp \left(-\frac{D_3}{8} \sigma^2 \right).$$

Al sustituir esta factorización directamente en el cociente de probabilidades de aceptación, obtenemos:

$$\gamma = \min \left(1, \frac{q(\sigma_*^2) \exp \left(-\frac{D_3}{8} \sigma_*^2 \right)}{q(\sigma_{\text{actual}}^2) \exp \left(-\frac{D_3}{8} \sigma_{\text{actual}}^2 \right)} \times \frac{q(\sigma_{\text{actual}}^2)}{q(\sigma_*^2)} \right).$$

Notemos que los términos correspondientes a la densidad de propuesta $q(\cdot)$ se cancelan recíprocamente en el numerador y el denominador. Esta simplificación analítica reduce drásticamente el cálculo computacional, ya que la evaluación de la probabilidad de aceptación depende de manera exclusiva del cociente de la perturbación de Itô. Por consiguiente, la probabilidad de aceptación se reduce a la siguiente expresión explícita:

$$\gamma = \min \left(1, \frac{\exp \left(-\frac{D_3}{8} \sigma_*^2 \right)}{\exp \left(-\frac{D_3}{8} \sigma_{\text{actual}}^2 \right)} \right).$$

Si el valor propuesto es aceptado, la cadena se actualiza, de lo contrario, se conserva el valor previo. Este mecanismo garantiza que, a pesar de la no-conjugación, las muestras

generadas converjan exactamente a la distribución posterior que dicta la teoría continua [48].

A modo de recapitulación para la implementación computacional del algoritmo, es fundamental consolidar los estadísticos suficientes que deben extraerse numéricamente de las trayectorias aumentadas en cada iteración. Como se demostró previamente (3.32), estos estadísticos condensan toda la información necesaria para los cálculos matriciales y se evalúan mediante suma de Riemann sobre la trayectoria discreta:

$$D_1 = \ln \left(\frac{x_T}{x_0} \right), \quad D_2 = \frac{1}{x_0} - \frac{1}{x_T}, \quad D_3 = T, \quad D_5 = \int_0^T \frac{ds}{X_s^2}, \quad D_6 = \int_0^T \frac{ds}{X_s}.$$

Asimismo, recordamos que la Suma de Errores Cuadráticos Estándar (E_{SSE}), la cual actúa como la “energía” de la deriva y alimenta tanto la actualización del vector (α, β) como el cálculo de la escala para la volatilidad σ^2 , se evalúa algebraicamente a partir de dichos estadísticos como:

$$E_{\text{SSE}} = \alpha^2 D_3 + 2\alpha\beta D_6 + \beta^2 D_5 - 2(\alpha D_1 + \beta D_2).$$

Esta formulación cierra el ciclo del muestreador de Gibbs, permitiendo que la reconstrucción de trayectorias mediante puentes brownianos en el espacio transformado y la estimación bayesiana de parámetros se retroalimenten mutuamente. Este enfoque iterativo corrige de manera sistemática el sesgo de discretización, logrando recuperar la dinámica no lineal y la reversión a la media originales del modelo de Brennan-Schwartz con alta precisión analítica [5, 22].

Capítulo 4

Validación con Datos Sintéticos

4.1. Resumen del Algoritmo MCMC para la Implementación Computacional

Tras desarrollar la maquinaria matemática en el capítulo anterior, el siguiente paso es poner a prueba el modelo en la computadora. En esta parte repasamos cómo funciona el algoritmo de estimación y revisamos qué tan bien responde cuando le faltan datos.

4.1.1. Pasos del algoritmo MCMC

Con las distribuciones condicionales y la estrategia de muestreo ya definidas, el algoritmo de estimación se organiza en un ciclo de varias repeticiones. Este esquema permite generar trayectorias para los datos que no vemos y actualizar los parámetros del modelo de Brennan-Schwartz de forma alternada. Como mencionamos antes, esto resuelve el problema de que necesitamos la trayectoria para estimar los parámetros, pero ocupamos los parámetros para reconstruir la trayectoria. El proceso sigue estos pasos [5, 55]:

1. **Inicio:** Comenzamos asignando valores iniciales a los parámetros $(\alpha^{(0)}, \beta^{(0)}, \sigma^{(0)})$. Aunque estos valores son arbitrarios, una buena elección ayuda a que el algoritmo encuentre más rápido la solución .
2. **Aumento de datos:** En cada intervalo donde faltan datos entre dos observaciones (x_{i-1}, x_i) , simulamos una trayectoria de alta frecuencia. Para esto, llevamos las observaciones al espacio de difusión unitaria con la transformación de Lamperti. Ahí trazamos un puente browniano y luego regresamos al espacio original con la función inversa. Este paso nos asegura que las tasas reconstruidas siempre sean positivas [36, 44].
3. **Cálculo de estadísticos:** Con la trayectoria ya completa, calculamos los estadísticos suficientes D_1 a D_6 usando la regla del trapecio. Estos valores resumen toda la información necesaria de la curva para los siguientes cálculos, sin tener que guardar cada punto de la simulación [36, 31].
4. **Actualización de la deriva:** Usando los estadísticos extraídos y el valor actual de σ , calculamos el vector ν_σ y la matriz de precisión Λ_σ . Gracias a la forma exponencial de la verosimilitud, podemos obtener nuevos valores para la deriva (α, β) directamente de su distribución condicional completa $\theta^{(k+1)} \sim \mathcal{N}(\Lambda_\sigma^{-1} \nu_\sigma, \Lambda_\sigma^{-1})$ [33, 37].

5. **Actualización de la volatilidad:** Calculamos la suma de errores cuadráticos (E_{SSE}) con la deriva que acabamos de actualizar. Debido a que la corrección de Itô impide usar una distribución directa, aplicamos un paso de Metropolis-Hastings. Proponemos un nuevo valor de σ^2 desde una distribución Gamma Inversa base $q(\sigma^2)$ y decidimos si lo aceptamos evaluando qué tanto influye la perturbación de Itô, garantizando la convergencia a la distribución objetivo $\pi(\sigma^2 | Y^*, \alpha, \beta)$ [48, 56].

Este ciclo se repite N_{iter} veces, generando una Cadena de Markov cuya distribución estacionaria converge a la distribución posterior conjunta de los parámetros y las trayectorias latentes.

4.1.2. Diseño del Experimento y Validación en Trayectoria Única

Para verificar la respuesta del algoritmo en un entorno controlado, realizamos una primera etapa de pruebas con datos simulados. Esta validación se estructuró en dos fases: un diagnóstico detallado sobre una sola trayectoria, con el fin de revisar que la cadena de datos se estabilice y explore correctamente el espacio de parámetros, y un experimento de Monte Carlo posterior, diseñado para confirmar la confiabilidad estadística de los estimadores bajo diferentes realizaciones del proceso.

Para la prueba de diagnóstico, utilizamos la trayectoria sintética descrita en el capítulo anterior, generada mediante el esquema de Milstein con los parámetros reales $\alpha = -0,5$, $\beta = 1,0$ y $\sigma = 0,3$. La serie original cuenta con 3,650 observaciones diarias a lo largo de 10 años. Sin embargo, para poner a prueba la robustez del modelo ante la escasez de información, aplicamos un submuestreo con un factor de recorte $k = 15$. Esto reduce los datos disponibles a solo 244 puntos, dejando huecos de aproximadamente dos semanas entre cada observación, lo que representa un escenario de baja frecuencia similar al que se encuentra en ciertos indicadores económicos reales [31].

La elección de las distribuciones a priori responde a criterios de conjugación analítica y objetividad estadística. Para el vector de deriva (α, β) , se asignó un prior Normal Multivariado con una matriz de precisión cercana a cero ($\Sigma_0^{-1} = 10^{-4}I_2$). Esta estructura plana garantiza que la inferencia sea dominada íntegramente por la verosimilitud de los datos y preserva la conjugación gaussiana deducida vía Girsanov. Por otro lado, para el parámetro de difusión σ^2 , se optó por una distribución Gamma Inversa con hiperparámetros $a_0 = 2,0$ y $b_0 = 0,05$ [4, 16]. Esta distribución respeta la restricción de positividad estricta de la varianza y actúa como el núcleo conjugado natural para el término de variación cuadrática de la verosimilitud, facilitando la eficiencia algorítmica del paso de Metropolis-within-Gibbs.

Para garantizar la robustez del diagnóstico y comprobar la ergodicidad de las cadenas de Markov generadas, el muestreador se inicializó deliberadamente con un vector de parámetros $(\alpha^{(0)} = -0,1, \beta^{(0)} = 0,5, \sigma^{(0)} = 0,5)$ alejado de la configuración real del proceso para verificar su capacidad de convergencia, y se ejecutaron 10,000 iteraciones del muestreador de Gibbs. De este total, se descartaron las primeras 500 iteraciones como periodo de calentamiento o burn-in, asegurando que los resultados analizados correspondan a la distribución estacionaria de la cadena [48]. En las secciones siguientes, utilizaremos gráficas de diagnóstico como trazas de la cadena e histogramas de densidad para evaluar si los parámetros estimados logran recuperar los valores originales a pesar de la pérdida masiva de información.

4.2. Implementación Computacional y Resultados Iniciales

La traducción del marco teórico a un entorno computacional requiere de una arquitectura eficiente que minimice el costo de evaluación en cada iteración. Para ello, el algoritmo fue implementado en el lenguaje de programación R, estructurando el proceso en dos funciones principales: un generador estocástico de puentes brownianos y el motor principal del muestreador de Gibbs.

El código utilizado se presenta en el apéndice, donde se puede observar la correspondencia directa entre la teoría de ecuaciones diferenciales estocásticas y su ejecución numérica.

4.2.1. Resultados Iniciales y Eficiencia del Muestreador

Al ejecutar este algoritmo sobre la trayectoria única de prueba descrita en la sección anterior (9,500 iteraciones post burn-in), se obtuvieron los siguientes resultados para las medias posteriores:

Parámetro	Valor Real	Estimador Clásico ($k = 15$)	Estimador MCMC
Alpha (α)	-0.5000	-0.1401	-0.4466
Beta (β)	1.0000	0.6704	0.9974
Sigma (σ)	0.3000	0.4593	0.3090
<i>Tasa de Aceptación Sigma: 99.87 %</i>			

Cuadro 4.1: Comparativa de estimadores para una trayectoria única con datos escasos. Se contrasta el sesgo masivo del estimador clásico frente a la recuperación de la dinámica estructural lograda por el motor MCMC.

Los estimadores puntuales de la cadena cruda demuestran una recuperación excepcional de los parámetros estructurales. El nivel de ajuste (β) y la volatilidad (σ) convergen casi de manera idéntica a sus valores reales. Por su parte, la estimación de la fuerza de reversión a la media ($\alpha \approx -0,4466$) presenta una ligera desviación respecto a su valor real de $-0,5$, lo cual es un comportamiento matemáticamente esperado. En la teoría de inferencia para difusiones, los parámetros de deriva sufren del conocido sesgo de muestra finita (sesgo de Hurwicz) cuando el horizonte temporal es corto ($T = 10$ años) [45].

Adicionalmente, durante la ejecución, la fase de Metropolis-Hastings Independiente encargada de la actualización de la volatilidad registró una tasa de aceptación empírica del 99.87 %. Esta métrica confirma computacionalmente que la distribución de propuesta Gamma Inversa $q(\sigma^2)$, derivada analíticamente en el Capítulo 3, es una aproximación analítica casi perfecta a la distribución objetivo posterior $\pi(\sigma^2 | \cdot)$. El único factor de rechazo proviene de la minúscula perturbación introducida por la corrección de Itô ($\exp[-D_3\sigma^2/8]$). Esta alta tasa de aceptación garantiza una exploración sumamente eficiente del espacio paramétrico, sin los estancamientos típicos de los algoritmos de caminata aleatoria.

4.2.2. El Problema de la Autocorrelación Estructural

A pesar de la fluidez teórica demostrada por la tasa de aceptación del 99,87 %, el análisis directo de la cadena cruda oculta un problema intrínseco al marco de Data Aug-

mentation. Dentro del muestreador de Gibbs, la trayectoria latente continua (X_{path}) y el parámetro de difusión (σ) se encuentran matemáticamente acoplados a través del concepto de variación cuadrática.

Dado que en la Fase A la trayectoria se reconstruye utilizando la volatilidad de la iteración anterior, la curva resultante posee una rigidez estructural que obliga a que el nuevo valor de σ , calculado en la Fase C, sea numéricamente muy similar al anterior. Este fenómeno genera una alta dependencia temporal entre las muestras sucesivas, conocida como autocorrelación [48, 55]. Extraer inferencias directamente de esta cadena fuertemente correlacionada subestimaría los errores estándar de los estimadores, otorgando una falsa sensación de precisión. Por lo tanto, es imperativo someter las cadenas de Markov a un diagnóstico de convergencia y aplicar técnicas de raleo (thinning) si es necesario, antes de validar las distribuciones posteriores definitivas [22, 32].

Para visualizar la magnitud de este problema, se calculó la Función de Autocorrelación empírica (ACF, por sus siglas en inglés) para las cadenas crudas de los tres parámetros. La Figura 4.1 ilustra el decaimiento de la correlación $\hat{\rho}(\tau)$ conforme aumenta el rezago τ entre iteraciones.




Figura 4.1: Función de Autocorrelación (ACF) empírica para las cadenas crudas sin raleo. Las líneas rojas punteadas representan las bandas de confianza de Bartlett.

El análisis de esta gráfica revela un fenómeno fascinante y teóricamente congruente: los parámetros de la deriva (α y β), al ser actualizados directamente desde una distribución Normal Multivariada condicionada (Fase B), presentan una memoria nula, su autocorrelación cae a cero de forma inmediata en el primer rezago. En contraste, el parámetro de volatilidad (σ) presenta un decaimiento sumamente lento. Esta persistencia (comportamiento de “resbaladilla”) es la prueba de la correlación estructural entre σ y la variación cuadrática de la trayectoria aumentada [48].

4.2.3. Tamaño Efectivo de Muestra (ESS) y Factor de Raleo

Para purificar la cadena y extraer conclusiones estadísticamente válidas, es necesario aplicar un factor de raleo (thinning), el cual consiste en conservar solo una de cada k iteraciones. Para determinar este salto óptimo sin recurrir a la inspección visual subjetiva, se calculó el Tamaño Efectivo de Muestra (ESS - *Effective Sample Size*).

El ESS es una métrica analítica que cuantifica cuántas observaciones verdaderamente independientes y no correlacionadas existen dentro de una cadena de Markov autocorrelacionada [48, 55]. Su cálculo se realizó utilizando la paquetería especializada `coda` en R, extrayendo la sub-cadena de volatilidad posterior al periodo de calentamiento (9,500 iteraciones)

El análisis reveló un ESS de $\approx 347,3$. Esto significa que, de las 9,500 iteraciones útiles procesadas por el algoritmo, únicamente se dispone de información matemática equivalente a 347 muestras “efectivas”, es decir, observaciones estocásticamente independientes.

Con este valor, el cálculo del factor de raleo k_{thin} se vuelve trivial. Para garantizar la destrucción absoluta de la memoria de la cadena, el salto empírico ideal se obtiene dividiendo el tamaño total de la muestra entre el ESS, redondeando hacia el entero superior para maximizar la seguridad:

$$k_{thin} = \left\lceil \frac{9500}{347,3053} \right\rceil = \lceil 27,35 \rceil = 28.$$

Al aplicar este salto ($k_{thin} = 28$) a la cadena original de volatilidad, obtenemos una sub-cadena depurada. La validación de esta purificación se observa en la Figura 4.2, donde se recalcula la Función de Autocorrelación para las muestras extraídas.




Figura 4.2: Validación de Independencia Estadística (ACF). Al aplicar un raleo de $k = 28$, la dependencia temporal se rompe drásticamente.

Como se puede observar en la gráfica inferior de la Figura 4.2, tras aplicar el raleo con un factor de salto de $k = 28$, la autocorrelación $\hat{\rho}(\tau)$ penetra inmediatamente el intervalo de confianza del 95 % de Bartlett (representado por las líneas rojas punteadas y dado analíticamente por $\pm 1.96/\sqrt{N_{eff}}$) a partir del primer rezago. Esta penetración consistente garantiza que no existe evidencia estadística para rechazar la hipótesis nula de independencia entre las muestras sucesivas, validada en código por una eficiencia relativa del 100 % (ESS = 340.00). Con esta sub-cadena purificada, el modelo queda matemáticamente blindado para proceder con la estimación de densidades y parámetros finales sin riesgo de subestimar la varianza posterior.

4.3. Distribuciones Marginales y Conjuntas (Resultados Definitivos)

Con las cadenas purificadas, analizamos las distribuciones posteriores marginales de los parámetros. La Figura 4.3 presenta el diagnóstico visual final del muestreador bayesiano.




Figura 4.3: Diagnóstico MCMC definitivo. Izquierda: Trazas raleadas mostrando una mezcla estacionaria perfecta. Derecha: Funciones de densidad núcleo (KDE) donde la estimación (línea punteada) coincide con la realidad de la simulación (línea continua).

Del lado izquierdo (las trazas), se observa un comportamiento estacionario, la cadena oscila alrededor de una media constante sin tendencias ascendentes ni descendentes, comprobando la convergencia a la distribución estacionaria [24, 32]. Del lado derecho, las densidades estimadas revelan formas de campana clásicas. Es particularmente notable el eje vertical de la densidad de σ : al estar tan concentrada la probabilidad en un intervalo diminuto, la densidad se dispara hasta valores de 50, evidenciando una varianza posterior (incertidumbre) casi nula para la volatilidad.

Para cuantificar la ganancia de información real obtenida mediante el Aumento de Datos, la Tabla 4.2 contrasta los estimadores puntuales finales (medias de la cadena raleada) frente a los resultados deficientes del estimador clásico analizado en el Capítulo 3 sobre los mismos datos faltantes ($k = 15$).

Parámetro	Valor Real	Estimador Clásico	Error Relativo	Estimador MCMC	Error Relativo
Alpha (α)	-0,5000	-0,1401	71,98 %	-0,4385	12,30 %
Beta (β)	1,0000	0,6704	32,96 %	0,9965	0,35 %
Sigma (σ)	0,3000	0,4593	53,10 %	0,3095	3,16 %

Cuadro 4.2: Comparativa definitiva de estimadores. El motor bayesiano restaura la arquitectura de la EDE, mitigando drásticamente el error inducido por la discretización severa.

Los resultados numéricos son contundentes: el algoritmo MCMC redujo la sobreestimación masiva del riesgo, llevando el error de la volatilidad (σ) de un inaceptable 53,10 % a un marginal 3,16 %. El nivel de inyección base (β) fue recuperado con una precisión virtualmente perfecta (error de 0,35 %).

En cuanto a la velocidad de reversión a la media ($\alpha \approx -0,4385$), es vital recalcar que esta desviación residual respecto al valor teórico ($-0,5$) no es una deficiencia del algoritmo, sino una consecuencia del sesgo de muestra finita (sesgo de Hurwicz). En el cálculo estocástico, la convergencia de la deriva está dictada por el horizonte temporal total (T), para un horizonte “corto” de 10 años, el estimador se sesga naturalmente hacia cero [45]. El hecho de que el MCMC elevara la estimación desde el colapso de $-0,14$ hasta $-0,4385$ demuestra la plena recuperación de la dinámica estructural a pesar de esta limitante [54].

Para comprender a fondo la estructura de la incertidumbre más allá de simples estimadores puntuales, la Figura 4.4 despliega la distribución posterior conjunta del vector de deriva (α, β).




Figura 4.4: Distribución Posterior Conjunta de la Deriva. El mapa de calor (KDE 2D) ilustra la topología probabilística del vector paramétrico. La orientación elíptica refleja la correlación para mantener el equilibrio a largo plazo ($-\beta/\alpha$). La cruz roja señala los parámetros reales, ubicada exactamente en la región de máxima verosimilitud bayesiana.

Dado que estamos estimando dos parámetros simultáneamente, esta gráfica debe in-

interpretarse como un mapa topográfico de probabilidades:

- **Los ejes:** El eje horizontal representa los posibles valores para la fuerza de reversión a la media (α), mientras que el eje vertical representa los posibles valores para la dirección del crecimiento (β).
- **Los colores (La “Montaña” de Probabilidad):** Las zonas en color morado oscuro representan regiones del espacio paramétrico que el algoritmo MCMC considera altamente improbables (el “nivel del mar”). Conforme el color transita hacia el verde y finalmente al amarillo brillante, la probabilidad aumenta. El núcleo amarillo central es la “cima de la montaña”, indicando la combinación de (α, β) donde el modelo tiene la mayor certeza.
- **La Cruz Roja:** Representa la Verdad absoluta de la simulación ($\alpha = -0,5, \beta = 1,0$), es decir, el objetivo que el algoritmo debía encontrar sin saber de antemano los valores de los parámetros.

El fenómeno visual más importante de esta gráfica es su geometría: la montaña no es un círculo perfecto, sino una elipse orientada diagonalmente hacia abajo. Esta forma (una fuerte correlación negativa) posee una profunda interpretación financiera ligada a la dinámica del modelo de Brennan-Schwartz establecida desde el Capítulo 1.

En este proceso estocástico, la deriva está dada por la ecuación lineal $(\alpha X_t + \beta)$. Si igualamos esta deriva a cero, encontramos que la tasa de interés posee un nivel de equilibrio asintótico a largo plazo igual a $-\beta/\alpha$. Durante la estimación, los datos le dictan al modelo dónde está ese punto de equilibrio. Por lo tanto, el algoritmo MCMC entiende que los parámetros operan en conjunto: si propone una fuerza de reversión a la media más débil (un valor de α menos negativo, moviéndose hacia la derecha en el eje X), está obligado a proponer una menor dirección de crecimiento constante (un β menor, moviéndose hacia abajo en el eje Y) para que el cociente $-\beta/\alpha$ siga apuntando exactamente al mismo nivel de equilibrio de largo plazo.

Esta dependencia estructural entre la reversión y el crecimiento constante es la que genera la elipse diagonal. Al inspeccionar la Imagen 4.4, es evidente que, aunque la cruz roja de los parámetros verdaderos no se ubica con precisión milimétrica en el centro geométrico del núcleo amarillo (la “cima” matemática del pico de probabilidad), sí se encuentra plenamente contenida dentro de la región amarilla de altísima densidad. Este resultado es estadísticamente coherente y esperado: puesto que la inferencia posterior proviene de una única realización finita del proceso (una trayectoria de 10 años con datos escasos), es natural que exista una leve discrepancia entre el pico máximo de certidumbre y el valor real debido al ruido de la muestra. El triunfo de nuestra metodología de Aumento de Datos se confirma porque el núcleo de máxima probabilidad bayesiana logra integrar exitosamente la verdad simulada dentro de su zona de mayor confianza, algo que los métodos clásicos no lograron.

4.3.1. Distribución Predictiva Posterior de las Trayectorias Latentes

Ahora vamos a ofrecer una representación visual del mecanismo interno que da nombre a la metodología de Aumento de Datos. Mientras que los enfoques clásicos se limitan a interpolar linealmente los vacíos de información, el enfoque bayesiano cuantifica la incertidumbre estocástica generando un abanico de posibilidades para los datos no observados.




Figura 4.5: Distribución Predictiva Posterior. La “nube” estocástica azul, generada mediante la propagación paramétrica, logra encapsular la verdadera trayectoria original no observada (línea negra).

La Figura 4.5 ilustra este fenómeno mediante la proyección de 20 realizaciones extraídas de la distribución predictiva posterior. Es fundamental aclarar que el algoritmo MCMC generó miles de estas trayectorias latentes durante el proceso iterativo de Gibbs, no obstante, para evitar la saturación gráfica y con fines estrictamente didácticos, se presenta únicamente una muestra representativa de 20 caminos independientes.

Estas trayectorias no son interpolaciones deterministas, sino verdaderos puentes brownianos construidos sobre la partición fina y mapeados dinámicamente sobre el espacio unitario de Lamperti [5, 25]. La geometría rugosa de alta frecuencia que exhibe cada una de estas líneas está dictada por distintas muestras del parámetro de volatilidad (σ), las cuales fueron extraídas directamente de la cadena paramétrica purificada. Al superponer estas simulaciones, se construye un enjambre estocástico que representa de manera gráfica la incertidumbre del modelo respecto al comportamiento de la tasa de interés entre las fechas de observación.

El resultado analítico más importante de esta proyección geométrica es comprobar la capacidad del enjambre para envolver y seguir de manera consistente a la verdadera trayectoria generadora original (representada por la línea negra, la cual permanece estrictamente inobservable para el algoritmo). Esta cobertura confirma visualmente que el esquema de verosimilitud aumentada, fundamentado en el teorema de Girsanov y la transformación de Lamperti, recupera la variación cuadrática perdida y resuelve de forma robusta el problema de la información faltante en la modelación financiera.

4.4. Validación Asintótica: Experimento de Monte Carlo

El diagnóstico exhaustivo sobre una trayectoria única demostró que el muestreador de Gibbs logra converger y explorar eficientemente la distribución posterior. Sin embargo, en estadística computacional, el éxito sobre una sola realización del proceso no es suficiente para garantizar la robustez metodológica, ya que los resultados podrían estar influenciados por características estocásticas particulares de esa simulación (una trayectoria afortunada).

Para confirmar la consistencia del estimador bayesiano y evaluar sus propiedades frecuentistas (sesgo promedio y error estándar), se diseñó un experimento de Monte Carlo masivo. El procedimiento consistió en simular 100 trayectorias independientes del modelo de Brennan-Schwartz bajo la misma parametrización original ($\alpha = -0,5, \beta = 1,0, \sigma = 0,3$) y el mismo régimen de escasez de datos ($k = 15$).

Para cada una de estas 100 realizaciones, se ejecutó el motor de inferencia MCMC de forma automatizada con 5,000 iteraciones, descartando las primeras 500 como periodo de calentamiento y aplicando el factor de raleo previamente validado ($k_{thin} = 28$) para extraer muestras estocásticamente independientes.

4.4.1. Análisis de Resultados Agregados

Para cada ejecución, se calculó la media posterior de los parámetros. La Tabla 4.3 resume las métricas descriptivas calculadas sobre el conjunto de estas 100 estimaciones independientes.

Parámetro	Valor Real	Media de las Posteriores	Desv. Estándar	Sesgo Promedio	Error Estándar
Alpha (α)	-0,5000	-0,48744	0,12876	0,01256	0,01288
Beta (β)	1,0000	0,96605	0,07197	-0,03395	0,00720
Sigma (σ)	0,3000	0,29531	0,01472	-0,00469	0,00147

Cuadro 4.3: Resultados del experimento Monte Carlo con 100 realizaciones independientes. El sesgo promedio se reduce a niveles marginales, validando la consistencia del estimador frente a datos submuestreados.

Para interpretar correctamente estos resultados, es fundamental definir qué representa cada métrica en el contexto de nuestro experimento. La **Media de las Posteriores** corresponde al promedio aritmético de las 100 estimaciones puntuales obtenidas, es decir, el valor central que nuestro modelo proyecta tras múltiples realizaciones independientes. La **Desv. Estándar** mide la dispersión empírica de estas 100 estimaciones, indicando qué tanto varían los resultados de una trayectoria a otra debido a la aleatoriedad propia del proceso. El **Sesgo Promedio** es la diferencia exacta entre la media estimada y el valor real subyacente, lo cual permite identificar si el algoritmo tiende a sobreestimar o subestimar de forma sistemática. Finalmente, el **Error Estándar** (calculado como la desviación estándar dividida por la raíz de las 100 simulaciones) cuantifica la precisión estadística con la que hemos estimado dicha media general.

Bajo estas definiciones, los resultados proporcionan evidencia matemática contundente sobre el éxito del esquema de verosimilitud aumentada. En primer lugar, respecto a la recuperación de la volatilidad, el parámetro σ (crítico para la valuación de riesgo en finanzas) presenta un sesgo promedio prácticamente nulo ($-0,00469$) y una desviación estándar empírica muy baja ($0,01472$). Adicionalmente su error estándar es diminuto

(0,00147), lo que confirma que el algoritmo no solo es insesgado en promedio, sino que goza de una varianza mínima entre diferentes experimentos. De forma paralela, el parámetro de nivel de ajuste (β) fue recuperado con alta precisión, arrojando un sesgo mínimo de $-0,03395$ y una desviación estándar contenida (0,07197), consolidando la estabilidad general de la estimación paramétrica.

En segundo lugar, el hallazgo más destacable reside en la mitigación del sesgo para la fuerza de reversión a la media (α). Durante el análisis previo de la trayectoria única, se observó un sesgo analítico residual provocado por la limitante de la muestra finita (estimando $\approx -0,43$). No obstante, al calcular el valor esperado sobre la medida de probabilidad conjunta del experimento masivo de Monte Carlo, el estimador promedio converge de manera exitosa a $-0,48744$ (exhibiendo una desviación estándar de 0,12876, la cual es natural dada la mayor dificultad matemática de estimar la reversión frente a la difusión). El sesgo promedio colapsa a tan solo 0,01256. Este resultado corrobora que el estimador bayesiano propuesto es asintóticamente insesgado y logra extraer la verdadera estructura económica del modelo, mitigando por completo el efecto de Hurwicz incluso bajo una pérdida severa de información.

4.4.2. Distribución Empírica de los Estimadores

Para visualizar el comportamiento de las estimaciones a lo largo del experimento, la Figura 4.6 despliega los histogramas de las medias posteriores obtenidas en las 100 simulaciones.




Figura 4.6: Distribución empírica de las medias posteriores en el experimento de Monte Carlo. La proximidad entre la línea roja sólida (Valor Real) y la línea punteada (Promedio MCMC) ratifica la ausencia de sesgos sistemáticos graves. Las curvas negras representan la densidad suavizada (KDE).

Esta representación gráfica constituye la demostración empírica del Teorema de Bernstein-von Mises en el contexto de nuestra metodología. El teorema dicta que, bajo ciertas condiciones de regularidad, la distribución posterior se aproxima a una distribución Normal centrada en el valor real conforme aumenta la información [59, 61].

En la Figura 4.6, observamos cómo las campanas de densidad (líneas negras continuas) adoptan formas fuertemente gaussianas, envolviendo de manera simétrica a las líneas rojas que marcan la verdad de la simulación. La coincidencia casi perfecta entre las líneas rojas (el norte objetivo) y las líneas punteadas (el centro de masa de nuestras estimaciones)

prueba que la imputación de puentes brownianos no inyecta desviaciones sistemáticas al proceso.

Con este experimento, se da por concluida la validación en el entorno sintético. Habiendo demostrado que el algoritmo de Metropolis-within-Gibbs con Aumento de Datos es computacionalmente estable, ergódico, y asintóticamente insesgado ante observaciones dispersas, la metodología queda formalmente habilitada para enfrentar el desafío final: la calibración del modelo de Brennan-Schwartz utilizando datos históricos reales del mercado de renta fija.

Capítulo 5

Aplicación Empírica del Modelo Brennan–Schwartz en Mercados de Bonos.

Tras haber validado la consistencia del algoritmo de Data Augmentation en un entorno controlado, en este capítulo enfrentamos la metodología a la complejidad de los mercados financieros reales. Como vimos en el capítulo anterior, el éxito en datos sintéticos es el primer paso, pero la prueba de fuego para cualquier modelo de tasas de interés es su capacidad de adaptación a series históricas donde la dinámica estocástica convive con ineficiencias institucionales y ruidos de mercado.

El objetivo de este capítulo es aplicar la metodología de Inferencia Bayesiana con Aumento de Datos a dos de los indicadores de deuda más relevantes para el mercado mexicano y global. A diferencia de las trayectorias perfectas generadas mediante el esquema de Milstein en el Capítulo 2, las series de tiempo reales no solo presentan una volatilidad estocástica errática, sino que están sujetas a un calendario institucional que interrumpe la observación del proceso.

Y es que un problema fundamental en la econometría financiera es el tratamiento de los periodos de inactividad, como fines de semana y días festivos. Los métodos clásicos suelen ignorar estos intervalos o tratarlos como saltos discretos, asumiendo implícitamente que la economía se detiene [23]. A través de la Inferencia Bayesiana, trataremos esos silencios informativos como variables latentes, permitiendo que el modelo recupere la trayectoria probable que la tasa siguió mientras el mercado permanecía cerrado [5, 22].

5.1. Naturaleza de los Datos y Análisis de Discontinuidad.

Para evaluar la versatilidad del modelo, hemos seleccionado dos instrumentos que, si bien operan bajo lógicas institucionales distintas, comparten la característica de ser activos de referencia para la construcción de curvas de rendimiento. El análisis se centrará en contrastar el comportamiento de un mercado con profundidad y liquidez global frente a uno con dinámicas de periodicidad más rígidas y dependientes de política monetaria local.

5.1.1. El Bono del Tesoro a 10 años ($\hat{\text{TNX}}$).

El rendimiento del Bono del Tesoro a 10 años de los Estados Unidos, comúnmente identificado por su ticker $\hat{\text{TNX}}$, es ampliamente reconocido como el activo financiero más importante del mundo. Este instrumento representa una obligación de deuda emitida por el Departamento del Tesoro de los Estados Unidos con un vencimiento a una década [58]. Su relevancia radica en que funciona como la tasa libre de riesgo de referencia global, sirviendo de base para la valoración de una infinidad de activos, desde créditos hipotecarios y corporativos hasta modelos de valuación de capitales (Equity) en mercados internacionales [27].

Históricamente, la importancia del TNX se consolidó tras el fin del sistema de Bretton Woods en la década de 1970, un periodo marcado por una volatilidad extrema en las tasas de interés que forzó el desarrollo de los modelos de difusión que utilizamos hoy en día [17]. El encargado de dictar la dirección de estas tasas es la Reserva Federal (Fed) a través de su política monetaria, sin embargo, al ser un bono de largo plazo, su rendimiento es movido principalmente por las expectativas de inflación, el crecimiento económico y los flujos de capital globales que buscan refugio en momentos de incertidumbre [58, 27].

Para este estudio, se ha seleccionado un horizonte temporal que inicia en el año 2003. Esta decisión busca garantizar una comparativa igualitaria con el mercado mexicano y capturar una muestra lo suficientemente extensa (más de dos décadas) que abarque diversos regímenes de volatilidad, desde la estabilidad previa a la crisis de 2008, el periodo prolongado de tasas cercanas a cero (Zero Lower Bound), hasta el reciente ciclo restrictivo global. La base de datos incluye observaciones diarias recolectadas hasta el 13 de marzo de 2026, fecha en la cual se realizó la última calibración del modelo y se obtuvieron los resultados finales de esta investigación.

Como se observa en la Figura 5.1, el $\hat{\text{TNX}}$ exhibe una trayectoria con una riqueza informativa notable, donde los cambios se dan de forma fluida día con día, lo que lo convierte en el candidato ideal para probar la eficiencia del algoritmo MCMC en mercados de alta frecuencia.




Figura 5.1: Evolución histórica del rendimiento del Bono del Tesoro a 10 años (2003-2026). Se aprecia la naturaleza continua del proceso y su sensibilidad ante eventos macroeconómicos globales.

La elección del $\hat{\text{TNX}}$ para esta investigación responde a su naturaleza como representante de un mercado de alta liquidez y profundidad. Desde la perspectiva del modelo, el $\hat{\text{TNX}}$ es lo más cercano que existe en la realidad a una trayectoria de difusión continua como la definida en el Capítulo 1. Sin embargo, incluso en el mercado más líquido del planeta, la observación del proceso se ve interrumpida por los cierres de fin de semana y días festivos de la bolsa de Nueva York.

Es común caer en la intuición errónea de que si el mercado está cerrado, el proceso estocástico simplemente se detiene o entra en una pausa. No obstante, la realidad económica es ininterrumpida, durante un sábado o un domingo la información sigue fluyendo, los riesgos geopolíticos evolucionan y las expectativas de los agentes cambian [23]. Cuando el mercado abre el lunes, el precio no inicia donde se quedó el viernes, sino que realiza un salto. Los métodos clásicos analizados en el Capítulo 2 tratan estos saltos como eventos discretos instantáneos. Al aplicar la metodología Bayesiana con Aumento de Datos, nuestra premisa es que existe una trayectoria latente durante esos silencios, entonces el algoritmo MCMC reconstruye probabilísticamente la variación cuadrática acumulada en el fin de semana, permitiendo una estimación de la volatilidad (σ) mucho más fiel a la realidad del riesgo continuo que el modelo de Brennan–Schwartz pretende capturar.

Finalmente, la elección de el $\hat{\text{TNX}}$ responde a que cumple con las características estructurales del modelo Brennan–Schwartz pues presenta una marcada reversión a la media dictada por los ciclos económicos y una volatilidad que tiende a ser proporcional al nivel de la tasa, especialmente en periodos de crisis inflacionarias donde niveles altos de tasas suelen venir acompañados de una mayor incertidumbre absoluta [17].

5.1.2. Los Certificados de la Tesorería (CETES 28).

En el contexto nacional, los Certificados de la Tesorería de la Federación (CETES) representan el instrumento de deuda más antiguo y emblemático del Gobierno de México. Emitidos por primera vez en 1978, los CETES son títulos de deuda pública que se colocan a descuento, funcionando como el pilar de la política monetaria y financiera del país [6]. El encargado de su emisión es la Secretaría de Hacienda y Crédito Público (SHCP), mientras que el Banco de México (Banxico) actúa como agente financiero en su colocación primaria.

La tasa de los CETES a 28 días es el indicador de referencia por excelencia para el sistema financiero mexicano. Sus movimientos están íntimamente ligados a la Tasa de Interés Interbancaria de Equilibrio (TIIE) y, fundamentalmente, a la tasa de referencia fijada por la Junta de Gobierno de Banxico en sus anuncios de política monetaria [6]. Este instrumento es movido por la inflación interna, el tipo de cambio peso-dólar y la prima de riesgo país que los inversionistas exigen para mantener deuda en mercados emergentes.

Un aspecto técnico a tener en cuenta en la construcción de esta tesis es la naturaleza de la serie histórica mexicana. Si bien existen registros de CETES desde finales de la década de 1970, el Banco de México comenzó a publicar la serie con periodicidad diaria en el mercado secundario formalmente el 16 de mayo de 2003 [7]. Antes de esto, la información se limitaba a frecuencias semanales (ancladas a las subastas primarias), quincenales o mensuales, lo que impediría una comparación homogénea con el estándar de alta frecuencia que buscamos.

Desde el punto de vista de la política económica, iniciar el análisis en 2003 es metodológicamente robusto. Este periodo coincide con la consolidación del régimen actual de Objetivos de Inflación y la modernización tecnológica de los sistemas de reporte financiero en México. Utilizar datos de los años 90 introduciría sesgos estructurales derivados

de crisis cambiarias y regímenes monetarios obsoletos que no corresponden a la dinámica de difusión que el modelo de Brennan–Schwartz pretende describir. Por tanto, la muestra se extiende desde mayo de 2003 hasta el 13 de marzo de 2026, como se muestra en 5.2, asegurando que los resultados reflejen la realidad operativa vigente del mercado de deuda nacional.




Figura 5.2: Trayectoria histórica de la tasa de rendimiento de los CETES a 28 días (2003-2026). Se observa la inercia institucional y los ajustes por escalones típicos de las decisiones de política monetaria en México.

La inclusión de los CETES en esta tesis es fundamental para contrastar el desempeño del modelo Brennan–Schwartz en un entorno de inercia institucional. A diferencia del $\hat{TNX}$, donde los precios se mueven por la interacción de millones de agentes en tiempo real, los CETES presentan una dinámica que se comporta mas escalonada. Debido a que las subastas primarias ocurren cada martes y el mercado secundario suele ser menos líquido que el estadounidense, la serie de tiempo muestra periodos de aparente inactividad seguidos de ajustes bruscos tras las decisiones de política monetaria.

Además, la elección de los CETES encaja perfectamente en la arquitectura de Brennan–Schwartz: existe un nivel de equilibrio de largo plazo ($-\beta/\alpha$) que en México ha estado históricamente anclado por los objetivos de inflación del banco central, y una volatilidad proporcional al nivel de la tasa que se vuelve evidente en los episodios de crisis financieras donde el incremento de las tasas nominales dispara la dispersión de los rendimientos. El enfoque Bayesiano propuesto en este trabajo pretende descubrir si, al recuperar la información perdida en los días no laborales y los huecos entre subastas, podemos obtener una calibración que no solo explique mejor el pasado, sino que sea más robusta para proyectar escenarios futuros de estrés en la economía nacional.

5.1.3. Diagnóstico de Irregularidad Temporal.

Una vez establecida la relevancia económica y el origen de las series de tiempo, es necesario llevar a cabo un análisis de la estructura temporal de las observaciones para cuantificar el grado de fragmentación al que se enfrentan los estimadores. La inferencia

en procesos de difusión parte del supuesto de una trayectoria ininterrumpida, sin embargo como ya mencionamos, en la práctica financiera, la presencia de huecos en la serie genera silencios informativos hace que la serie sea un conjunto de datos discretos con espaciamientos irregulares.

Para dimensionar esta problemática, se realizó un conteo de la frecuencia de los saltos temporales expresados en días naturales entre observaciones consecutivas. Los resultados comparativos se presentan en la Tabla 5.1, donde se desglosa el comportamiento tanto para el bono estadounidense como para los certificados mexicanos.

Instrumento	1 día	2 días	3 días	4 días	5 días
Bono del Tesoro ($\hat{\text{TNX}}$)	4562	57	1047	161	2
CETES 28 días	4499	59	1067	101	23

Cuadro 5.1: Frecuencia de saltos temporales en días naturales para las series analizadas (2003-2026). El predominio de saltos de un día refleja la actividad ordinaria, mientras que los valores superiores a representan los silencios de mercado por periodos no laborales.

Como se observa en los datos obtenidos, ambas series muestran una estructura dominada por las sesiones ordinarias de mercado. No obstante, existe una discontinuidad sistemática reflejada en más de mil ocurrencias de tres días por cada instrumento, las cuales corresponden a los cierres habituales de fin de semana, además también observamos saltos de 2 días relacionados a días festivos no laborables entre semana, y saltos de 4 días correspondientes a fines de semana largos, con un lunes o un viernes no laborable pegado a un fin de semana. Un hallazgo relevante en la serie de los certificados de la tesorería es la mayor frecuencia de saltos de cinco días en comparación con su contraparte estadounidense. Esto refleja una estructura de puentes festivos o interrupciones en los sistemas de reporte institucionales más prolongada en México, lo que incrementa la incertidumbre sobre la dinámica interna del proceso durante esos silencios de mercado.

La suma de estas irregularidades representa una cantidad masiva de intervalos donde la metodología clásica de Euler, analizada en capítulos previos, se ve forzada a ignorar la actividad estocástica. Al asumir de manera implícita que la economía se detiene mientras el mercado permanece cerrado, los métodos tradicionales incurren en un sesgo de discretización que puede comprometer la precisión de los parámetros estructurales. Matemáticamente, esta fragmentación es la que justifica la implementación de la técnica de aumento de datos, ya que permite tratar cada una de estas interrupciones temporales como una variable latente que debe ser reconstruida probabilísticamente para recuperar la verdadera variación cuadrática del activo [5, 48, 22].

5.2. Estimación Bayesiana con Aumento de Datos.

Habiendo identificado la magnitud de la fragmentación en las series de tiempo, el siguiente paso consiste en la ejecución de la inferencia estadística para la recuperación de los parámetros. Pero surge un reto técnico que obliga a realizar un refinamiento en el código utilizado hasta ahora. En la fase de validación con datos sintéticos detallada en el capítulo anterior, el algoritmo operaba bajo el supuesto de un factor de recorte constante, donde cada observación estaba separada por una distancia temporal idéntica. Dicha estructura permitía reconstruir las trayectorias latentes mediante puentes brownianos de longitud fija y una resolución uniforme en toda la serie.

Al enfrentar el modelo a datos históricos reales, este enfoque resulta insuficiente. Como se detalló en el diagnóstico de irregularidad, las brechas entre registros no son constantes, sino que oscilan entre uno y cinco días dependiendo del calendario de mercado. Aplicar una resolución fija a intervalos tan dispares introduciría distorsiones en la estimación de la variación cuadrática, un salto de fin de semana requiere una densidad de puntos latentes menor a la de un salto de 4 días para preservar la coherencia de la difusión. Por tanto, es necesario transitar hacia una implementación de puentes variables que reconozca la naturaleza cronológica de la base de datos [48, 22].

5.2.1. Implementación del Algoritmo MCMC.

La adaptación del muestreador de Gibbs para series de tiempo reales requiere que el motor de simulación lea directamente las fechas de observación y calcule, para cada intervalo, la diferencia exacta en días naturales. En esta implementación, el incremento temporal T_i deja de ser un escalar constante para convertirse en un vector de saltos temporales, los cuales son anualizados bajo la convención financiera de 365.25 días. Esta precisión es vital para que los parámetros de deriva y volatilidad mantengan una escala interpretable en términos anuales.

Para optimizar el costo computacional de procesar décadas de información diaria, el algoritmo realiza una pre-cálculo de estructuras de memoria y constantes matemáticas. En lugar de reconstruir la geometría de la interpolación lineal en cada iteración del MCMC, se genera una lista de constantes que almacena los pasos de tiempo finos, las desviaciones estándar teóricas y la línea base en el espacio de Lamperti para cada par de observaciones. Durante la fase de aumento de datos, el algoritmo simplemente inyecta el ruido estocástico del puente browniano sobre estas estructuras predefinidas, lo que acelera significativamente la convergencia de la cadena de Markov [22].

Asimismo, la transición a datos reales exige mecanismos de protección numérica para garantizar la estabilidad del algoritmo ante eventos de volatilidad extrema. Se incorporaron pisos de seguridad para evitar que el proceso se aproxime al cero de forma asintótica y salvaguardas mediante la captura de errores en la inversión de la matriz de precisión, previniendo que singularidades matemáticas detengan la ejecución. Como todo el código del trabajo, el núcleo del código desarrollado para esta aplicación empírica, el cual integra la lógica de puentes variables y las protecciones de robustez necesarias para el análisis de los mercados de deuda, se presenta en el apéndice.

5.2.2. Resultados de las Estimaciones.

Con el motor computacional robustecido para procesar calendarios irregulares, se realizó la calibración de los parámetros sobre la muestra completa de ambas series temporales. En esta fase se contrastan los estimadores obtenidos mediante el enfoque clásico de máxima verosimilitud y variación cuadrática frente a los resultados generados por el algoritmo de cadenas de Markov con Monte Carlo mediante aumento de datos.

Para la ejecución de este motor computacional, se definió un parámetro de resolución diaria (`res_diaria`) igual a cinco. Esta elección es por la necesidad de reducir el error de discretización dentro del esquema de Euler-Maruyama, analizado teóricamente en el segundo capítulo [36]. Mientras que en la fase de validación sintética se utilizó una resolución unitaria debido a que el entorno era controlado y la frecuencia de observación era constante, la irregularidad de los datos reales exige una malla más fina. Al asignar

cinco puntos latentes por cada día transcurrido, se garantiza que incluso en los saltos de un solo día el algoritmo opere con un paso de tiempo infinitesimalmente pequeño, lo que permite que las integrales estocásticas calculadas por el muestreador se aproximen con mayor fidelidad a su contraparte continua.

La primera evaluación corresponde al rendimiento del bono del tesoro estadounidense. Al ejecutar el muestreador de Gibbs con 10,000 iteraciones, se obtuvo una tasa de aceptación para el parámetro de volatilidad del 99.50 por ciento, lo que indica una eficiencia de muestreo sobresaliente. Los parámetros calculados para este instrumento se detallan en la Tabla 5.2.

Parámetro	Método Clásico	MCMC Continuo
α (Reversión a la media)	-0.1316	-0.1580
β (Dirección del crecimiento)	0.0054	0.0065
σ (Volatilidad difusiva)	0.3992	0.4365
Equilibrio de largo plazo ($-\beta/\alpha$)	4.07 %	4.09 %

Cuadro 5.2: Comparativa de estimación para el rendimiento del bono del tesoro a 10 años ($\hat{\text{TNX}}$) cubriendo el periodo 2003-2026.

En estos resultados del bono estadounidense se observa un fenómeno relevante respecto al parámetro de difusión. Mientras que el estimador clásico sitúa la volatilidad anualizada en 0.3992, el algoritmo MCMC la eleva a 0.4365. Esta diferencia representa la volatilidad latente que el método tradicional ignora al asumir que el proceso se detiene durante los fines de semana y días feriados. Al reconstruir probabilísticamente la trayectoria durante esos silencios informativos, el modelo de Brennan–Schwartz identifica una mayor acumulación de riesgo estocástico. Respecto a la deriva, se observa que el parámetro de velocidad de reversión α presenta una magnitud absoluta mayor en el enfoque bayesiano, pasando de -0.1316 a -0.1580, mientras que el parámetro β se ajusta de 0.0054 a 0.0065. Este incremento conjunto sugiere que, al considerar la actividad oculta en los periodos no laborales, el proceso manifiesta una fuerza de atracción hacia la media más vigorosa.

Es fundamental destacar que, a pesar de estos ajustes en la dinámica de corto plazo, el nivel de equilibrio de largo plazo permanece estable en torno al 4.08 por ciento con ambos métodos. Esta convergencia en el punto de equilibrio constituye un indicador de robustez para el algoritmo, ya que demuestra que la recuperación de la volatilidad y el ajuste de la reversión no distorsionan el ancla fundamental de la tasa, preservando la coherencia con la media histórica de la economía estadounidense durante las últimas dos décadas.

Posteriormente se realizó la estimación para los certificados de la tesorería mexicana. Para esta serie, el algoritmo registró una tasa de aceptación para la volatilidad del 99.85 por ciento, reflejando una convergencia casi perfecta a pesar de la inercia institucional característica de la tasa nacional. Los valores recuperados para los CETES 28 días se presentan en la Tabla 5.3.

Parámetro	Método Clásico	MCMC Continuo
α (Reversión a la media)	-0.1007	-0.1307
β (Dirección del crecimiento)	0.0071	0.0091
σ (Volatilidad difusiva)	0.2058	0.2312
Equilibrio de largo plazo ($-\beta/\alpha$)	7.08 %	6.95 %

Cuadro 5.3: Comparativa de estimación para la tasa de rendimiento de los CETES a 28 días en el mercado mexicano (2003-2026).

En este caso, la volatilidad recuperada mediante aumento de datos asciende a 0.2312 frente al 0.2058 del método clásico. Esta ganancia proporcional en la dispersión es mayor que la observada en el bono estadounidense, lo cual se explica por la presencia de huecos más prolongados en el calendario de reporte nacional. Asimismo, el parámetro de reversión a la media muestra una magnitud absoluta mayor en el MCMC, alcanzando un valor de -0.1307 frente al -0.1007 del estimador tradicional lo que sugiere que el activo posee una tendencia a regresar a su equilibrio con mayor fuerza de la que un análisis tradicional percibiría si solo considerara los días con registro oficial.

Al igual que en el caso anterior, la notable estabilidad del equilibrio de largo plazo, situado en el 7.08 por ciento, actúa como un validador interno de la metodología. El hecho de que ambos métodos coincidan en el centro de gravedad del proceso confirma que el aumento de datos está refinando la precisión de la trayectoria y la captura del riesgo sin desplazar las propiedades estructurales de la serie hacia valores ajenos a la realidad económica mexicana. La consistencia de estos resultados demuestra que el algoritmo es capaz de mitigar el suavizamiento artificial inducido por la discretización.

Es importante precisar que el incremento en los puntos entre días mencionado antes no es el responsable del aumento en el valor estimado de la volatilidad σ . En la teoría de procesos de difusión, la volatilidad es una propiedad estructural de la variación cuadrática del camino. El uso de una malla más densa no inyecta varianza artificial al sistema, más bien permite que el algoritmo de aumento de datos realice una evaluación más exacta de la energía del proceso en los intervalos de silencio. El incremento en la magnitud de σ observado en los resultados anteriores es consecuencia directa de permitir que la trayectoria se desvíe de la interpolación lineal durante los periodos no laborales, recuperando así la incertidumbre que el mercado acumuló mientras no existían registros oficiales.

Asimismo estos resultados demuestran que el algoritmo no solo es estable en mercados de alta liquidez, sino que es capaz de corregir el sesgo de suavizamiento artificial inducido por la discretización en instrumentos emergentes. Al recuperar estos parámetros latentes, el modelo queda calibrado de forma más robusta para enfrentar las pruebas de validación estadística y los ejercicios de proyección estocástica que se desarrollan en las secciones siguientes.

5.2.3. Diagnóstico de Convergencia de las Cadenas.

La validez de las estimaciones presentadas en las tablas anteriores depende de la consistencia estadística de las cadenas de Markov generadas por el muestreador de Gibbs. No es suficiente con reportar la media de una distribución, es necesario demostrar que el algoritmo exploró de manera exhaustiva el espacio de parámetros y que las muestras obtenidas son representativas de la distribución posterior [32]. Para verificar este comportamiento, se recurre a un diagnóstico visual que combina las gráficas de traza con las densidades marginales de cada variable.

Como se observa en las figuras 5.3 y 5.4, el análisis comienza con un periodo de descarte denominado burn-in, el cual se fijó en 500 iteraciones. Este intervalo, indicado por la línea punteada roja vertical en los paneles de la izquierda, sirve para mitigar la influencia de los valores iniciales y asegurar que el registro de muestras comience una vez que la cadena ha alcanzado su estado estacionario [24].

Un detalle técnico relevante en estas gráficas es la ausencia de una trayectoria errática desde el punto de partida hacia la zona de equilibrio. Esto ocurre porque el primer valor registrado en el vector de resultados ya ha pasado por la primera actualización completa

del motor de inferencia. Dado que el algoritmo es computacionalmente eficiente y los valores iniciales se eligieron en regiones financieramente razonables, la cadena encuentra su zona de estabilidad de forma casi inmediata, eliminando los largos periodos de transición que suelen presentarse en modelos menos robustos.




Figura 5.3: Diagnóstico de convergencia para el bono del tesoro estadounidense. Las trazas muestran una exploración estacionaria y las densidades confirman la concentración de probabilidad en torno a los valores reportados en la tabla de estimación.

A partir del periodo de descarte, las trazas de los parámetros α , β y σ exhiben un comportamiento oscilatorio constante alrededor de un valor central. La ausencia de tendencias crecientes o decrecientes es una señal de que el muestreador de Gibbs está navegando de forma óptima por el espacio de parámetros, lo cual garantiza que las muestras no están estancadas en óptimos locales. Este patrón de oscilación estable es lo que permite afirmar que la cadena ha logrado un buen mezclado, requisito indispensable para que las conclusiones estadísticas tengan validez asintótica.




Figura 5.4: Diagnóstico de convergencia para los certificados de la tesorería mexicana. Se observa una estabilidad notable en el parámetro de volatilidad, coherente con la alta tasa de aceptación registrada por el motor computacional.

Por otro lado, los paneles de la derecha presentan la estimación de la densidad posterior para cada parámetro tras haber aplicado un proceso de raleo. Este procedimiento tiene la función de reducir la autocorrelación entre las muestras, seleccionando únicamente aquellas que guardan un espaciamiento suficiente para ser tratadas como observaciones independientes. Las campanas de densidad resultantes permiten visualizar la incertidumbre del modelo: una base angosta indica que el algoritmo ha identificado el valor del parámetro con una alta precisión. Las líneas punteadas negras en estos diagramas coinciden con las medias posteriores calculadas, demostrando que nuestros estimadores finales son los centros de masa de distribuciones de probabilidad bien formadas y estacionarias.

Al contrastar estas distribuciones con los resultados del estimador clásico (representados por la línea punteada azul), se observa un comportamiento diferenciado entre los componentes de la dinámica. En los parámetros α y β , el valor obtenido mediante máxima verosimilitud se sitúa dentro de las regiones de masa de la distribución posterior, lo que sugiere que ambos métodos guardan una consistencia relativa respecto a la dirección y la tendencia del activo. Sin embargo, en el caso de la volatilidad σ , la línea del estimador clásico queda desplazada fuera de la campana de densidad generada por el MCMC. Este distanciamiento es la evidencia estadística de que el aumento de datos ha capturado una fuente de variabilidad latente que el método tradicional no podía percibir. El hecho de que la distribución bayesiana no incluya al valor clásico confirma que, al reconstruir las trayectorias durante los periodos de inactividad, el modelo identifica una estructura de riesgo más profunda y fiel a la naturaleza continua del mercado.

La consistencia visual observada en ambos mercados confirma que el algoritmo de aumento de datos es lo suficientemente robusto para operar bajo diferentes regímenes de volatilidad. Este diagnóstico asegura que las diferencias encontradas entre el método clásico y el enfoque bayesiano no son producto de una falta de convergencia, sino que reflejan la verdadera recuperación de información latente durante los periodos de inactividad del mercado.

5.3. Diagnóstico Estadístico del Modelo.

Tras haber verificado la convergencia y el correcto mezclado de las cadenas de Markov, resulta fundamental evaluar la calidad del ajuste del modelo de Brennan–Schwartz frente a la realidad de los datos observados. No basta con que el algoritmo sea estable, es necesario cuantificar en qué medida la incorporación de trayectorias latentes y la calibración bayesiana representan una mejora respecto a los métodos de estimación tradicionales. En esta sección se presentan diversas pruebas de bondad de ajuste y análisis de residuales que sirven como validación estadística del desempeño del modelo en ambos mercados.

5.3.1. Pruebas de Verosimilitud (Log-Likelihood).

La métrica primaria para comparar la capacidad explicativa de dos modelos estadísticos es la función de log-verosimilitud. Matemáticamente, este indicador mide la probabilidad de observar la serie de tiempo real dado un conjunto de parámetros y una estructura de difusión específica. En el contexto de esta investigación, comparamos la verosimilitud alcanzada por el estimador de máxima verosimilitud clásica frente a la verosimilitud evaluada en la media posterior obtenida mediante el algoritmo MCMC.

Para comprender el origen de esta métrica, debemos recordar que la función de verosimilitud, denotada como $\mathcal{L}(\theta \mid \mathbf{x})$, representa la densidad conjunta de una serie de observaciones $\mathbf{x} = \{x_0, x_1, \dots, x_n\}$ tratada como una función del vector de parámetros $\theta \in \Theta$. En el contexto de un proceso de difusión que cumple con la propiedad de Markov, como es el caso del modelo de Brennan–Schwartz, la densidad conjunta se puede descomponer mediante el producto de las densidades de transición condicionales [29, 38]:

$$\mathcal{L}(\theta; x_0, \dots, x_n) = f(x_0; \theta) \prod_{i=1}^n p(x_i, t_i \mid x_{i-1}, t_{i-1}; \theta), \quad (5.1)$$

donde $p(x_i, t_i \mid x_{i-1}, t_{i-1}; \theta)$ es la densidad de transición que describe la probabilidad de que el proceso se encuentre en el estado x_i en el tiempo t_i , dado que se encontraba en x_{i-1} en el tiempo t_{i-1} .

La transformación logarítmica de esta función, definida como $\ell(\theta) = \ln \mathcal{L}(\theta)$, se prefiere tanto en la estadística teórica como en la computacional por dos razones. En primer lugar, debido a que el logaritmo es una función monótona creciente, el valor de θ que maximiza la verosimilitud también maximiza su logaritmo, preservando las propiedades del estimador [16]. En segundo lugar, la operación logarítmica convierte el producto de densidades en una suma, lo cual mejora drásticamente la estabilidad numérica al evitar el desbordamiento por valores infinitesimales que suelen aparecer al multiplicar miles de densidades:

$$\ell(\theta) = \ln f(x_0; \theta) + \sum_{i=1}^n \ln p(x_i, t_i \mid x_{i-1}, t_{i-1}; \theta). \quad (5.2)$$

En la práctica, para un modelo de tasas de interés definido por una ecuación diferencial estocástica, la densidad de transición exacta suele ser desconocida o difícil de evaluar analíticamente. Por ello, recurrimos a la aproximación de Euler–Maruyama para intervalos de tiempo pequeños Δt . Bajo esta discretización, la densidad de transición entre dos observaciones consecutivas se aproxima mediante una distribución normal, donde la media y la varianza dependen de las funciones de deriva $\mu(x, \theta)$ y difusión $\sigma(x, \theta)$ del modelo de Brennan–Schwartz [36]:

$$x_i \mid x_{i-1} \sim \mathcal{N}(x_{i-1} + \mu(x_{i-1}, \theta)\Delta t, \sigma^2(x_{i-1}, \theta)\Delta t). \quad (5.3)$$

Para evaluar esta métrica de forma computacionalmente eficiente y numéricamente estable, se desarrolló una función en R que utiliza la log-densidad normal vectorizada. Este enfoque evita los errores de precisión que podrían surgir al calcular productos de probabilidades infinitesimales, permitiendo una comparación directa entre el estimador clásico y la media posterior obtenida mediante el MCMC.

Esta métrica permite realizar una comparación directa entre los métodos de estimación. Mientras que en el enfoque clásico se busca el punto θ_{MLE} que maximiza globalmente esta expresión bajo los datos crudos [37], en nuestra metodología bayesiana evaluamos esta misma función utilizando la media de la distribución posterior obtenida del algoritmo MCMC, la cual ha sido calibrada considerando la información latente de los puentes brownianos [5, 22, 48].

Al aplicar esta función a los parámetros recuperados, se obtuvieron los resultados comparativos que se detallan en las tablas siguientes. Un valor de log-verosimilitud más elevado indica que el modelo explica mejor la variabilidad de los datos. En este sentido, una diferencia positiva a favor del modelo MCMC indica que la configuración de parámetros obtenida mediante el aumento de datos hace que la trayectoria histórica observada sea mucho más probable bajo la dinámica de difusión propuesta.

Para el rendimiento del bono del tesoro estadounidense, los resultados numéricos se presentan en la Tabla 5.4.

Método de Estimación	Log-Verosimilitud (LL)
Método Clásico	33693.61
Muestreador MCMC	33761.30
Diferencia	67.69 unidades

Cuadro 5.4: Comparativa de Log-Verosimilitud para el bono del tesoro a 10 años ($\hat{\text{TNX}}$).

En el caso del $\hat{\text{TNX}}$, la implementación con aumento de datos logra una ganancia de 67.69 unidades de verosimilitud. Dado que estamos operando en una escala logarítmica, una diferencia de esta magnitud es estadísticamente contundente. Este incremento sugiere que al permitir que la volatilidad y la reversión a la media se ajusten considerando la trayectoria probable durante los fines de semana, el modelo de Brennan–Schwartz encuentra una configuración de parámetros que hace que los datos observados sean mucho más probables bajo la dinámica de difusión propuesta.

Por otro lado, la evaluación para los certificados de la tesorería mexicana arroja una disparidad todavía más marcada. Los resultados para la serie de los CETES 28 días se detallan en la Tabla 5.5.

Método de Estimación	Log-Verosimilitud (LL)
Método Clásico	32682.33
Muestreador MCMC	32771.69
Diferencia	89.36 unidades

Cuadro 5.5: Comparativa de Log-Verosimilitud para los CETES a 28 días.

Para el mercado mexicano, la diferencia a favor del enfoque bayesiano asciende a 89.36 unidades. Esta superioridad numérica se alinea con el diagnóstico de irregularidad temporal presentado al inicio de este capítulo: dado que la serie de los CETES presenta silencios informativos más prolongados y frecuentes, el beneficio de reconstruir la trayectoria latente es mayor. La log-verosimilitud superior del MCMC confirma que el método clásico, al ignorar los periodos de inactividad, fuerza al modelo a una configuración subóptima que no logra capturar la verdadera esencia estocástica de la tasa nacional.

El hecho de que en ambos instrumentos el MCMC supere significativamente al método clásico demuestra que el aumento de datos no es una simple sofisticación algorítmica, sino una herramienta de corrección estadística necesaria. Al rellenar los huecos del calendario con puentes brownianos que respetan la estructura de la EDE de Brennan–Schwartz, logramos que la función de verosimilitud reconozca una continuidad que el mercado posee intrínsecamente, pero que la discretización de los registros oculta. Esta mejora en la verosimilitud es el primer indicador sólido de que los parámetros recuperados en las secciones anteriores poseen una validez superior para describir la dinámica de los mercados de deuda.

5.3.2. Análisis de Residuales.

Tras evaluar la capacidad explicativa del modelo mediante la verosimilitud, es necesario realizar un diagnóstico sobre la estructura de los errores para verificar si se cumplen los supuestos teóricos de la difusión. En la formulación analítica del primer capítulo, establecimos que la dinámica de las tasas de interés está impulsada por un proceso de Wiener, cuyas trayectorias son continuas pero poseen variaciones estocásticas gaussianas. El análisis de residuales permite comprobar qué tanta información de la serie original ha sido capturada por la deriva y la difusión, y qué parte permanece como un ruido blanco no explicado.

Matemáticamente, definimos los residuales estandarizados a partir de la discretización de Euler–Maruyama. Partiendo de la ecuación diferencial del modelo de Brennan–Schwartz, el incremento de la tasa en un intervalo pequeño Δt se expresa como:

$$x_i - x_{i-1} = (\alpha x_{i-1} + \beta)\Delta t + \sigma x_{i-1}\sqrt{\Delta t}\epsilon_i, \quad (5.4)$$

donde ϵ_i representa una variable aleatoria que, bajo el supuesto del modelo, sigue una distribución normal estándar $\mathcal{N}(0, 1)$. Para validar esta premisa, aislamos el término de perturbación estocástica, obteniendo la fórmula de los residuales estandarizados $\hat{\epsilon}_i$:

$$\hat{\epsilon}_i = \frac{(x_i - x_{i-1}) - (\alpha x_{i-1} + \beta)\Delta t}{\sigma x_{i-1}\sqrt{\Delta t}}. \quad (5.5)$$

Esta expresión mide la diferencia entre el cambio observado en la tasa y el cambio esperado por la deriva del modelo, normalizada por la volatilidad local. Si el modelo describe perfectamente la realidad del mercado, el conjunto de residuales resultantes debería

comportarse como una secuencia de variables independientes e idénticamente distribuidas provenientes de una normal estándar [54].

Para evaluar formalmente la normalidad de estos residuales, aplicamos la prueba de Shapiro–Wilk [50] (con la función `shapiro.test` de R) sobre los errores generados tanto por el método clásico como por la media posterior del MCMC. Los resultados de este diagnóstico se detallan en la Tabla 5.6.

Instrumento	P-value (Clásico)	P-value (MCMC)
Bono del Tesoro	$6,6329 \times 10^{-60}$	$1,0352 \times 10^{-59}$
CETES 28 días	$1,1587 \times 10^{-64}$	$1,3381 \times 10^{-63}$

Cuadro 5.6: Diagnóstico de normalidad mediante la prueba de Shapiro–Wilk. Valores menores a 0.05 indican un rechazo categórico de la hipótesis nula de normalidad.

Los resultados numéricos revelan un rechazo absoluto de la normalidad en ambos mercados y para ambos métodos de estimación. El hecho de que los valores p sean órdenes de magnitud cercanos a cero sugiere que, aunque el modelo de Brennan–Schwartz es la mejor aproximación difusiva disponible, existen características intrínsecas en las tasas de interés que no pueden ser explicadas únicamente por un movimiento browniano. Este fenómeno es una constante en la econometría financiera y se debe a la presencia de leptocurtosis (colas pesadas), donde el mercado experimenta cambios bruscos con una frecuencia muy superior a la predicha por una campana de Gauss [19].

Para profundizar en el origen de este rechazo, se analizan los gráficos de probabilidad normal (Q-Q Plots). En la Figura 5.5 se presenta el diagnóstico para el mercado estadounidense, mientras que en la Figura 5.6 se observa el caso mexicano.




Figura 5.5: Gráfico Q-Q de residuales para el bono del tesoro estadounidense. Se observa un ajuste adecuado en la zona central, pero desviaciones significativas en los extremos.




Figura 5.6: Gráfico Q-Q de residuales para los certificados de la tesorería mexicana. La presencia de leptocurtosis es evidente, confirmando que el mercado presenta eventos de cola más frecuentes de lo que predice la normalidad.

Al observar estas gráficas, es posible notar que los puntos se alinean con la recta teórica en la región central de la distribución, lo que indica que el modelo captura correctamente los movimientos cotidianos de las tasas. Sin embargo, en los extremos de las colas, los residuales se disparan formando una silueta en forma de S. En el caso del bono estadounidense, las colas reflejan episodios de volatilidad global que generan choques externos. En el caso de los CETES, esta desviación es aún más pronunciada debido a la inercia institucional. Como ya hemos discutido, los ajustes de política monetaria en México ocurren en fechas discretas, generando saltos que el componente difusivo del modelo no puede absorber con una distribución normal [47].

Esta discrepancia se cuantificó formalmente mediante la prueba de Kolmogorov–Smirnov (K–S), ejecutada con la función `ks.test` de R. A diferencia de Shapiro–Wilk, el test K–S evalúa la máxima distancia vertical (D) entre la distribución acumulada de los residuales y la normalidad teórica $\mathcal{N}(0, 1)$, proporcionando una medida de la desviación global del modelo. Los resultados se detallan en la Tabla 5.7.

Mercado / Método	Estadístico D	p -value
Tesoro (Clásico)	0.0724	$5,33 \times 10^{-27}$
Tesoro (MCMC)	0.0901	$1,64 \times 10^{-41}$
CETES (Clásico)	0.1646	$9,43 \times 10^{-136}$
CETES (MCMC)	0.1773	$2,35 \times 10^{-157}$

Cuadro 5.7: Prueba de Kolmogorov–Smirnov para los residuales estandarizados.

En ambos mercados, el estadístico D es ligeramente superior para el método MCMC, este resultado indica que el algoritmo bayesiano es más sensible a la naturaleza no continua de las tasas, mientras que el método clásico tiende a absorber parte del ruido discreto en la estimación de los parámetros para minimizar el error, el MCMC preserva la integridad de la difusión continua, dejando al descubierto los saltos institucionales en los residuales [22, 48].

Además, mientras que en el mercado estadounidense esta distancia alcanzó un valor de $D = 0,0901$ para el estimador MCMC, en el caso de los CETES el estadístico se elevó significativamente hasta $D = 0,1773$. Este incremento sustancial ratifica matemáticamente que la carga institucional en México aleja al proceso de la continuidad gaussiana con mayor severidad que en el tesoro estadounidense. Más allá de la comparación entre mercados, la convergencia de todos los p -values hacia un rechazo absoluto ($p \approx 0$) actúa como una confirmación robusta de que el ruido financiero no puede ser capturado íntegramente por un proceso de Wiener.

Cabe señalar que, si bien la presencia de valores repetidos (*ties*) en las cotizaciones originales genera advertencias técnicas en el cálculo, la magnitud de los estadísticos obtenidos confirma que el rechazo de la normalidad es una propiedad estructural del sistema y no un artefacto de la sensibilidad de las pruebas ante muestras grandes [19].

Es fundamental recalcar que estos resultados no invalidan la metodología bayesiana, sino que marcan el límite superior de ajuste para cualquier modelo de difusión continua. Mientras que el modelo de Brennan–Schwartz asume una trayectoria gobernada por un proceso de Wiener continuo, las series de tiempo reales están sujetas a saltos y eventos de fatiga en las colas [47, 19]. Al forzar una herramienta de tiempo continuo en un entorno de eventos discretos y choques exógenos, el MCMC logra capturar la mejor aproximación difusiva posible, sin embargo, los residuales resultantes conservan la huella de esos componentes no continuos que la estructura de la EDE, por definición, no puede absorber.

Desde un punto de vista econométrico, esto sugiere que el límite no está en la estimación de los parámetros, sino en la propia estructura del modelo. Es decir, incluso con una calibración óptima, una difusión gaussiana no alcanza a reproducir completamente la dinámica real de las tasas, especialmente en presencia de colas pesadas y cambios abruptos [19, 40]. En este sentido, el rechazo sistemático de la normalidad en los residuales no debe interpretarse como una falla, sino como una señal clara de que existen componentes adicionales en la dinámica del mercado que quedan fuera del alcance del modelo.

El hecho de que el algoritmo MCMC alcance valores de verosimilitud superiores a pesar de la no-normalidad demuestra que el aumento de datos es resiliente y logra identificar la mejor configuración de parámetros posible dentro de un mercado que presenta fricciones y saltos institucionales. Lo que queda en los residuales es el ruido puro del sistema financiero que escapa a la continuidad pura, lo que nos permite proceder con confianza a las pruebas de desempeño fuera de la muestra, sabiendo que poseemos la calibración más robusta posible dentro del marco de las Ecuaciones Diferenciales Estocásticas.

5.4. Validación Predictiva Out-of-Sample.

Tras haber evaluado la capacidad del modelo para describir el pasado, la fase final y más rigurosa de esta investigación consiste en someter a los estimadores a una prueba de validación fuera de la muestra, conocida técnicamente como backtesting o validación predictiva. El objetivo fundamental no es solo demostrar que el modelo de Brennan–Schwartz puede ajustarse a una serie de datos histórica, sino verificar si los parámetros recuperados mediante el algoritmo MCMC poseen capacidad de generalización sobre periodos de tiempo que el modelo no conoció durante su entrenamiento. Esta sección es la última prueba del algoritmo, pues permite distinguir entre un ajuste estadístico (overfitting) y una verdadera captura de la dinámica estocástica de las tasas de interés.

5.4.1. Diseño del Experimento de Predicción.

Las bases de datos fueron divididas en dos conjuntos independientes: un conjunto de entrenamiento, que abarca todas las observaciones registradas desde el año 2003 hasta el 31 de diciembre de 2023, y un conjunto de prueba, que es el periodo desde el 1 de enero de 2024 hasta principios de 2026.

La elección del 1 de enero de 2024 como fecha de corte responde a una lógica de cambio de régimen en los mercados financieros globales. Tras el periodo de alta volatilidad y las agresivas subidas de tipos de interés iniciadas en 2022 por la Reserva Federal y el Banco de México para combatir la inflación post-pandemia, el inicio de 2024 marca el comienzo de una fase de estabilización o meseta en las tasas. Al situar el muro en este punto, sometemos al modelo de Brennan–Schwartz a una prueba crítica: verificar si los parámetros calibrados durante décadas de fluctuaciones y crisis recientes son capaces de capturar la dinámica de un mercado que intenta encontrar un nuevo equilibrio de largo plazo.

El procedimiento de validación consistió en re-estimar los parámetros utilizando exclusivamente la información del conjunto de entrenamiento. Para ello, se ejecutó el motor computacional bajo las mismas condiciones de rigor analizadas previamente: se realizaron 10,000 iteraciones del muestreador de Gibbs con una resolución diaria de cinco puntos latentes por cada observación real y un periodo de descarte (burn-in) de 500 iteraciones.

Este diseño permite contrastar el desempeño del enfoque bayesiano frente al método clásico no solo en términos de precisión puntual, sino de consistencia estocástica. El objetivo de la validación no es simplemente minimizar el Error Cuadrático Medio (RMSE), sino determinar si la recuperación de la volatilidad latente permite que el modelo represente de forma más realista la incertidumbre del mercado. Como se demostrará en los resultados subsecuentes, el valor del MCMC no reside necesariamente en una reducción universal del error de pronóstico, sino en su capacidad para capturar la verdadera energía estocástica de las tasas, evitando la subestimación del riesgo que suele presentar el método tradicional al ignorar los silencios informativos del calendario.

5.4.2. Trayectorias Predictivas y Bandas de Confianza.

Una vez implementado el proceso de re-estimación bajo el esquema de partición temporal descrito, se presentan en la Tabla 5.8 los parámetros obtenidos exclusivamente con la información del periodo de entrenamiento. Estos valores son importantes pues son desde donde se construirán las proyecciones estocásticas y las bandas de confianza necesarias para evaluar el desempeño del modelo frente a la trayectoria real observada a partir de 2024.

Parámetro	Bono Tesoro		CETES 28 Días	
	Clásico	MCMC	Clásico	MCMC
α (Reversión)	-0.1597	-0.1885	-0.0258	-0.0584
β (Deriva)	0.0058	0.0070	0.0042	0.0062
σ (Volatilidad)	0.4144	0.4532	0.2093	0.2346

Cuadro 5.8: Comparativa de estimadores obtenidos con el conjunto de entrenamiento (Muro de fuego: 1 de enero de 2024).

El análisis de estos estimadores muestra una tendencia consistente con lo observado in-sample: el algoritmo MCMC identifica una volatilidad σ superior en ambos instrumentos

y una velocidad de reversión a la media α más intensa. Para visualizar el impacto de estas diferencias, se generaron 1,000 trayectorias sintéticas a partir del último dato observado en diciembre de 2023, utilizando el esquema de Euler–Maruyama. Las bandas de confianza se construyeron tomando los cuantiles del 2.5 % y 97.5 % de estas simulaciones, lo que define el área donde se espera encontrar el 95 % de los datos reales si el modelo fuera correcto.




Figura 5.7: Bandas de confianza predictivas para el bono del tesoro a 10 años ($\hat{TNX}$). La zona sombreada representa el rango de probabilidad del 95 % proyectado desde 2024.

En la Figura 5.7 se observa el desempeño para el mercado estadounidense. Se puede notar que la banda generada por el MCMC es más amplia que la del método clásico (por ejemplo, superando valores de 0.09). Esta mayor amplitud no debe interpretarse como una falta de precisión, sino como una representación más fiel de la incertidumbre. Mientras que el método clásico proyecta una banda más estrecha al subestimar la volatilidad histórica (ignorando los fines de semana), el MCMC reconoce que el activo posee una mayor energía estocástica. Como resultado, la trayectoria real de 2024 y 2025 se mantiene contenida dentro de la banda bayesiana con mayor holgura, evitando falsos positivos de fuera de control que el modelo clásico podría señalar erróneamente.




Figura 5.8: Bandas de confianza predictivas para los CETES 28 días. Se observa la capacidad de las bandas MCMC para absorber la volatilidad del mercado mexicano.

Para el caso mexicano (Figura 5.8), la diferencia entre las bandas es aún más pronunciada. La serie de los CETES presentó una estabilidad relativa durante 2024, pero con episodios de volatilidad latente. La banda del MCMC, impulsada por una σ de 0.2346 frente al 0.2093 del clásico, logra cubrir un espectro de riesgo que el método tradicional considera improbable. Esta característica es crucial para la gestión de riesgos: una banda demasiado estrecha (como la clásica) genera una falsa sensación de seguridad, mientras que la banda del MCMC admite que el proceso tiene la capacidad de oscilar con mayor fuerza.

La superioridad visual de las bandas MCMC radica en que no solo contienen la trayectoria real, sino que lo hacen respetando la naturaleza de los datos. Al haber calibrado el modelo considerando los puentes brownianos, el abanico de posibilidades futuras incorpora el hecho de que el mercado puede moverse drásticamente incluso cuando no hay registros oficiales. Este resultado sugiere que el aumento de datos dota al modelo de una capacidad de cobertura estadística superior, proporcionando un margen de maniobra más realista para la toma de decisiones financieras en escenarios de incertidumbre.

5.4.3. Métricas de Desempeño Predictivo.

Para concluir el análisis de validación, se calcularon métricas de error y momentos estadísticos sobre el conjunto de prueba que abarca el periodo 2024–2025. Este análisis permite cuantificar la precisión de las simulaciones estocásticas frente a la trayectoria real de las tasas observadas. En la Tabla 5.9 se presentan los resultados comparativos de precisión, tendencia y dispersión.

	Bono Tesoro ($\hat{\text{TNX}}$)		CETES 28 Días	
Media Real (Test)	0.042390		0.092952	
Varianza Real (Test)	$4,6670 \times 10^{-6}$		$2,4094 \times 10^{-4}$	
Métrica	Clásico	MCMC	Clásico	MCMC
RMSE (Error Puntual)	0.007140	0.008565	0.023882	0.019298
Media Simulada Prom.	0.038524	0.038087	0.113911	0.111110
Diferencia de Medias	0.003866	0.004303	0.020959	0.018159
Varianza Simulada	$9,4884 \times 10^{-5}$	$1,1605 \times 10^{-4}$	$2,0083 \times 10^{-4}$	$2,5072 \times 10^{-4}$
Diferencia de Varianzas	$9,0217 \times 10^{-5}$	$1,1138 \times 10^{-4}$	$4,0114 \times 10^{-5}$	$9,7828 \times 10^{-6}$

Cuadro 5.9: Métricas detalladas de validación predictiva fuera de la muestra (2024–2025).

En el mercado de los certificados mexicanos, los resultados validan la superioridad del enfoque bayesiano. El MCMC no solo reduce el Error Cuadrático Medio de 0.0238 a 0.0192, sino que logra una captura casi exacta de la dispersión del mercado. Mientras que el método clásico presenta una diferencia de varianzas notable, el estimador obtenido mediante aumento de datos arroja una discrepancia de apenas $9,7828 \times 10^{-6}$. Esta precisión demuestra que al considerar la actividad latente durante los silencios informativos, el modelo se calibra con una estructura de riesgo que replica fielmente la variabilidad real de los CETES, incluso en periodos de alta incertidumbre.

Aunque el modelo captura bien la volatilidad, todavía hay una diferencia de unos 180 puntos base en la media de los CETES. Esto se explica por la propia limitación del modelo: el Brennan–Schwartz es de un solo factor y asume que todo se mueve por pura reversión a la media, pero en la realidad, los CETES dependen de lo que decida Banxico. Esas decisiones de política monetaria no son azarosas ni dependen de una sola fuente de riesgo, esa inercia institucional de nuestro mercado mete ruidos que un modelo de pura difusión no alcanza a captar por completo, especialmente cuando hay cambios en la tasa objetivo [47, 17].

Por otro lado, los resultados del bono estadounidense presentan un matiz relevante. El método clásico muestra un error puntual ligeramente menor, sin embargo, el MCMC arroja una varianza simulada mayor. Esta aparente pérdida de precisión es en realidad un reflejo de la prudencia del modelo. Al reconocer una volatilidad histórica más alta debido a la reconstrucción de los fines de semana, el MCMC proyecta un abanico de posibilidades más amplio. En la gestión de riesgos, este comportamiento es preferible, ya que el modelo clásico tiende a un optimismo artificial que subestima la probabilidad de movimientos extremos, mientras que el enfoque bayesiano ofrece una cobertura más realista de la incertidumbre [19, 57]. El ligero aumento en el RMSE es el costo de poseer una banda de cobertura más realista que no subestima la volatilidad del activo.

En resumen, la validación fuera de la muestra confirma que la incorporación de trayectorias latentes no es solo una sofisticación teórica, sino una corrección estadística con efectos tangibles en la capacidad predictiva del modelo. Mientras que el método clásico opera bajo la premisa de que el mercado se detiene en los silencios informativos, el algoritmo MCMC reconoce la continuidad del riesgo, lo que se traduce en una captura superior de la varianza en mercados emergentes como el mexicano y en una gestión más conservadora del riesgo en mercados desarrollados. Estos resultados cierran el ciclo de experimentación, demostrando que la inferencia bayesiana con aumento de datos constituye un marco de trabajo más robusto y coherente para la modelación de tasas de interés en tiempo continuo, sentando las bases para las conclusiones generales de esta investigación.

Capítulo 6

Conclusiones y Trabajo Futuro

La presente investigación permitió validar la hipótesis de que la irregularidad temporal en los registros de las tasas de rendimiento no es un factor despreciable, sino un componente estructural que sesga la estimación de parámetros bajo los métodos tradicionales. Al confrontar la elegancia de las ecuaciones diferenciales estocásticas con la aspereza de los datos reales, se confirmó que el tiempo financiero no se detiene durante los silencios informativos del mercado. La implementación del algoritmo MCMC con aumento de datos demostró que la reconstrucción de trayectorias latentes mediante puentes brownianos permite capturar una volatilidad consistentemente superior a la del método clásico, revelando que ignorar los fines de semana y días feriados conduce a una subestimación importante de la energía estocástica de los activos analizados [22, 48].

El desempeño del modelo resultó particularmente notable en el caso de los certificados de la tesorería mexicana. En un mercado caracterizado por una marcada inercia institucional y discontinuidades en el reporte, la aplicación del rigor bayesiano permitió reducir el error puntual en la validación fuera de la muestra y lograr una captura casi exacta de la varianza real de los CETES a 28 días. Aunque el método tradicional puede parecer más atractivo en periodos de estabilidad extrema debido a sus estimaciones de volatilidad más bajas, el análisis determinó que este comportamiento responde a un optimismo artificial. El enfoque bayesiano, al incorporar la incertidumbre de los periodos no observados [22, 48], ofrece una cobertura de riesgo más honesta y conservadora, lo cual es fundamental para la gestión de carteras y la prevención de eventos extremos en el sector de renta fija.

Más allá de los hallazgos estadísticos, este trabajo aporta un motor computacional optimizado en el lenguaje R, diseñado específicamente para procesar décadas de información diaria mediante el uso de puentes brownianos variables. Esta herramienta es capaz de manejar miles de puntos latentes y garantizar la convergencia de las cadenas de Markov incluso ante eventos de volatilidad elevada, proporcionando un marco de trabajo sólido para diferenciar entre la volatilidad que simplemente se observa y la volatilidad intrínseca que rige el tiempo continuo. Con esto, la metodología transforma las fórmulas de inferencia en herramientas confiables para el analista financiero contemporáneo, superando las limitantes de la discretización lineal que suelen comprometer la precisión de los modelos de difusión tradicionales.

Finalmente, la arquitectura desarrollada en esta tesis sienta las bases para diversas líneas de investigación que podrían expandir la frontera de la econometría financiera. La persistencia de la leptocurtosis en los residuales del modelo de Brennan–Schwartz sugiere que una extensión natural sería la transición hacia modelos de difusión con saltos, donde

la incorporación de un proceso de Poisson permitiría modelar explícitamente los cambios discretos en la política monetaria [40, 47]. Asimismo, el uso de redes neuronales aplicadas a ecuaciones diferenciales, como las Neural SDEs, representa una oportunidad para que el modelo aprenda funciones de deriva y difusión no lineales que las formas paramétricas actuales no logran absorber por completo [35]. Por último, la exploración de técnicas de inferencia variacional se presenta como una alternativa viable para reducir el costo computacional en series de tiempo masivas [3], permitiendo escalar estas estimaciones probabilísticas sin sacrificar la coherencia matemática que define a este trabajo.

Bibliografía

- [1] Yacine Aït-Sahalia. Maximum likelihood estimation of discretely sampled diffusions: A closed-form approximation approach. *Econometrica*, 70(1):223–262, 2002.
- [2] Yacine Aït-Sahalia. Closed-form likelihood expansions for multivariate diffusions. *The Annals of Statistics*, 36(2):906–937, 2008.
- [3] Cédric Archambeau, Dan Cornford, Manfred Opper, and John Shawe-Taylor. Gaussian process approximations of stochastic differential equations. *Journal of Machine Learning Research*, 8:17–54, 2007.
- [4] F. Baltazar-Larios. *Inferencia estadística para ecuaciones diferenciales estocásticas*. Universidad Nacional Autónoma de México, 2025.
- [5] F. Baltazar-Larios, G. A. Salcedo-Varela, and F. Delgado-Vences. Bayesian estimation of discretely observed diffusion processes using wiener chaos expansion. *Results in Applied Mathematics*, 28:100644, 2025.
- [6] Banco de México. Certificados de la tesorería de la federación (cetes). descripción del instrumento, 2024. Información institucional e histórica.
- [7] Banco de México. Tasa de interés de cetes a 28 días (cf114). sistema de información económica, 2025. Recuperado el 28 de mayo de 2025.
- [8] Ole E. Barndorff-Nielsen and Neil Shephard. Econometric analysis of realized volatility and its use in estimating stochastic volatility models. *Journal of the Royal Statistical Society: Series B (Statistical Methodology)*, 64(2):253–280, 2002.
- [9] Fred Espen Benth, Jūratė Šaltytė Benth, and Steen Koekebakker. *Stochastic Modeling of Electricity and Related Markets*, volume 11. World Scientific, 2008.
- [10] Patrick Billingsley. *Convergence of Probability Measures*. John Wiley & Sons, 2 edition, 1999.
- [11] Fischer Black and Myron Scholes. The pricing of options and corporate liabilities. *Journal of Political Economy*, 81(3):637–654, 1973.
- [12] Michael J. Brennan and Eduardo S. Schwartz. A continuous time approach to the pricing of bonds. *Journal of Banking & Finance*, 3(2):133–155, 1979.
- [13] Michael J. Brennan and Eduardo S. Schwartz. An equilibrium model of bond pricing and a test of market efficiency. *Journal of Financial and Quantitative Analysis*, 17(3):301–329, 1982.

- [14] Damiano Brigo and Fabio Mercurio. *Interest Rate Models - Theory and Practice: With Smile, Inflation and Credit*. Springer Science & Business Media, Berlin, Heidelberg, 2 edition, 2006.
- [15] Robert Brown. A brief account of microscopical observations made in the months of june, july and august 1827, on the particles contained in the pollen of plants; and on the general existence of active molecules in organic and inorganic bodies. *The Philosophical Magazine*, 4(21):161–173, 1828.
- [16] George Casella and Roger L. Berger. *Statistical Inference*. Duxbury, 2 edition, 2002.
- [17] K. C. Chan, G. Andrew Karolyi, Francis A. Longstaff, and Anthony B. Sanders. An empirical comparison of alternative models of the short-term interest rate. *The Journal of Finance*, 47(3):1209–1227, 1992.
- [18] Marc Chesney and Robert J. Elliott. Estimating the instantaneous volatility and covariance of risky assets. *Applied Stochastic Models and Data Analysis*, 11(1):51–58, 1995.
- [19] Rama Cont. Empirical properties of asset returns: stylized facts and statistical issues. *Quantitative Finance*, 1(2):223–236, 2001.
- [20] J. C. Cox, J. E. Ingersoll Jr, and S. A. Ross. A theory of the term structure of interest rates. *Econometrica*, 53(2):385–407, 1985.
- [21] Albert Einstein. Über die von der molekularkinetischen theorie der wärme geforderte bewegung von in ruhenden flüssigkeiten suspendierten teilchen. *Annalen der Physik*, 322(8):549–560, 1905.
- [22] Bjørn Eraker. Mcmc analysis of diffusion models with application to finance. *Journal of Business & Economic Statistics*, 19(2):177–191, 2001.
- [23] Kenneth R. French and Richard Roll. Stock return variances: The arrival of information and the reaction of traders. *Journal of Financial Economics*, 17(1):5–26, 1986.
- [24] Stuart Geman and Donald Geman. Stochastic relaxation, gibbs distributions, and the bayesian restoration of images. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 6(6):721–741, 1984.
- [25] Paul Glasserman. *Monte Carlo Methods in Financial Engineering*, volume 53. Springer Science & Business Media, 2003.
- [26] I. S. Gradshteyn and I. M. Ryzhik. *Table of Integrals, Series, and Products*. Academic Press, New York, corrected and enlarged edition edition, 1980.
- [27] Refet S. Gürkaynak, Brian Sack, and Jonathan H. Wright. The u.s. treasury yield curve: 1961 to the present. *Journal of Monetary Economics*, 54(8):2291–2304, 2007.
- [28] Leonid Hurwicz. Least squares bias in time series. *Statistical Inference in Dynamic Economic Models*, 10:365–383, 1950.
- [29] Stefano M. Iacus. *Simulation and Inference for Stochastic Differential Equations: With R Examples*. Springer Science & Business Media, New York, 2008.

- [30] Kiyosi Itô. Stochastic integral. *Proceedings of the Imperial Academy*, 20(8):519–524, 1944.
- [31] Jean Jacod and Philip Protter. *Discretization of Processes*, volume 67. Springer Science & Business Media, 2012.
- [32] Michael Johannes and Nicholas Polson. MCMC methods for continuous-time financial econometrics. In *Handbook of Financial Econometrics: Applications*, pages 1–72. North-Holland, 2010.
- [33] Ioannis Karatzas and Steven E. Shreve. *Brownian Motion and Stochastic Calculus*. Springer-Verlag, New York, 1991.
- [34] Samuel Karlin and Howard M. Taylor. *A Second Course in Stochastic Processes*. Academic Press, New York, 1981.
- [35] Patrick Kidger, James Foster, Xuechen Li, and Terry Lyons. Neural sdes as infinite-dimensional gans. In *Proceedings of the 38th International Conference on Machine Learning (ICML)*, volume 139, pages 5453–5463. PMLR, 2021.
- [36] Peter E. Kloeden and Eckhard Platen. *Numerical solution of stochastic differential equations*. Springer, 1992.
- [37] Yury A. Kutoyants. *Statistical Inference for Ergodic Diffusion Processes*. Springer Science & Business Media, 2004.
- [38] Robert S. Liptser and Albert N. Shiryaev. *Statistics of Random Processes: II. Applications*. Springer Science & Business Media, 2 edition, 2001.
- [39] Robert C. Merton. Theory of rational option pricing. *The Bell Journal of Economics and Management Science*, 4(1):141–183, 1973.
- [40] Robert C. Merton. Option pricing when underlying stock returns are discontinuous. *Journal of Financial Economics*, 3(1-2):125–144, 1976.
- [41] Robert C. Merton. On estimating the expected return on the market: An exploratory investigation. *Journal of Financial Economics*, 8(4):323–361, 1980.
- [42] G. N. Milstein. Approximate integration of stochastic differential equations. *Theory of Probability & Its Applications*, 19(3):557–562, 1975.
- [43] Ahmed Nafidi, G. Moutabir, and Ramón Gutiérrez-Sánchez. Stochastic brennan–schwartz diffusion process: Statistical computation and application. *Mathematics*, 7(11):1062, 2019.
- [44] Bernt Øksendal. *Stochastic differential equations: An introduction with applications*. Springer, 6 edition, 2003.
- [45] Peter C. B. Phillips and Jun Yu. A Priorless Gibbs Sampler with Application to Mean-Reverting Diffusion Processes. *Econometric Theory*, 25(1):275–291, 2009.
- [46] Daniel Revuz and Marc Yor. *Continuous Martingales and Brownian Motion*, volume 293. Springer Science & Business Media, 1999.

- [47] B. Reynoso, F. Baltazar-Larios, and L. Eslava. Maximum likelihood estimation for a markov-modulated jump-diffusion model. *Communications in Statistics - Theory and Methods*, 2022. Inference for jump-diffusion processes.
- [48] Gareth O. Roberts and Osnat Stramer. On inference for partially observed nonlinear diffusion models using the metropolis–hastings algorithm. *Biometrika*, 88(3):603–621, 2001.
- [49] Eduardo S. Schwartz. The stochastic behavior of commodity prices: Implications for valuation and hedging. *The Journal of Finance*, 52(3):923–973, 1997.
- [50] S. S. Shapiro and M. B. Wilk. An analysis of variance test for normality (complete samples). *Biometrika*, 52(3/4):591–611, 1965.
- [51] Eugen Slutsky. Über stochastische Asymptoten und Grenzwerte. *Metron*, 5(4):3–89, 1925.
- [52] Marian Smoluchowski. Zur kinetischen theorie der brownischen molekularbewegung und der suspensionen. *Annalen der Physik*, 326(14):756–780, 1906.
- [53] Michael Sørensen. Parametric inference for discretely sampled stochastic differential equations. In *Handbook of financial time series*, pages 407–432. Springer, 2004.
- [54] Cheng Yong Tang and Song Xi Chen. Parameter estimation and bias correction for diffusion processes. *Journal of Econometrics*, 149(1):65–81, 2009.
- [55] Martin A. Tanner. *Tools for Statistical Inference: Methods for the Exploration of Posterior Distributions and Likelihood Functions*. Springer, 3 edition, 1996.
- [56] Martin A. Tanner and Wing Hung Wong. The calculation of posterior distributions by data augmentation. *Journal of the American Statistical Association*, 82(398):528–540, 1987.
- [57] Stephen J. Taylor. *Asset Price Dynamics, Volatility, and Prediction*. Princeton University Press, 2005.
- [58] U.S. Department of the Treasury. Treasury securities: U.s. treasury bonds, notes and bills, 2024. Technical and structural description of 10-year bonds.
- [59] Aad W. Van der Vaart. *Asymptotic Statistics*, volume 3. Cambridge University Press, 1998.
- [60] Oldrich Vasicek. An equilibrium characterization of the term structure. *Journal of Financial Economics*, 5(2):177–188, 1977.
- [61] A. M. Walker. On the asymptotic behaviour of posterior distributions. *Journal of the Royal Statistical Society: Series B (Methodological)*, 31(1):80–88, 1969.
- [62] Norbert Wiener. Differential-space. *Journal of Mathematics and Physics*, 2(1-4):131–174, 1923.

Apéndice A

Cálculos técnicos

A.1. Cálculo del segundo momento transitorio

Ahora calculemos el segundo momento, para esto vamos a expandir x_t^2

$$\begin{aligned} x_t^2 &= e^{2Z(t)} \left(x_{t_0} + \beta \int_{t_0}^t e^{-Z(s)} ds \right)^2 \\ &= e^{2Z(t)} \left[x_{t_0}^2 + 2\beta x_{t_0} \int_{t_0}^t e^{-Z(s)} ds + \beta^2 \left(\int_{t_0}^t e^{-Z(s)} ds \right)^2 \right] \end{aligned}$$

Queremos obtener la esperanza de x_t^2 , es decir,

$$\mathbb{E}[x_t^2] = x_{t_0}^2 \mathbb{E}[e^{2Z(t)}] + 2\beta x_{t_0} \mathbb{E} \left[e^{2Z(t)} \int_{t_0}^t e^{-Z(s)} ds \right] + \beta^2 \mathbb{E} \left[e^{2Z(t)} \left(\int_{t_0}^t e^{-Z(s)} ds \right)^2 \right]$$

Término 1: $\mathbb{E}[e^{2Z(t)}]$

$$\begin{aligned} \mathbb{E}[e^{2Z(t)}] &= \exp(2\mathbb{E}[Z(t)] + 2\text{Var}[Z(t)]) \\ &= \exp \left(2 \left(\alpha - \frac{\sigma^2}{2} \right) (t - t_0) + 2\sigma^2(t - t_0) \right) \\ &= e^{(2\alpha + \sigma^2)(t - t_0)} \end{aligned}$$

Término 2: $\mathbb{E} \left[e^{2Z(t)} \int_{t_0}^t e^{-Z(s)} ds \right]$

$$\mathbb{E} \left[e^{2Z(t)} \int_{t_0}^t e^{-Z(s)} ds \right] = \int_{t_0}^t \mathbb{E} [e^{2Z(t) - Z(s)}] ds$$

Donde:

$$2Z(t) - Z(s) = \left(\alpha - \frac{\sigma^2}{2} \right) (2t - s - t_0) + \sigma(2W_t - W_s - W_{t_0})$$

Calculamos:

$$\begin{aligned} \mathbb{E}[2Z(t) - Z(s)] &= \left(\alpha - \frac{\sigma^2}{2} \right) (2t - s - t_0) \\ \text{Var}[2Z(t) - Z(s)] &= \sigma^2(4t + s - 4 \min(t, s)) \\ &= \sigma^2(4t - 3s) \quad (\text{para } s \leq t) \end{aligned}$$

Para una variable gaussiana $Y \sim N(\mu, \sigma^2)$ tenemos que $\mathbb{E}[e^Y] = e^{\mu + \frac{\sigma^2}{2}}$ [44], por tanto:

$$\mathbb{E} [e^{2Z(t)-Z(s)}] = e^{\left(\alpha - \frac{\sigma^2}{2}\right)(2t-s-t_0) + \frac{\sigma^2}{2}(4t-3s)}$$

Término 3: $\mathbb{E} \left[e^{2Z(t)} \left(\int_{t_0}^t e^{-Z(s)} ds \right)^2 \right]$

Utilizamos la identidad para el cuadrado de una integral:

$$\left(\int_{t_0}^t f(s) ds \right)^2 = 2 \int_{t_0}^t \int_{t_0}^s f(s) f(u) du ds.$$

Aplicado a $f(s) = e^{-Z(s)}$:

$$\left(\int_{t_0}^t e^{-Z(s)} ds \right)^2 = 2 \int_{t_0}^t \int_{t_0}^s e^{-Z(s)-Z(u)} du ds.$$

Vamos a descomponer $2Z(t) - Z(s) - Z(u)$,

$$\begin{aligned} 2Z(t) - Z(s) - Z(u) &= 2 \left(\alpha - \frac{\sigma^2}{2} \right) (t - t_0) - \left(\alpha - \frac{\sigma^2}{2} \right) (s - t_0) - \left(\alpha - \frac{\sigma^2}{2} \right) (u - t_0) \\ &\quad + \sigma (2W_t - W_s - W_u) \\ &= \left(\alpha - \frac{\sigma^2}{2} \right) (2t - s - u - t_0) + \sigma (2W_t - W_s - W_u). \end{aligned}$$

Definimos $Y \equiv 2W_t - W_s - W_u$

Media de Y :

$$\mathbb{E}[Y] = 0 \quad (\text{por linealidad de la esperanza y } \mathbb{E}[W.] = 0).$$

Varianza de Y :

$$\begin{aligned} \text{Var}(Y) &= \mathbb{E} [(2W_t - W_s - W_u)^2] \\ &= 4\mathbb{E}[W_t^2] + \mathbb{E}[W_s^2] + \mathbb{E}[W_u^2] - 4\mathbb{E}[W_t W_s] - 4\mathbb{E}[W_t W_u] + 2\mathbb{E}[W_s W_u] \\ &= 4t + s + u - 4 \min(t, s) - 4 \min(t, u) + 2 \min(s, u). \end{aligned}$$

Para $t_0 \leq u \leq s \leq t$ (rango de integración):

$$\text{Var}(Y) = 4t + s + u - 4s - 4u + 2u = 4t - 3s - u.$$

Usando la fórmula para la esperanza de una exponencial de variable gaussiana [44]:

$$\begin{aligned} \mathbb{E} [e^{2Z(t)-Z(s)-Z(u)}] &= \exp \left(\mathbb{E}[2Z(t) - Z(s) - Z(u)] + \frac{1}{2} \text{Var}(2Z(t) - Z(s) - Z(u)) \right) \\ &= \exp \left(\left(\alpha - \frac{\sigma^2}{2} \right) (2t - s - u - t_0) + \frac{\sigma^2}{2} (4t - 3s - u) \right). \end{aligned}$$

Combinando todo:

$$\begin{aligned} &\mathbb{E} \left[e^{2Z(t)} \left(\int_{t_0}^t e^{-Z(s)} ds \right)^2 \right] \\ &= 2 \int_{t_0}^t \int_{t_0}^s \mathbb{E} [e^{2Z(t)-Z(s)-Z(u)}] du ds \\ &= 2 \int_{t_0}^t \int_{t_0}^s \exp \left(\left(\alpha - \frac{\sigma^2}{2} \right) (2t - s - u - t_0) + \frac{\sigma^2}{2} (4t - 3s - u) \right) du ds. \end{aligned}$$

Asi que la expresion final, sustituyendo los terminos es:

$$\begin{aligned}\mathbb{E}[x_t^2] &= x_{t_0}^2 e^{(2\alpha+\sigma^2)(t-t_0)} + 2\beta x_{t_0} \int_{t_0}^t e^{\left(\alpha-\frac{\sigma^2}{2}\right)(2t-s-t_0)+\frac{\sigma^2}{2}(4t-3s)} ds \\ &\quad + 2\beta^2 \int_{t_0}^t \int_{t_0}^s e^{\left(\left(\alpha-\frac{\sigma^2}{2}\right)(2t-s-u-t_0)+\frac{\sigma^2}{2}(4t-3s-u)\right)} du ds\end{aligned}$$

Apéndice B

Repositorio Computacional y Código Fuente

El desarrollo computacional de esta investigación, incluyendo la simulación de trayectorias estocásticas, el motor de inferencia bayesiana (Muestreador de Gibbs con *Data Augmentation*) y el análisis de validación empírica para las tasas de interés, fue implementado íntegramente en el lenguaje de programación R.

Dada la extensión del código fuente y con el objetivo de fomentar la reproducibilidad de la investigación, el entorno de ejecución completo se encuentra alojado en la nube. Esto permite al lector no solo revisar la sintaxis, sino ejecutar el código de manera interactiva sin necesidad de configurar un entorno local.

El cuaderno computacional (Google Colab) contiene la implementación exacta documentada en los capítulos anteriores. Puede acceder al repositorio escaneando el siguiente código QR o ingresando directamente a la URL:



<https://colab.research.google.com/drive/1RIF1VFgIaQBDIb8IwaM8En4s60ZfFQFD#scrollTo=vwwsL3Q4QPpl>